MARCO DE EVALUACIÓN DE CIBERSEGURIDAD

LLM-Sec

Evaluación de la postura de ciberseguridad en plataformas que integran LLM

Alineado a OWASP LLM Top 10:2025,
ISO/IEC 33001 e ISO/IEC 27002:2022

Valentina Paz Campos Olguín

Universidad de Santiago de Chile | DIINF

Versión 1.0 | Julio 2026

Control de versiones

Versión	Fecha	Autor	Descripción
1.0	Julio 2026	V. Campos Olguín	Versión inicial del documento del marco.

Índice general

Control de versiones **2**

1. Introducción **1**
1.1. Propósito del documento . . . 1
1.2. Alcance . . . 1
1.3. Audiencia . . . 2
1.4. Referencias normativas . . . 2
1.5. Convenciones del documento . . . 2

2. Modelo de madurez **3**
2.1. Identificación de activos del sistema RAG . . . 3
2.2. Valoración de riesgo por activo . . . 4
2.2.1. Escala de valoración . . . 5
2.2.2. Matriz de riesgo . . . 5
2.2.3. Interpretación y priorización . . . 6
2.2.4. Trazabilidad hacia las subdimensiones . . . 7
2.3. Estructura del modelo . . . 7
2.4. Niveles de madurez . . . 7
2.5. Subdimensiones . . . 8
2.5.1. D1: Protección de entrada . . . 9
2.5.2. D2: Control de contexto RAG . . . 10
2.5.3. D3: Gestión de salida . . . 11
2.5.4. D4: Monitoreo y trazabilidad . . . 12
2.5.5. D5: Gobernanza organizacional . . . 13
2.6. Nivel verificado y nivel declarado . . . 15
2.7. Regla de piso mínimo . . . 15

3. Taxonomía de controles **17**
3.1. Estructura de los controles . . . 17
3.2. D1: Protección de entrada . . . 18
3.3. D2: Control de contexto RAG . . . 20
3.4. D3: Gestión de salida . . . 23
3.5. D4: Monitoreo y trazabilidad . . . 24
3.6. D5: Gobernanza organizacional . . . 25
3.7. Distribución de controles . . . 27

4. Perfiles organizacionales **29**
4.1. P1: PYME . . . 29

4.1.1. Trayectoria recomendada . . . 30
4.1.2. Controles prioritarios . . . 30
4.2. P2: Mediana/Grande . . . 31
4.2.1. Trayectoria recomendada . . . 31
4.2.2. Controles prioritarios . . . 31
4.3. P3: Crítica regulada . . . 32
4.3.1. Trayectoria recomendada . . . 33
4.3.2. Obligaciones regulatorias aplicables . . . 33
4.3.3. Controles prioritarios . . . 33

5. Métricas de evaluación **35**
5.1. Tasa de Filtrado de Ataques (TFA) . . . 35
5.1.1. Fuentes de *ground truth* por vector . . . 36
5.1.2. Prueba estadística . . . 36
5.1.3. Tasa de falsos positivos . . . 36
5.1.4. Correspondencia con ISO/IEC 25010:2023 . . . 37
5.2. Latencia Agregada de Seguridad (LAS) . . . 37
5.2.1. Prueba estadística . . . 37
5.2.2. Correspondencia con ISO/IEC 25010:2023 . . . 37
5.3. Porcentaje de Controles Cumplidos (PCC) . . . 37
5.3.1. Definición del universo . . . 38
5.3.2. Correspondencia con ISO/IEC 25010:2023 . . . 38
5.4. Nivel de Consistencia de Protección (NCP) . . . 39
5.4.1. Criterios de validez . . . 39
5.4.2. Correspondencia con ISO/IEC 25010:2023 . . . 39

6. Guía de evaluación **40**
6.1. Flujo de evaluación . . . 40
6.2. Criterios de verificación por fuente de evidencia . . . 40
6.2.1. Configuración . . . 41
6.2.2. Experimental . . . 41
6.2.3. Declarativo . . . 41
6.3. Matriz RACI . . . 41
6.4. Ciclo de mejora . . . 42

A. Resumen de controles por nivel **43**

B. Mapeo normativo **48**

C. Fichas técnicas de control **51**
C.1. Controles transversales . . . 51
C.1.1. C06: Delimitación explícita del contenido recuperado . . . 51
C.1.2. C13: Límite de volumen de contexto inyectado . . . 52
C.1.3. C15: Definición del rol y las restricciones del modelo . . . 53
C.1.4. C16: Proxy de seguridad independiente del generador . . . 54
C.1.5. C17: Fundamentación de la respuesta en el contexto recuperado . . . 55
C.1.6. C21: Externalización de la configuración de tiempo de ejecución . . . 56
C.1.7. C30: Verificación de procedencia e integridad del modelo . . . 56
C.2. D1: Protección de entrada . . . 57
C.2.1. C01: Límite de longitud del prompt de entrada . . . 57
C.2.2. C02: Sanitización de caracteres de control en la entrada . . . 58
C.2.3. C03: Bloqueo de intentos de inyección de instrucciones . . . 59

C.2.4. C04: Restricción de la consulta al dominio autorizado 60
C.2.5. C05: No inclusión del prompt del sistema en la respuesta 61
C.2.6. C31: Registro estructurado del motivo de bloqueo 62
C.2.7. C32: Verificación de integridad del prompt del sistema 63
C.2.8. C33: Ajuste dinámico de los umbrales de detección 64
C.2.9. C34: Medición de la tasa de rechazo por categoría de ataque 65
C.2.10. C35: Actualización de los patrones de detección 65
C.2.11. C36: Revisión del prompt del sistema ante cambios del modelo 66
C.3. D2: Control de contexto RAG 67
C.3.1. C07: Restricción al uso exclusivo del contexto recuperado 67
C.3.2. C10: Control de la cantidad de fragmentos recuperados 68
C.3.3. C08: Clasificación y filtrado del corpus por sensibilidad 69
C.3.4. C09: Verificación de integridad de los fragmentos recuperados 70
C.3.5. C11: Validación de coherencia de la consulta 71
C.3.6. C14: Exclusión de metadatos en la recuperación 72
C.3.7. C22: Control de acceso por sesión al vector store 73
C.3.8. C12: Detección de reconocimiento sistemático del corpus 74
C.3.9. C62: Registro versionado del corpus indexado 75
C.3.10. C37: Medición de la tasa de recuperación de fragmentos sensibles 76
C.3.11. C38: Ajuste de los parámetros de recuperación 76
C.3.12. C39: Actualización del particionamiento ante reclasificación 77
C.3.13. C40: Revisión proactiva del corpus ante nuevas amenazas 78
C.4. D3: Gestión de salida 79
C.4.1. C18: Sanitización de caracteres de control en la salida 79
C.4.2. C19: Bloqueo de contenido sensible por patrones deterministas 80
C.4.3. C20: Detección semántica de contenido sensible en la salida 81
C.4.4. C41: Ajuste dinámico de los umbrales de sanitización 82
C.4.5. C42: Medición de la tasa de supresión de contenido confidencial 83
C.4.6. C43: Actualización de los patrones de detección en la salida 84
C.4.7. C44: Incorporación de retroalimentación de incidentes a los patrones . . 84
C.5. D4: Monitoreo y trazabilidad 85
C.5.1. C26: Política documentada de umbrales de detección y bloqueo 85
C.5.2. C27: Procedimiento de notificación de incidentes ante la autoridad 86
C.5.3. C28: Política de retención y eliminación de datos de sesión 87
C.5.4. C23: Registro de las decisiones de bloqueo 88
C.5.5. C25: Registro de latencia y metadatos de las solicitudes 89
C.5.6. C29: Plan de pruebas de seguridad ofensiva previo al despliegue 90
C.5.7. C24: Monitoreo de patrones de consulta anómalos 91
C.5.8. C45: Actualización de los patrones de detección de anomalías 92
C.5.9. C46: Incorporación de retroalimentación de incidentes al sistema de alertas 93
C.6. D5: Gobernanza organizacional 94
C.6.1. C47: Designación del responsable de la seguridad del sistema 94
C.6.2. C48: Declaración del sistema RAG como activo de información 95
C.6.3. C49: Política de uso aceptable del sistema 96
C.6.4. C61: Inventario de activos del sistema RAG 97
C.6.5. C50: Instanciación de la matriz RACI 97
C.6.6. C51: Procedimiento de gestión de accesos 98
C.6.7. C52: Inventario de datos personales procesados 99
C.6.8. C53: Programa de capacitación en seguridad de sistemas LLM 100
C.6.9. C54: Ciclo de revisión periódica del marco 101
C.6.10. C55: Comunicación de los riesgos residuales a la dirección 102

C.6.11. C60: Evaluación formal de riesgos del sistema 103
C.6.12. C56: Métricas de desempeño de la gobernanza de seguridad 103
C.6.13. C57: Clasificación del sistema por nivel de criticidad 104
C.6.14. C58: Revisión proactiva del marco ante cambios del entorno 105
C.6.15. C59: Incorporación de lecciones aprendidas al ciclo de gobernanza 106

D. Glosario **108**

Referencias **111**

Capítulo 1

Introducción

1.1 Propósito del documento

Este documento especifica el marco LLM-Sec, un instrumento de evaluación de la postura de ciberseguridad para plataformas que integran modelos de lenguaje de gran escala (LLM) en arquitecturas de generación aumentada por recuperación (RAG). El marco combina un modelo de madurez de seis niveles con una taxonomía de 62 controles operacionales, proporcionando al evaluador criterios cuantificables y reproducibles para determinar el estado de seguridad de un sistema RAG.

1.2 Alcance

El marco LLM-Sec está diseñado para evaluar sistemas RAG que cumplan las siguientes condiciones:

- Utilizan un modelo de lenguaje como componente de inferencia.
- Incorporan una base de datos vectorial como fuente de contexto.
- Operan en un entorno donde la entrada del usuario se procesa en lenguaje natural.
- El modelo opera sin agencia sobre el sistema que lo aloja: no invoca funciones, no accede al sistema de archivos, no establece conexiones de red ni ejecuta código. Su única salida es texto generado.

Esta última condición delimita la arquitectura evaluable a un flujo RAG conversacional y excluye las arquitecturas agénticas, en que el modelo dispone de herramientas que le permiten actuar sobre su entorno. Tales sistemas introducen vectores de amenaza adicionales, como la ejecución de acciones no autorizadas derivadas de una instrucción inyectada, que requieren controles de aislamiento y validación de invocación no contemplados en la taxonomía de este marco.

El marco cubre cuatro categorías de amenaza del OWASP LLM Top 10:2025 pertinentes al flujo RAG: LLM01 (Prompt Injection), LLM02 (Sensitive Information Disclosure), LLM07 (System Prompt Leakage) y LLM08 (Vector and Embedding Weaknesses).

1.3 Audiencia

- **Evaluadores de seguridad:** profesionales que realizan auditorías de sistemas RAG.
- **Equipos de desarrollo:** responsables de implementar controles en el ciclo de vida del sistema.
- **Oficiales de cumplimiento:** encargados de verificar la adherencia a normativa vigente.
- **Dirección:** tomadores de decisiones que requieren una visión ejecutiva del nivel de riesgo.

1.4 Referencias normativas

El marco LLM-Sec se ancla a las siguientes referencias:

Referencias principales

OWASP	LLM Top 10:2025
ISO/IEC 33001	Evaluación de capacidad de procesos
ISO/IEC 27002:2022	Controles de seguridad de la información
NIST AI RMF	Marco de gestión de riesgos de IA
Ley 21.663	Marco de Ciberseguridad (Chile)
Ley 21.719	Protección de Datos Personales (Chile)
Boletín 16821-19	Proyecto de Ley de Inteligencia Artificial (Chile)

1.5 Convenciones del documento

A lo largo de este documento se utilizan las siguientes convenciones visuales:

- Los controles se identifican con `C01` – `C62`.
- Los niveles de madurez se representan con etiquetas: N0 N1 N2 N3 N4 N5.
- Los tipos funcionales se distinguen por color: Preventivo Detectivo Correctivo Gobernanza.
- Las fuentes de evidencia se indican como: Configuración Experimental Declarativo.

Los términos técnicos empleados en este documento se definen en el Apéndice D.

Capítulo 2

Modelo de madurez

El modelo de madurez es el componente del marco LLM-Sec que asigna a un sistema RAG un nivel en una escala ordinal según la solidez de sus controles de seguridad. Su construcción sigue tres pasos: la identificación de los activos que el sistema expone, la valoración del riesgo asociado a cada uno, y la definición de las subdimensiones y niveles sobre los cuales se realiza la evaluación. Las dos primeras secciones establecen el perímetro y la priorización; las restantes especifican la estructura del modelo, los seis niveles de madurez, las cinco subdimensiones y la regla de agregación del nivel global.

2.1 Identificación de activos del sistema RAG

Toda evaluación de seguridad requiere, como paso previo a la definición de controles, la identificación de los activos sobre los cuales opera el riesgo. Esta práctica está establecida en el NIST CSF 2.0, cuya función *Identify* define la gestión de activos como condición necesaria antes de seleccionar e implementar medidas de protección. En consecuencia, esta sección declara los activos del sistema RAG que el marco LLM-Sec tiene por objeto proteger, delimitando el perímetro de evaluación sobre el cual se articulan los componentes del marco.

A diferencia de un LLM aislado, los sistemas RAG exponen una superficie de ataque distribuida en múltiples componentes encadenados, cada uno de los cuales constituye un activo susceptible de ser comprometido de forma independiente. La Tabla 2.1 presenta los cinco activos identificados, su descripción funcional dentro del flujo RAG y el riesgo principal asociado a cada uno.

Cuadro 2.1: Activos del sistema RAG y riesgos asociados.

ID	Activo	Riesgo principal	Referencia
A1	LLM	Manipulación del comportamiento del modelo mediante inyección de instrucciones maliciosas en lenguaje natural.	LLM01
A2	Base de datos vectorial	Recuperación no autorizada de fragmentos indexados e intoxicación del corpus mediante documentos maliciosos.	LLM08
A3	Corpus de conocimiento	Exposición de información sensible contenida en los documentos indexados mediante consultas diseñadas para exfiltración.	LLM02
A4	Canales de entrada y salida	Transporte de instrucciones maliciosas en la entrada y filtración de información del corpus o del prompt del sistema en la salida.	LLM01, LLM07
A5	Mecanismos de acceso y sesión	Acceso no autorizado a información sensible por ausencia de control de identidad o segregación de permisos.	NIST AI RMF

Cada activo ocupa una posición específica dentro del flujo de inferencia RAG, lo que determina qué vectores de amenaza le son aplicables y, en consecuencia, qué subdimensión del modelo de madurez lo cubre:

Mapeo activo → subdimensión

Activo	Etapa del flujo	Subdimensión	Vectores
A1 (LLM)	Inferencia	D1, D3	LLM01
A2 (Base vectorial)	Recuperación	D2	LLM08
A3 (Corpus)	Recuperación	D2	LLM02
A4 (Canales E/S)	Entrada y salida	D1, D3	LLM01, LLM07
A5 (Acceso y sesión)	Transversal	D4, D5	Transversal

Este mapeo justifica la existencia de exactamente cinco subdimensiones y no un número arbitrario: cada subdimensión protege un subconjunto distinto del flujo RAG, y el modelo de madurez evalúa cada uno de forma independiente antes de agregar un nivel global mediante la regla de piso mínimo (sección 2.7).

2.2 Valoración de riesgo por activo

Una vez identificados los activos, el paso siguiente consiste en valorar el riesgo asociado a cada uno. El marco LLM-Sec adopta la definición de riesgo de la Ley 21.663, que lo formula en términos de **probabilidad de ocurrencia** de un incidente y el **impacto de sus consecuencias**. Esta formulación exige que la valoración no sea cualitativa sino cuantificable, lo que justifica el uso de una matriz de riesgo como instrumento de priorización.

2.2.1 Escala de valoración

La valoración emplea dos ejes, cada uno con tres niveles:

Escalas de probabilidad e impacto

Probabilidad de explotación			Impacto de compromiso		
3	Alta	Explotable con herramientas automatizadas de acceso público.	3	Alto	Exfiltración de datos sensibles o pérdida de control del modelo.
2	Media	Requiere conocimiento técnico específico del sistema.	2	Medio	Degradación del servicio o exposición parcial de información.
1	Baja	Requiere acceso privilegiado o condiciones poco frecuentes.	1	Bajo	Impacto operacional contenido, sin exposición de datos.

2.2.2 Matriz de riesgo

La Tabla 2.2 presenta la valoración de riesgo para cada activo identificado en la sección anterior. El nivel de riesgo se obtiene como el producto de probabilidad e impacto, clasificado en tres categorías: **Alto** (≥ 6), **Medio** ($3{-}4$) y **Bajo** (≤ 2).

Cuadro 2.2: Matriz de valoración de riesgo por activo del sistema RAG.

ID	Activo	Probabilidad	Impacto	Riesgo	Clasificación
A4	Canales de E/S	3 (Alta)	3 (Alto)	9	Alto
A1	LLM	3 (Alta)	3 (Alto)	9	Alto
A3	Corpus	3 (Alta)	3 (Alto)	9	Alto
A2	Base vectorial	2 (Media)	3 (Alto)	6	Alto
A5	Acceso y sesión	1 (Baja)	3 (Alto)	3	Medio

La Figura 2.1 ubica cada activo en la matriz probabilidad $\times$ impacto, evidenciando la concentración del riesgo en la zona superior derecha.



Figura 2.1: Matriz de riesgo probabilidad × impacto con la ubicación de los activos del sistema RAG.

2.2.3 Interpretación y priorización

La valoración revela tres hallazgos que condicionan el diseño del modelo de madurez y la distribución de controles:

1. **Los canales de entrada/salida, el LLM y el corpus concentran el riesgo más alto.** Esto se debe a que los vectores LLM01, LLM02 y LLM07 son explotables con herramientas automatizadas de acceso público (como Garak), sin requerir acceso privilegiado al sistema. Esta condición explica que las subdimensiones D1 (Protección de entrada), D2 (Control de contexto RAG) y D3 (Gestión de salida) concentren el mayor volumen de controles en la taxonomía: 17, 18 y 10 respectivamente, frente a 9 de D4 y 15 de D5.

2. **La base vectorial presenta riesgo alto con probabilidad media.** A diferencia de los canales de E/S, la explotación de LLM08 requiere conocimiento específico de la infraestructura de recuperación (tipo de base vectorial, estrategia de indexación, configuración de similitud). No obstante, el impacto de su compromiso es alto porque afecta la integridad de todo el corpus recuperable. Esto justifica que D2 sea la subdimensión con mayor densidad de controles (18), cubriendo tanto los riesgos de alta probabilidad del corpus (LLM02) como los de probabilidad media de la infraestructura vectorial (LLM08).

3. **Los mecanismos de acceso y sesión presentan riesgo medio.** Su probabilidad de explotación es baja porque requiere acceso privilegiado o condiciones poco frecuentes, pero el impacto de su compromiso sigue siendo alto. Esto justifica que el control de acceso por sesión (C22) se clasifique con fuente de evidencia declarativa: su verificación depende de la capa de identidad y autenticación de la organización, componente externo al flujo de inferencia RAG y por tanto no evaluable mediante auditoría ofensiva contra el sistema. Su implementación sigue siendo imprescindible en todo despliegue productivo.

La valoración presentada corresponde a un sistema RAG genérico. Cada organización debe recalcular la probabilidad y el impacto según su contexto de despliegue específico, utilizando las escalas definidas. El perfil organizacional (P1, P2 o P3) orienta la interpretación del nivel de riesgo aceptable, pero no reemplaza esta valoración.

2.2.4 Trazabilidad hacia las subdimensiones

La valoración de riesgo justifica la estructura del modelo de madurez de la siguiente forma:

Riesgo → subdimensión → densidad de controles

Activo	Riesgo	Subdimensión	Controles	Prioridad
A4 (Canales E/S)	Alto (9)	D1, D3	17 + 10	Máxima
A1 (LLM)	Alto (9)	D1, D3	17 + 10	Máxima
A3 (Corpus)	Alto (9)	D2	18	Máxima
A2 (Base vectorial)	Alto (6)	D2	18	Alta
A5 (Acceso y sesión)	Medio (3)	D4, D5	9 + 15	Media

Esta trazabilidad garantiza que la distribución de controles del marco no es arbitraria, sino proporcional al riesgo valorado de cada activo. Las subdimensiones con mayor densidad de controles (D1, D2, D3) corresponden a los activos con mayor nivel de riesgo, mientras que D4 y D5, asociadas a activos de riesgo medio, priorizan la observación y la gobernanza sobre la intervención directa.

2.3 Estructura del modelo

A partir de los activos identificados y su valoración de riesgo (secciones 2.1 y 2.2), el modelo de madurez LLM-Sec define seis niveles (N0 a N5) que representan una escala ordinal de la postura de ciberseguridad de un sistema RAG. La progresión es acumulativa: alcanzar un nivel N_k requiere satisfacer todos los criterios de los niveles N_0 a N_{k-1}. Las distancias entre niveles no son uniformes; cada nivel refleja un salto cualitativo en la solidez de los procesos, no un incremento lineal.

El modelo evalúa cinco subdimensiones derivadas de los ítems del OWASP LLM Top 10:2025 pertinentes al flujo RAG, cuya trazabilidad hacia los activos del sistema se estableció en la sección 2.1. Dado que no existe un modelo de madurez estandarizado para arquitecturas RAG en la literatura actual, esta derivación constituye una contribución original del marco.

2.4 Niveles de madurez

N0: Inexistente

Sin consciencia de seguridad. No existen controles, políticas ni identificación de riesgos asociados al sistema RAG. Estado previo al despliegue del sistema; no genera artefactos de evaluación.

N1: Inicial

Los riesgos son reconocidos pero no se han implementado controles para abordarlos. El sistema opera sin mecanismos de protección activos, asumiendo implícitamente los riesgos existentes. Corresponde a un sistema RAG desplegado sin capa defensiva.

N2: Reactivo

Controles básicos implementados de forma parcial o no sistemática. Respuesta ante incidentes conocidos, no preventiva. Se evidencia mediante la activación de una capa defensiva con configuración por defecto; la tasa de filtrado de ataques es positiva pero variable entre categorías.

N3: Definido

Controles formalmente definidos, documentados y aplicados de forma consistente. Umbrales de detección establecidos antes de la operación. Los logs de la capa defensiva son trazables por escáner y categoría de amenaza.

N4: Gestionado

Seguridad gestionada cuantitativamente. Métricas de desempeño definidas y controles ajustados según resultados medidos. El nivel de correlación entre la puntuación del checklist y la resistencia experimental es estadísticamente significativo.

N5: Optimizado

Mejora continua. Controles actualizados proactivamente ante nuevas amenazas documentadas. Marco revisado periódicamente e integrado al ciclo de gestión de riesgos organizacional. Requiere validación longitudinal y en múltiples dominios.

2.5 Subdimensiones

El modelo organiza la evaluación en cinco subdimensiones, cada una derivada de los vectores de amenaza del OWASP LLM Top 10:2025 pertinentes al flujo RAG. Las tres primeras (D1, D2, D3) operan sobre etapas específicas del flujo de inferencia: entrada, recuperación y salida respectivamente. D4 opera de forma transversal registrando los eventos generados por las anteriores, y D5 captura las obligaciones organizacionales que sustentan la operación segura del sistema en su conjunto. Esta estructura garantiza que cada punto del flujo RAG identificado en la sección 2.1 sea cubierto por al menos una subdimensión, y que la densidad de controles de cada una sea proporcional al riesgo valorado en la sección 2.2. El siguiente cuadro sintetiza las cinco subdimensiones, los vectores OWASP que cubre cada una y el aspecto del sistema que captura.

Subdimensiones del modelo LLM-Sec

ID	Nombre	OWASP	Captura
D1	Protección de entrada	LLM01, LLM02	Validación y sanitización de prompts
D2	Control de contexto RAG	LLM02, LLM08	Acceso y exposición de la base vectorial
D3	Gestión de salida	LLM02, LLM07	Filtrado y control de respuestas
D4	Monitoreo y trazabilidad	Todos	Logging, alertas y auditoría
D5	Gobernanza organizacional	—	Roles, políticas y cultura de seguridad

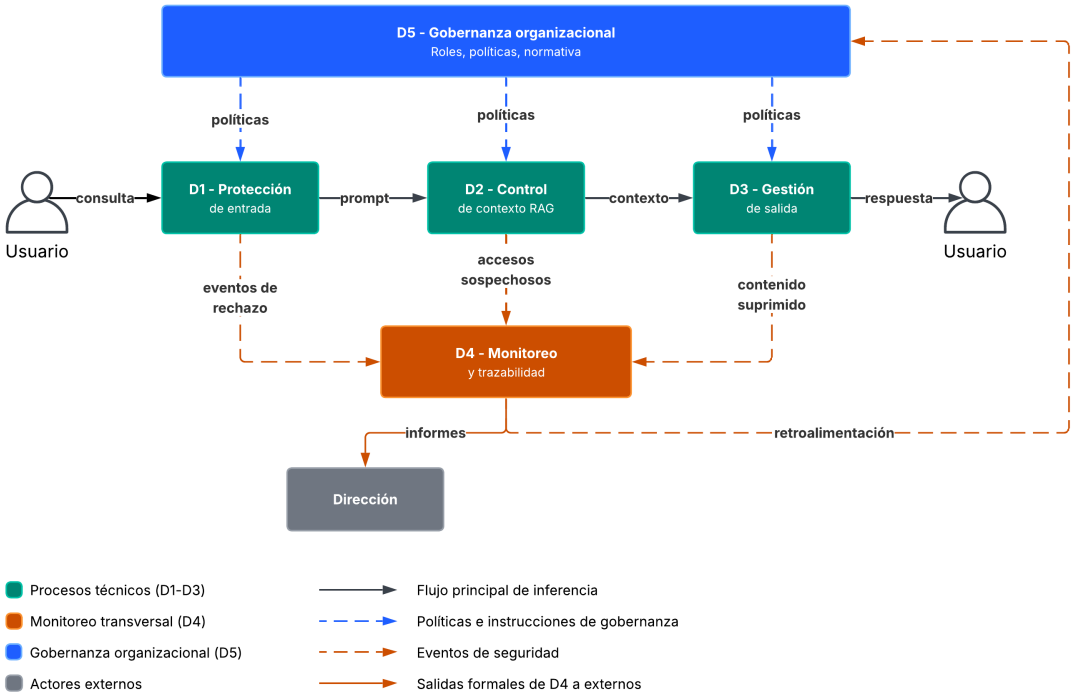


Figura 2.2: Flujo de entradas y salidas de todos los procesos.

2.5.1 D1: Protección de entrada

La subdimensión D1 representa el primer punto de contacto entre el usuario y el sistema RAG, constituyendo la primera línea de defensa para garantizar una secuencia de acciones segura. Los activos sobre los que opera son los canales de entrada y el propio LLM, cuyo comportamiento puede ser manipulado si el prompt no es validado previamente.

La ficha del proceso y su especificación de entradas y salidas se presentan a continuación; la Figura 2.3 representa gráficamente el mismo flujo.

Ficha del proceso D1: Protección de entrada

Propósito	Interceptar amenazas semánticas antes de que alcancen la capa de inferencia, mediante validación y sanitización del prompt de entrada.
Activos que protege	Canales de entrada y LLM.
Vector OWASP asociado	LLM01:2025

Entradas y salidas del proceso D1

Desde	Entrada	Salida	Hacia
Usuario	Prompt en lenguaje natural	Prompt sanitizado y validado	D2
Sistema	System prompt configurado	Registro de prompts rechazados	D4
Configuración	Políticas de restricción (YAML)	Alerta de intento de inyección detectado	D4
D5	Política de uso aceptable	—	—

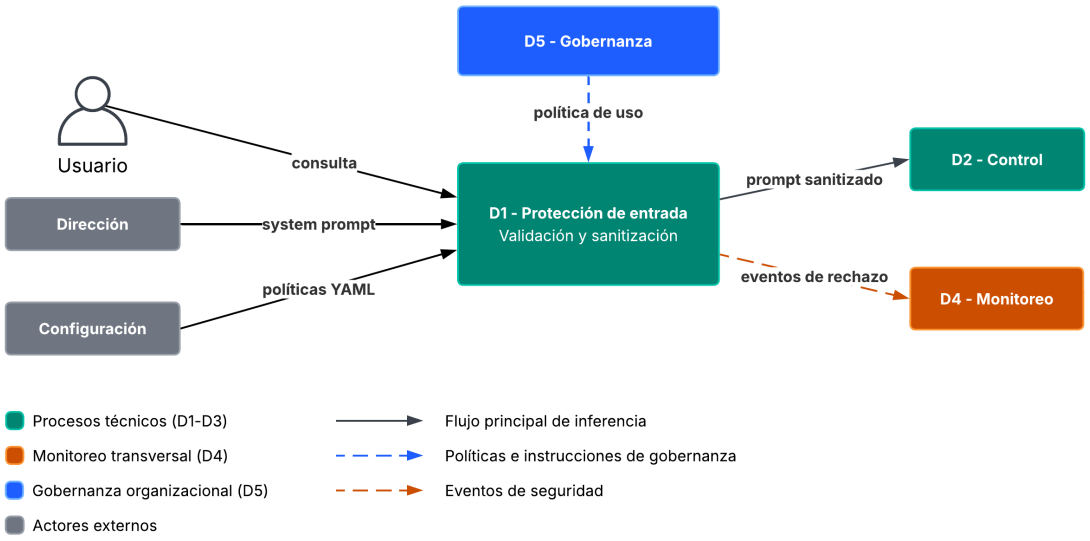


Figura 2.3: Flujo de entradas y salidas del proceso D1: Protección de entrada.

2.5.2 D2: Control de contexto RAG

La subdimensión D2 abarca los controles que regulan el acceso, la exposición y la integridad de la base de datos vectorial y el corpus de conocimiento. Opera sobre la etapa de recuperación del flujo RAG, donde los fragmentos de contexto son seleccionados y entregados al modelo como parte del prompt aumentado.

La ficha del proceso y su especificación de entradas y salidas se presentan a continuación; la Figura 2.4 representa gráficamente el mismo flujo.

Ficha del proceso D2: Control de contexto RAG

Propósito	Controlar el acceso y la exposición del corpus indexado, limitando qué fragmentos pueden ser recuperados e incorporados al contexto de inferencia del LLM.
Activos que protege	Base de datos vectorial y corpus de conocimiento.
Vector OWASP asociado	LLM02:2025, LLM08:2025

Entradas y salidas del proceso D2

Desde	Entrada	Salida	Hacia
D1	Prompt sanitizado y validado	Contexto recuperado y prompt aumentado	D3
Corpus	Documentos indexados	Contexto recuperado y prompt aumentado	D3
Sistema	Configuración del *vector store*	Eventos de recuperación sospechosa	D4
D5	Política de clasificación de sensibilidad del corpus	—	—

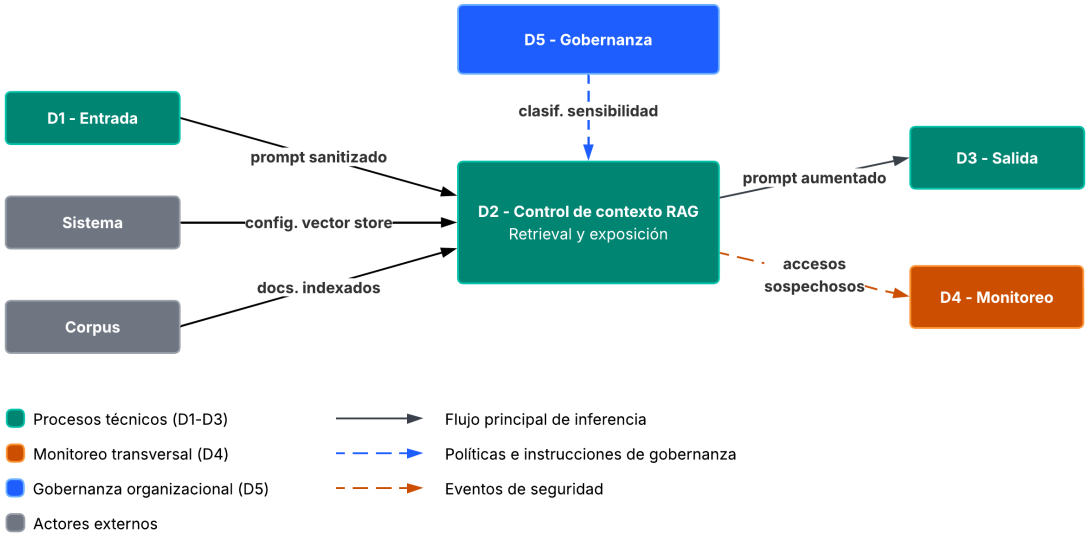


Figura 2.4: Flujo de entradas y salidas del proceso D2: Control de contexto RAG.

2.5.3 D3: Gestión de salida

La subdimensión D3 comprende los controles que filtran y regulan las respuestas generadas por el modelo antes de entregarlas al usuario. Opera sobre el canal de salida del flujo RAG, constituyendo la última línea de defensa contra la exfiltración de información sensible y la fuga del prompt del sistema.

La ficha del proceso y su especificación de entradas y salidas se presentan a continuación; la Figura 2.5 representa gráficamente el mismo flujo.

Ficha del proceso D3: Gestión de salida

Propósito	Filtrar y controlar las respuestas generadas por el LLM, detectando y suprimiendo contenido sensible antes de que sea transmitido al usuario.
Activos que protege	Canales de salida y corpus de conocimiento.
Vector OWASP asociado	LLM01:2025, LLM07:2025

Entradas y salidas del proceso D3

Desde	Entrada	Salida	Hacia
D2	Prompt aumentado con contexto recuperado	Respuesta sanitizada y validada	Usuario
LLM	Respuesta generada	Registro de contenido suprimido	D4
Configuración	Patrones de detección de contenido sensible (YAML)	Alerta de fuga de información detectada	D4
D5	Política de clasificación de sensibilidad	—	—

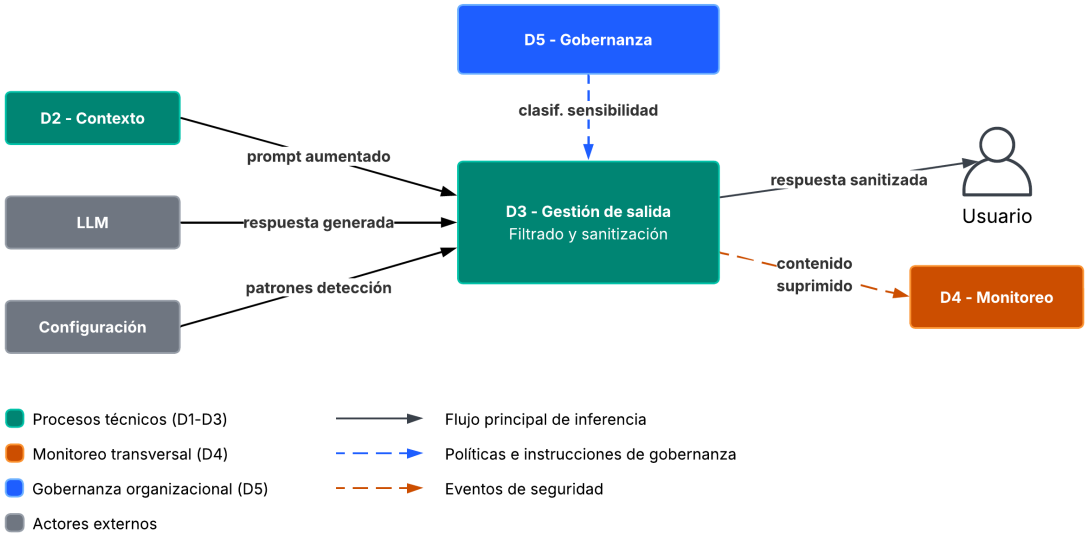


Figura 2.5: Flujo de entradas y salidas del proceso D3: Gestión de salida.

2.5.4 D4: Monitoreo y trazabilidad

La subdimensión D4 opera de forma transversal sobre el sistema RAG completo. Su naturaleza es observacional: no interviene sobre el flujo sino que lo registra. Sus entradas son eventos generados por las tres subdimensiones anteriores y sus salidas son exclusivamente artefactos de auditoría.

D4 no define controles de nivel N1 porque el monitoreo mínimo viable requiere que el sistema disponga de algún mecanismo activo de registro, condición que no se cumple en un sistema

sin capa defensiva. Un sistema en esa condición se clasifica como no conforme en esta subdimensión.

La ficha del proceso y su especificación de entradas y salidas se presentan a continuación; la Figura 2.6 representa gráficamente el mismo flujo.

Ficha del proceso D4: Monitoreo y trazabilidad

Propósito	Registrar, alertar y auditar los eventos de seguridad generados en el flujo RAG, garantizando trazabilidad completa sobre el comportamiento defensivo del sistema.
Activos que protege	Sistema RAG completo.
Vector OWASP asociado	LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

Entradas y salidas del proceso D4

Desde	Entrada	Salida	Hacia
D1	Registro de prompts rechazados y alertas de inyección	Logs de auditoría consolidados	D5
D2	Eventos de recuperación sospechosa	Alertas de comportamiento anómalo	D5
D3	Registro de contenido suprimido y alertas de fuga	Informe de incidentes de seguridad	D5
Sistema	Métricas de latencia del flujo de inferencia	—	—

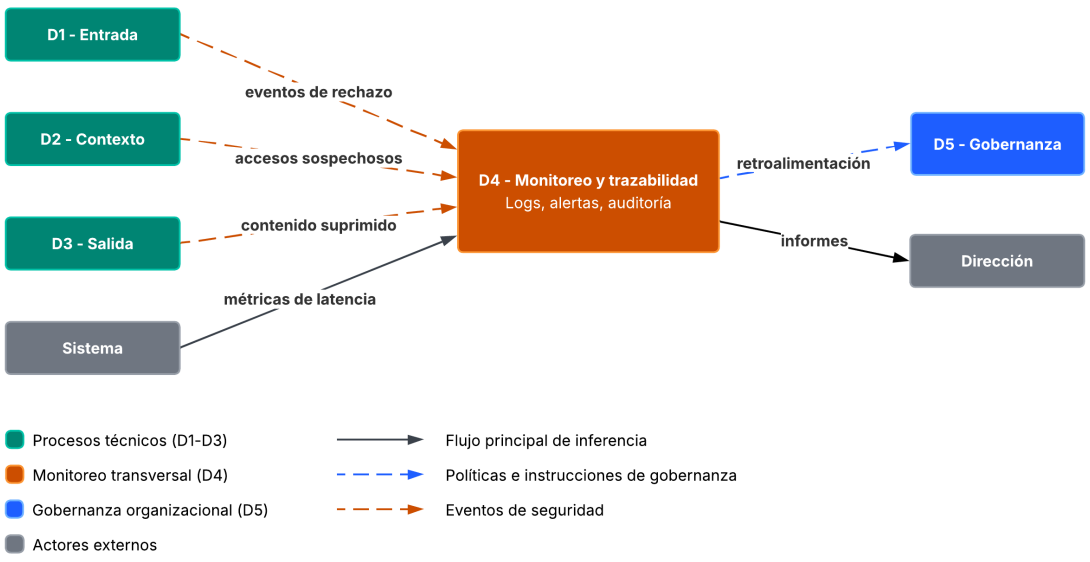


Figura 2.6: Flujo de entradas y salidas del proceso D4: Monitoreo y trazabilidad.

2.5.5 D5: Gobernanza organizacional

La subdimensión D5 opera de forma transversal sobre la organización completa, no sobre una etapa técnica específica del flujo RAG. Captura las obligaciones institucionales de gestión de la

seguridad: definición de roles y responsabilidades, políticas de uso, cumplimiento normativo y mejora continua del marco. Su verificación es exclusivamente declarativa porque sus controles son artefactos organizacionales que no producen traza observable en el flujo de inferencia: su cumplimiento se establece mediante revisión documental y auditoría organizacional, no mediante inspección del sistema ni ejecución de pruebas ofensivas contra él.

D5 provee insumos normativos e institucionales a las demás subdimensiones, actuando como el proceso de gobernanza que sustenta la operación segura del sistema RAG en su conjunto. Sus entradas son marcos normativos y retroalimentación de D4, y sus salidas son políticas e instrumentos de gobernanza que condicionan la operación del resto del sistema.

La ficha del proceso y su especificación de entradas y salidas se presentan a continuación; la Figura 2.7 representa gráficamente el mismo flujo.

Ficha del proceso D5: Gobernanza organizacional

Propósito	Establecer y mantener el marco institucional de gobernanza que sustenta la operación segura del sistema RAG, definiendo roles, políticas y mecanismos de mejora continia.
Activos que protege	Sistema RAG completo (a nivel organizacional)
Vector OWASP asociado	LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

Entradas y salidas del proceso D5

Desde	Entrada	Salida	Hacia
Normativa	Ley 21.663, Ley 21.719, Proyecto Ley IA	Política de uso aceptable	D1
NIST AI RMF	Marco de gestión de riesgos de IA	Política de clasificación de sensibilidad	D2
D4	Logs de auditoría e informes de incidentes	Matriz RACI instanciada	D1–D4
D4	Logs de auditoría e informes de incidentes	Informe de riesgos residuales	Dirección
D4	Logs de auditoría e informes de incidentes	Plan de capacitación en seguridad LLM	Roles definidos

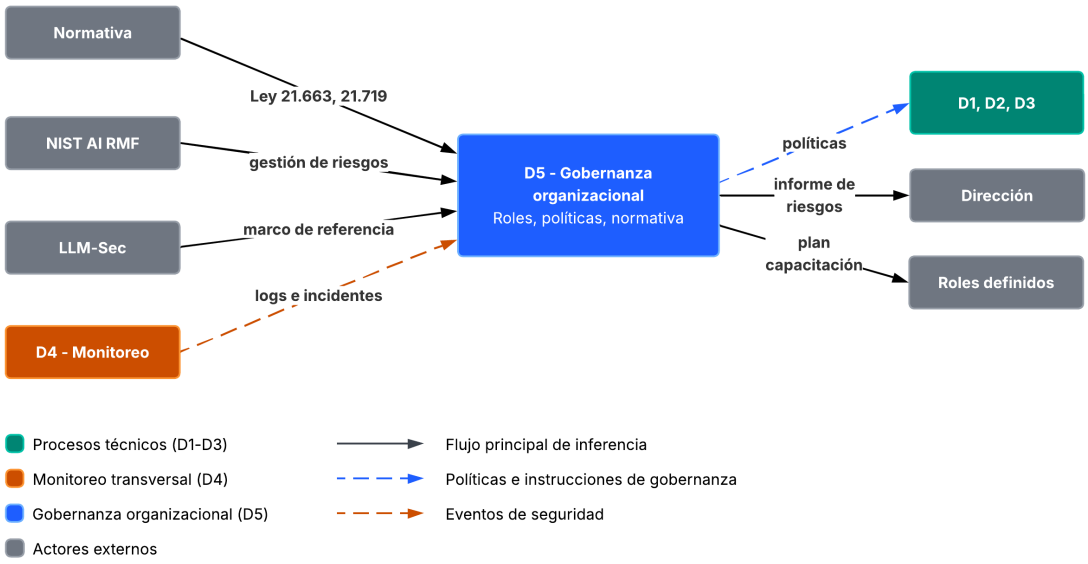


Figura 2.7: Flujo de entradas y salidas del proceso D5: Gobernanza organizacional.

2.6 Nivel verificado y nivel declarado

Las subdimensiones del modelo no admiten el mismo tipo de evidencia. D1 a D4 operan sobre componentes técnicos del flujo RAG y su cumplimiento es constatable mediante inspección del sistema o ejecución de pruebas contra él. D5 captura obligaciones organizacionales que no producen traza técnica observable. El modelo distingue en consecuencia dos tipos de nivel asignado según la fuente de evidencia que lo sustenta:

Nivel verificado: determinado mediante evidencia experimental (resultados de auditoría ofensiva, logs de la capa defensiva) o de configuración (archivos YAML, prompt del sistema). Aplica a las subdimensiones D1, D2, D3 y D4.
Nivel declarado: determinado mediante lista de chequeo sin evidencia técnica directa, basado en auditoría organizacional o revisión documental. Aplica a la subdimensión D5.

Esta distinción no establece una jerarquía entre ambos tipos de nivel: un control declarativo no es menos exigible que uno verificable, sino que su cumplimiento se constata por un medio distinto. La consecuencia práctica es que el nivel global de un sistema RAG no puede reportarse como un valor único sin especificar qué subdimensiones lo sustentan con evidencia técnica y cuáles con evidencia documental.

2.7 Regla de piso mínimo

El nivel global L del sistema se determina como:

$$L = \text{mín}(d_1, d_2, d_3, d_4, d_5)$$

donde d_i es el nivel verificado de la subdimensión i. La justificación subyacente es que la postura de seguridad de un sistema es tan sólida como su componente más débil. A modo de ejemplo, si D1, D2 y D3 alcanzan nivel 4 pero D4 alcanza nivel 2, el nivel global verificado es 2.

Dado que D5 opera exclusivamente con fuente de evidencia declarativa (sección 2.6), el nivel global resultante de la regla de piso mínimo integra necesariamente una componente declarada.

En cuanto a la ponderación dentro de cada subdimensión, todos los controles de un mismo nivel tienen peso equivalente. Esta decisión se justifica porque la ausencia de literatura previa comparable impide anclar ponderaciones diferenciales a evidencia empírica; asignar pesos arbitrarios introduciría un sesgo no justificable.

Capítulo 3

Taxonomía de controles

El modelo de madurez del capítulo anterior establece qué se evalúa y en qué escala, pero no especifica las medidas concretas que un sistema debe implementar para alcanzar cada nivel. Ese es el objeto de la taxonomía de controles: traducir cada nivel de cada subdimensión en un conjunto verificable de acciones. El capítulo define primero los atributos que caracterizan a un control, presenta luego el catálogo completo organizado por subdimensión, y cierra con la distribución de controles por nivel que resulta de la valoración de riesgo establecida en la sección 2.2.

3.1 Estructura de los controles

Cada control se caracteriza por cinco atributos:

1. **Nivel de madurez** (N1 a N5): determina en qué nivel del modelo se requiere su implementación.
2. **Tipo funcional**: preventivo, detectivo, correctivo o gobernanza, según el momento en que actúa respecto al evento de seguridad (ISO/IEC 27002:2022).
3. **Fuente de evidencia**: configuración (archivos YAML, prompt del sistema), experimental (resultados de auditoría ofensiva) o declarativo (verificación por lista de chequeo).
4. **Descripción**: acción específica que el control requiere.
5. **Fuente normativa**: referencia al estándar o legislación que lo origina.

Un control puede satisfacer más de un tipo funcional simultáneamente, consistente con el modelo de atributos de ISO/IEC 27002:2022. Por ejemplo, un escáner de salida que identifica y suprime contenido sensible actúa como control detectivo y correctivo en una misma operación.

Todos los controles de un mismo nivel tienen peso equivalente dentro de su subdimensión.

Un control transversal, aplicable a más de una subdimensión, puede citar fuentes normativas distintas en cada una de ellas. Esto responde a que su función protectora se articula contra vectores de amenaza diferentes según la etapa del flujo RAG en que actúa: el proxy de seguridad (C16) intercepta inyección de instrucciones en la entrada (LLM01), limita la exposición del corpus en la recuperación (LLM02) y previene la fuga del prompt del sistema en la salida (LLM07). El identificador y la descripción del control permanecen invariantes; solo el conjunto de fuentes normativas se acota a los vectores pertinentes a cada subdimensión.

El conjunto completo comprende 62 controles distribuidos en cinco subdimensiones y cinco niveles de madurez. Las secciones siguientes presentan los controles organizados por subdimensión.

3.2 D1: Protección de entrada

La subdimensión D1 agrupa 17 controles distribuidos en cinco niveles de madurez: 8 en N1, 3 en N2, 2 en N3, 2 en N4 y 2 en N5. El predominio de controles preventivos refleja la naturaleza de esta subdimensión: interceptar la amenaza antes de que alcance la capa de inferencia.

C01 N1

Limitar la longitud máxima del prompt de entrada, medida en la misma unidad que el modelo emplea para su ventana de contexto.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025

C02 N1

Eliminar de la entrada los tokens especiales del modelo, los bytes nulos y los caracteres de control Unicode, antes de que el texto alcance cualquier componente de análisis.

Tipo: Correctivo **Evidencia:** Experimental **Fuente:** LLM01:2025

C06 N1

Segregar e identificar el contenido recuperado del corpus mediante delimitadores explícitos que lo separen de la consulta del usuario en el prompt aumentado.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C13 N1

Limitar el volumen total de contexto inyectado al LLM restringiendo la cantidad de fragmentos recuperados por consulta.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C15 N1

Restringir el rol, las capacidades y las limitaciones del modelo mediante instrucciones de sistema declaradas externamente al código.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C16 N1

Interponer un proxy de seguridad desplegado como componente independiente del generador, que intercepte la entrada y la salida del flujo de inferencia.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C21 N1

Externalizar la configuración de tiempo de ejecución, incluidas las credenciales y los umbrales, como parámetros declarados fuera del código fuente.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C30 N1

Verificar la procedencia e integridad del modelo mediante *checksums* antes del despliegue.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663, LLM08:2025

C03 N2

Bloquear las entradas clasificadas como intento de inyección de instrucciones por un escáner que asigne una puntuación de riesgo contrastada contra un umbral configurado.

Tipo: Preventivo **Evidencia:** Experimental **Fuente:** LLM01:2025

C04 N2

Bloquear las consultas cuya distancia semántica mínima al corpus supere el umbral configurado, rechazando aquellas ajenas al dominio autorizado.

Tipo: Preventivo **Evidencia:** Experimental **Fuente:** LLM01:2025

C05 N2

Extraer de la respuesta del modelo únicamente el texto generado, sin incorporar el prompt del sistema ni sus restricciones al contenido retornado al usuario.

Tipo: Detectivo **Evidencia:** Experimental **Fuente:** LLM01:2025, LLM07:2025

C31 N3

Registrar un motivo de bloqueo estructurado para cada solicitud rechazada, identificando el componente que originó el rechazo.

Tipo: Detectivo **Evidencia:** Experimental **Fuente:** LLM01:2025

C32 N3

Verificar mediante función de resumen criptográfico que el prompt del sistema y sus restricciones no han sido modificados desde el arranque.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM07:2025

C33 N4

Ajustar dinámicamente los umbrales de detección de inyección según las tasas de falsos positivos observadas.

Tipo: Preventivo **Evidencia:** Declarativo **Fuente:** LLM01:2025

C34 N4

Medir y reportar periódicamente la tasa de prompts rechazados por categoría de ataque.

Tipo: Detectivo **Evidencia:** Declarativo **Fuente:** LLM01:2025

C35 N5

Actualizar los patrones de detección ante nuevas técnicas de inyección documentadas.

Tipo: Preventivo **Evidencia:** Declarativo **Fuente:** LLM01:2025

C36 N5

Revisar y ajustar el prompt del sistema ante cambios en el modelo base.

Tipo: Preventivo **Evidencia:** Declarativo **Fuente:** LLM01:2025

3.3 D2: Control de contexto RAG

La subdimensión D2 agrupa 20 controles orientados a regular el acceso, la exposición y la integridad de la base de datos vectorial y el corpus de conocimiento. La distribución por nivel refleja una progresión desde controles básicos de particionamiento y sanitización (N1) hasta mecanismos de auditoría avanzada y mejora continua (N5).

C06 N1

Segregar e identificar el contenido recuperado del corpus mediante delimitadores explícitos que lo separen de la consulta del usuario en el prompt aumentado.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C07 N1

Restringir el modelo al uso exclusivo del contexto recuperado, prohibiendo mediante instrucción de sistema la generación de información no fundamentada en él.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM02:2025

C10 N1

Controlar la cantidad de fragmentos recuperados por consulta para limitar la exposición del corpus.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM02:2025

C13 N1

Limitar el volumen total de contexto inyectado al LLM restringiendo la cantidad de fragmentos recuperados por consulta.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM02:2025

C15 N1

Restringir el rol, las capacidades y las limitaciones del modelo mediante instrucciones de sistema declaradas externamente al código.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C16 N1

Interponer un proxy de seguridad desplegado como componente independiente del generador, que intercepte la entrada y la salida del flujo de inferencia.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C21 N1

Externalizar la configuración de tiempo de ejecución, incluidas las credenciales y los umbrales, como parámetros declarados fuera del código fuente.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025

C30 N1

Verificar la procedencia e integridad del modelo mediante *checksums* antes del despliegue.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663, LLM08:2025

C08 N2

Clasificar cada fragmento del corpus según su nivel de sensibilidad al momento de la indexación, y restringir la recuperación a los niveles autorizados.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM02:2025, LLM08:2025

C09 N2

Verificar la integridad de los fragmentos recuperados contra una línea base establecida, antes de inyectarlos al contexto de inferencia.

Tipo: Preventivo/Detectivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM08:2025

C11 N2

Bloquear las consultas cuya distancia semántica mínima a los fragmentos del corpus supere el umbral de coherencia configurado, rechazando aquellas incoherentes o codificadas.

Tipo: Preventivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM08:2025

C14 N2

Excluir los metadatos de los documentos en la etapa de recuperación, de modo que solo el texto de los fragmentos alcance el contexto de inferencia.

Tipo: Preventivo **Evidencia:** Experimental **Fuente:** LLM02:2025

C17 N2

Bloquear las respuestas cuyo solapamiento con el contexto recuperado caiga por debajo del umbral de fundamentación configurado.

Tipo: Preventivo/Detectivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM07:2025

C22 N2

Controlar y auditar el acceso por sesión a los documentos del *vector store*.

Tipo: Preventivo/Detectivo **Evidencia:** Declarativo **Fuente:** LLM02:2025

C12 N3

Detectar y bloquear las consultas indicativas de reconocimiento o enumeración sistemática del corpus.

Tipo: Detectivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM08:2025

C62 N3

Mantener un registro versionado y persistente de cada evento de indexación del corpus, que permita identificar qué documentos estaban activos en cada sesión y rastrear los cambios entre versiones.

Tipo: Detectivo **Evidencia:** Configuración **Fuente:** LLM02:2025, LLM08:2025

C37 N4

Medir y reportar periódicamente la tasa de recuperación de fragmentos sensibles ante consultas de prueba.

Tipo: Detectivo **Evidencia:** Declarativo **Fuente:** LLM02:2025

C38 N4

Ajustar los parámetros de *retrieval* según las métricas de exposición observadas.

Tipo: Preventivo **Evidencia:** Declarativo **Fuente:** LLM02:2025

C39 N5

Actualizar el particionamiento del *vector store* ante cambios en la clasificación de sensibilidad del corpus.

Tipo: Preventivo **Evidencia:** Declarativo **Fuente:** LLM02:2025, LLM08:2025

C40 N5

Revisar proactivamente los fragmentos indexados ante nuevas amenazas de exfiltración documentadas.

Tipo: Preventivo **Evidencia:** Declarativo **Fuente:** LLM02:2025, LLM08:2025

3.4 D3: Gestión de salida

La subdimensión D3 comprende 9 controles que filtran y regulan las respuestas generadas por el modelo antes de entregarlas al usuario, constituyendo la última línea de defensa contra la exfiltración de información sensible y la fuga del prompt del sistema.

C16 N1

Interponer un proxy de seguridad desplegado como componente independiente del generador, que intercepte la entrada y la salida del flujo de inferencia.

Tipo: Preventivo **Evidencia:** Configuración **Fuente:** LLM01:2025, LLM02:2025, LLM07:2025

C17 N2

Bloquear las respuestas cuyo solapamiento con el contexto recuperado caiga por debajo del umbral de fundamentación configurado.

Tipo: Preventivo/Detectivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM07:2025

C18 N2

Eliminar de la salida del modelo los caracteres de control y los tokens especiales, antes de someterla a los escáneres de contenido y de retornarla al usuario.

Tipo: Correctivo **Evidencia:** Experimental **Fuente:** LLM01:2025, LLM07:2025

C19 N2

Bloquear las respuestas que coincidan con patrones deterministas de contenido sensible: marcadores de confidencialidad e identificadores personales estructurados.

Tipo: Detectivo/Correctivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM07:2025

C20 N3

Detectar y puntuar mediante análisis semántico las respuestas que contengan información sensible no capturada por los patrones deterministas.

Tipo: Detectivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM07:2025

C41 N4

Ajustar dinámicamente los umbrales de sanitización según las métricas de falsos positivos observadas en la salida.

Tipo: Detectivo **Evidencia:** Declarativo **Fuente:** LLM02:2025, LLM07:2025

C42 N4

Medir y reportar la tasa de supresión de fragmentos confidenciales por tipo de ataque.

Tipo: Detectivo **Evidencia:** Declarativo **Fuente:** LLM02:2025, LLM07:2025

C43 N5

Revisar y actualizar los patrones de detección de contenido sensible en la salida ante nuevas técnicas de exfiltración.

Tipo: Detectivo **Evidencia:** Declarativo **Fuente:** LLM02:2025, LLM07:2025

C44 N5

Incorporar retroalimentación de incidentes reales al conjunto de patrones de sanitización.

Tipo: Detectivo **Evidencia:** Declarativo **Fuente:** LLM02:2025, LLM07:2025

3.5 D4: Monitoreo y trazabilidad

La subdimensión D4 agrupa 9 controles de naturaleza observacional, distribuidos a partir de N2. D4 no define controles de nivel N1 porque el monitoreo mínimo viable requiere que el sistema disponga de algún mecanismo activo de registro, condición que no se cumple en un sistema sin capa defensiva.

C26 N2

Definir y documentar la política de umbrales de detección y bloqueo con anterioridad a la operación.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663

C27 N2

Establecer un procedimiento formal de notificación de incidentes de seguridad ante las autoridades competentes.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663

C28 N2

Definir la política de retención y eliminación de datos de sesión conforme a la normativa aplicable.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.719

C23 N3

Registrar cada decisión de bloqueo en la entrada y en la salida, identificando el componente que la originó.

Tipo: Detectivo **Evidencia:** Experimental **Fuente:** LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

C25 N3

Registrar la latencia y los metadatos de cada solicitud en un formato que permita el análisis posterior del comportamiento del flujo de inferencia.

Tipo: Detectivo **Evidencia:** Experimental **Fuente:** LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

C29 N3

Documentar y ejecutar un plan de pruebas de seguridad ofensiva con anterioridad a cada despliegue.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663

C24 N4

Monitorear los patrones de consulta anómalos que sugieran reconocimiento sistemático del corpus a lo largo de múltiples sesiones.

Tipo: Detectivo **Evidencia:** Experimental **Fuente:** LLM02:2025, LLM08:2025

C45 N5

Revisar y actualizar los patrones de detección de anomalías ante nuevas amenazas documentadas.

Tipo: Detectivo **Evidencia:** Declarativo **Fuente:** LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

C46 N5

Incorporar retroalimentación de incidentes al sistema de alertas de forma sistemática y periódica.

Tipo: Correctivo **Evidencia:** Declarativo **Fuente:** LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

3.6 D5: Gobernanza organizacional

La subdimensión D5 agrupa 15 controles de tipo exclusivamente Gobernanza con fuente de evidencia Declarativa. Estos controles capturan las obligaciones institucionales derivadas de la Ley 21.663, la Ley 21.719, el NIST AI RMF y el Proyecto de Ley de IA.

C47 N1

Designar formalmente un responsable de la seguridad del sistema RAG con atribuciones documentadas.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663

C48 N1

Declarar el sistema RAG como activo de información sujeto a las obligaciones de la normativa vigente.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663

C49 N1

Establecer una política de uso aceptable del sistema RAG accesible a todos los usuarios.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.719

C61 N1

Mantener un inventario actualizado de los activos del sistema RAG, incluyendo modelo, corpus, base vectorial y componentes de seguridad, conforme a lo definido en la sección 2.1.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663

C50 N2

Adoptar y adaptar la matriz RACI del marco LLM-Sec, asignando los roles genéricos definidos a personas o cargos concretos de la organización.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.663

C51 N2

Establecer un procedimiento formal de gestión de accesos que regule altas, bajas y modificaciones de permisos sobre el sistema.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.719

C52 N2

Documentar el inventario de datos personales procesados por el sistema RAG conforme a las obligaciones del responsable de tratamiento.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Ley 21.719

C53 N3

Establecer un programa formal de capacitación en seguridad de sistemas LLM dirigido a los roles definidos en la matriz RACI.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** NIST AI RMF

C54 N3

Definir y ejecutar un ciclo de revisión periódica del marco LLM-Sec con frecuencia mínima anual.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** NIST AI RMF

C55 N3

Documentar y comunicar formalmente los riesgos residuales del sistema RAG a la dirección de la organización.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** NIST AI RMF

C60 N3

Realizar y documentar una evaluación formal de riesgos del sistema RAG con frecuencia mínima anual o ante cambios significativos en el modelo o el corpus.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** NIST AI RMF

C56 N4

Establecer métricas de desempeño de la gobernanza de seguridad y reportarlas periódicamente a la dirección.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Proyecto Ley IA

C57 N4

Implementar un proceso formal de gestión de riesgos de IA que clasifique el sistema RAG según su nivel de criticidad.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Proyecto Ley IA

C58 N5

Revisar y actualizar proactivamente el marco LLM-Sec ante cambios normativos, nuevas amenazas o modificaciones del modelo base.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Proyecto Ley IA

C59 N5

Incorporar lecciones aprendidas de incidentes de seguridad al ciclo de mejora continua del marco de gobernanza.

Tipo: Gobernanza **Evidencia:** Declarativo **Fuente:** Proyecto Ley IA

3.7 Distribución de controles

El marco define 62 controles con identificador único (C01 a C62). Dado que un control puede proteger activos correspondientes a más de una subdimensión, un mismo identificador aparece en cada una de las subdimensiones donde su función protectora es aplicable. El control C16 (proxy de seguridad), por ejemplo, opera simultáneamente sobre la entrada, el contexto recuperado y la salida, por lo que se lista en D1, D2 y D3.

La Tabla 3.7 contabiliza aplicaciones de control por subdimensión y nivel de madurez, no controles únicos. La suma total es por tanto superior a 62: los 62 controles únicos generan 70

aplicaciones, diferencia que corresponde a los siete controles transversales del marco (C06, C13, C15, C16, C17, C21 y C30).

Distribución de controles: subdimensión × nivel

Subdim.	N1	N2	N3	N4	N5	Aplicaciones
D1	8	3	2	2	2	17
D2	8	6	2	2	2	20
D3	1	3	1	2	2	9
D4	0	3	3	1	2	9
D5	4	3	4	2	2	15
Total	**21**	**18**	**12**	**9**	**10**	**70**

Capítulo 4

Perfiles organizacionales

Los perfiles organizacionales orientan la interpretación del nivel de madurez asignado según el tipo de organización. No modifican los criterios de asignación ni la definición de los niveles; únicamente establecen el nivel mínimo recomendado y el nivel objetivo según las obligaciones regulatorias aplicables. El nivel mínimo recomendado corresponde al nivel verificado, por constituir un umbral de seguridad técnica demostrable mediante evidencia experimental o de configuración. El nivel objetivo corresponde al nivel declarado, incorporando los controles de gobernanza de D5 cuya verificación es declarativa y representa la madurez organizacional completa que la organización debería aspirar a alcanzar.

Los controles prioritarios listados en cada perfil se ordenan según tres criterios aplicados en cascada. El primero es la fuente de evidencia: los controles con fuente de evidencia **Configuración** se priorizan sobre los de tipo **Experimental** y **Declarativo**, dado que su implementación requiere únicamente parametrización de componentes existentes sin desarrollo adicional. El segundo es el costo estimado de implementación: dentro de una misma fuente de evidencia, los controles de costo Bajo preceden a los de costo Medio y Alto. El tercero es el nivel de madurez: ante igual fuente y costo, los controles de niveles inferiores preceden a los de niveles superiores, respetando la progresión acumulativa obligatoria del modelo. El costo estimado es relativo al contexto de cada perfil y se define en la nota informativa de cada tabla.

Resumen de perfiles

Perfil	Tipo	Nivel mínimo	Nivel objetivo	Descripción
P1	PYME	N2	N3	Organizaciones pequeñas y medianas
P2	Mediana/Grande	N3	N4	Organizaciones con infraestructura formal
P3	Crítica regulada	N4	N5	Infraestructura crítica, sector regulado

4.1 P1: PYME

El perfil P1 está diseñado para pequeñas y medianas empresas que despliegan sistemas RAG con recursos limitados de ciberseguridad. El nivel mínimo recomendado es N2 y el nivel objetivo es N3.

Los perfiles del marco LLM-Sec clasifican a las organizaciones según su capacidad de seguridad, no según su categoría legal. La Ley 21.663 no establece un régimen específico para este perfil, de modo que una organización bajo P1 queda por lo general fuera de sus obligaciones reforzadas. Esto no la exime de la Ley 21.719 sobre protección de datos personales, cuyas obligaciones aplican con independencia del tamaño de la organización.

4.1.1 Trayectoria recomendada

1. **N1 (Inicial):** Implementar los controles preventivos básicos de D1 y D2. Desplegar un prompt del sistema con instrucciones de seguridad. Activar la capa defensiva con configuración por defecto.
2. **N2 (Reactivo):** Configurar umbrales de detección y habilitar logging básico (D4). Establecer política de uso aceptable (D5).
3. **N3 (Definido):** Documentar formalmente los controles implementados. Calibrar umbrales basándose en resultados de auditoría. Establecer trazabilidad completa por escáner.

4.1.2 Controles prioritarios

El perfil P1 debe priorizar los controles de N1 con fuente de evidencia Configuración, dado que su implementación no requiere desarrollo adicional sino parametrización de componentes existentes. La Tabla 4.1 los ordena por subdimensión y costo estimado de implementación.

Cuadro 4.1: Controles prioritarios para el perfil P1 (PYME).

Ctrl	Nivel	Dim.	Costo	Acción requerida
Implementación inmediata (configuración, sin desarrollo)				
C15	N1	D1, D2	Bajo	Redactar prompt del sistema con restricciones de rol.
C01	N1	D1	Bajo	Configurar límite de longitud del prompt.
C06	N1	D1, D2	Bajo	Agregar delimitadores al contexto inyectado.
C10	N1	D2	Bajo	Limitar fragmentos recuperados por consulta.
C13	N1	D1, D2	Bajo	Limitar volumen total de contexto por sesión.
C07	N1	D2	Bajo	Restringir fuentes a documentos autorizados.
C21	N1	D1, D2	Bajo	Variables de entorno para credenciales.
C16	N1	D1, D2, D3	Medio	Desplegar proxy de seguridad (ej. LLM Guard).
Fase siguiente (requiere proxy activo, niveles N2–N3)				
C02	N1	D1	Medio	Activar sanitización de entrada en el proxy.
C08	N2	D2	Medio	Particionar vector store por sensibilidad.
C18	N2	D3	Medio	Activar sanitización de salida en el proxy.
C19	N2	D3	Medio	Activar detección de contenido confidencial.
C26	N2	D4	Bajo	Documentar política de umbrales.
C23	N3	D4	Medio	Habilitar logging de decisiones de bloqueo.
C31	N3	D1	Medio	Registrar prompts rechazados con motivo.

El costo estimado es relativo al contexto PYME. **Bajo** indica parametrización sin componentes adicionales. **Medio** indica despliegue o configuración de un componente nuevo (proxy, particiones). Los controles de D5 (gobernanza) aplican transversalmente a todos

los perfiles y se listan en la sección 3.6.

4.2 P2: Mediana/Grande

El perfil P2 aplica a organizaciones medianas y grandes con infraestructura formal de seguridad de la información. El nivel mínimo recomendado es N3 y el nivel objetivo es N4.

Una organización bajo este perfil puede quedar comprendida entre los prestadores de servicios esenciales que define el artículo 4 de la Ley 21.663, según el sector económico en que opere. La pertenencia a la categoría no depende del tamaño de la organización sino de la actividad que desarrolla, por lo que el evaluador debe verificar la aplicabilidad sectorial antes de asumir el régimen de obligaciones correspondiente.

4.2.1 Trayectoria recomendada

1. **N3 (Definido):** Controles documentados y aplicados consistentemente. Auditoría ofensiva periódica. Matriz RACI asignada.

2. **N4 (Gestionado):** Métricas de desempeño definidas (TFA, LAS). Controles ajustados según resultados cuantitativos. Monitoreo de patrones de consulta anómalos.

4.2.2 Controles prioritarios

El perfil P2 parte de N3 como nivel mínimo y apunta a N4. Los controles prioritarios se concentran en la trazabilidad, la auditoría formal y el inicio de la gestión cuantitativa. Se asume que los controles de N1 y N2 ya están implementados, conforme a la progresión acumulativa del modelo.

Cuadro 4.2: Controles prioritarios para el perfil P2 (Mediana/Grande).

Ctrl	Nivel	Dim.	Costo	Acción requerida
Tránsito a N3 (trazabilidad y auditoría formal)				
C23	N3	D4	Medio	Habilitar logging de decisiones de bloqueo con vector e identificador.
C25	N3	D4	Medio	Registrar y analizar latencia del flujo de inferencia.
C31	N3	D1	Medio	Registrar prompts rechazados con motivo del rechazo.
C32	N3	D1	Bajo	Validar integridad del prompt del sistema entre sesiones.
C12	N3	D2	Alto	Detectar consultas de reconocimiento sistemático del corpus.
C20	N3	D3	Medio	Validar que la salida no reproduzca literalmente fragmentos sensibles.
C62	N3	D2	Medio	Mantener registro versionado del corpus indexado.
C29	N3	D4	Medio	Documentar y ejecutar plan de pruebas ofensivas por despliegue.
C53	N3	D5	Medio	Establecer programa de capacitación en seguridad LLM.
C54	N3	D5	Bajo	Definir ciclo de revisión periódica del marco.
C55	N3	D5	Bajo	Documentar y comunicar riesgos residuales a la dirección.
C60	N3	D5	Medio	Realizar evaluación formal de riesgos del sistema RAG.
Nivel objetivo N4 (gestión cuantitativa)				
C33	N4	D1	Alto	Ajustar umbrales de detección según tasas de falsos positivos.
C34	N4	D1	Medio	Medir y reportar tasa de prompts rechazados por categoría.
C24	N4	D4	Alto	Monitorear patrones de consulta anómalos.
C37	N4	D2	Medio	Medir tasa de recuperación de fragmentos sensibles ante consultas de prueba.
C38	N4	D2	Alto	Ajustar parámetros de retrieval según métricas de exposición.
C41	N4	D3	Alto	Ajustar umbrales de sanitización según falsos positivos en salida.
C42	N4	D3	Medio	Medir tasa de supresión de fragmentos confidenciales por tipo de ataque.
C56	N4	D5	Medio	Establecer métricas de desempeño de la gobernanza de seguridad.
C57	N4	D5	Medio	Clasificar el sistema RAG según nivel de criticidad.

El costo estimado es relativo al contexto de una organización mediana o grande con equipo de seguridad dedicado. **Bajo** indica documentación o parametrización. **Medio** indica configuración de componentes existentes o desarrollo de procedimientos. **Alto** indica desarrollo, integración de componentes nuevos o capacidad analítica especializada.

4.3 P3: Crítica regulada

El perfil P3 aplica a organizaciones que operan infraestructura crítica o pertenecen a sectores regulados, donde las obligaciones de la Ley 21.663 y la Ley 21.719 imponen requisitos formales de ciberseguridad y protección de datos. El nivel mínimo recomendado es N4 y el nivel objetivo es N5.

4.3.1 Trayectoria recomendada

1. **N4 (Gestionado):** Gestión cuantitativa de la seguridad. Proceso formal de gestión de riesgos de IA con clasificación por criticidad. Reportes periódicos a dirección.

2. **N5 (Optimizado):** Mejora continua integrada. Marco revisado ante cambios normativos o nuevas amenazas. Lecciones aprendidas incorporadas al ciclo de gobernanza.

4.3.2 Obligaciones regulatorias aplicables

Las organizaciones bajo el perfil P3 deben considerar especialmente:

- **Ley 21.663:** obligaciones de notificación de incidentes, designación de responsable de seguridad, inventario de activos de información.
- **Ley 21.719:** obligaciones del responsable de tratamiento, inventario de datos personales procesados por el sistema RAG.
- **Proyecto de Ley de IA:** clasificación del sistema según nivel de criticidad, métricas de desempeño de gobernanza.

4.3.3 Controles prioritarios

El perfil P3 parte de N4 como nivel mínimo y apunta a N5. Los controles prioritarios enfatizan la gestión cuantitativa, la mejora continua y el cumplimiento normativo de la Ley 21.663, la Ley 21.719 y el Proyecto de Ley de IA. Se asume que los controles de N1 a N3 ya están implementados y que la organización cuenta con los recursos para sostener un ciclo de mejora continua.

Cuadro 4.3: Controles prioritarios para el perfil P3 (Crítica regulada).

Ctrl	Nivel	Dim.	Costo	Acción requerida
Tránsito a N4 (gestión cuantitativa y cumplimiento normativo)				
C33	N4	D1	Alto	Ajuste dinámico de umbrales según tasas de falsos positivos.
C34	N4	D1	Medio	Reporte periódico de tasa de rechazo por categoría de ataque.
C24	N4	D4	Alto	Monitoreo de patrones de consulta anómalos.
C37	N4	D2	Medio	Medición periódica de tasa de recuperación de fragmentos sensibles.
C38	N4	D2	Alto	Ajuste de parámetros de retrieval según métricas de exposición.
C41	N4	D3	Alto	Ajuste dinámico de umbrales de sanitización de salida.
C42	N4	D3	Medio	Reporte de tasa de supresión de fragmentos confidenciales.
C56	N4	D5	Medio	Métricas de desempeño de gobernanza reportadas a la dirección.
C57	N4	D5	Medio	Clasificación formal del sistema según nivel de criticidad.
Nivel objetivo N5 (mejora continua y actualización proactiva)				
C35	N5	D1	Alto	Actualizar patrones de detección ante nuevas técnicas de inyección.
C36	N5	D1	Alto	Revisar prompt del sistema ante cambios en el modelo base.
C39	N5	D2	Alto	Actualizar particionamiento ante cambios de clasificación del corpus.
C40	N5	D2	Alto	Revisión proactiva de fragmentos ante nuevas amenazas de exfiltración.
C43	N5	D3	Alto	Actualizar patrones de detección de contenido sensible en salida.
C44	N5	D3	Alto	Incorporar retroalimentación de incidentes a patrones de sanitización.
C45	N5	D4	Alto	Actualizar patrones de detección de anomalías ante nuevas amenazas.
C46	N5	D4	Alto	Incorporar retroalimentación de incidentes al sistema de alertas.
C58	N5	D5	Medio	Actualización proactiva del marco ante cambios normativos.
C59	N5	D5	Medio	Incorporar lecciones aprendidas al ciclo de mejora continua.

El costo estimado es relativo al contexto de infraestructura crítica con obligaciones regulatorias formales. **Bajo** indica documentación. **Medio** indica procedimientos o configuración. **Alto** indica capacidad analítica especializada, desarrollo de componentes o procesos de mejora continua que requieren personal dedicado. Las organizaciones bajo este perfil deben considerar especialmente los controles anclados a la Ley 21.663 (notificación de incidentes, inventario de activos), la Ley 21.719 (inventario de datos personales, gestión de accesos) y el Proyecto de Ley de IA (clasificación por criticidad, métricas de gobernanza).

Capítulo 5

Métricas de evaluación

El marco LLM-Sec define cuatro métricas complementarias para cuantificar la postura de ciberseguridad de un sistema RAG. Ninguna métrica individual captura simultáneamente las tres dimensiones relevantes de la evaluación: efectividad defensiva ante ataques reales, costo operacional introducido por los controles, y coherencia entre el nivel de madurez asignado y la resistencia técnica observada. Las cuatro métricas operan en conjunto para cubrir estas dimensiones de forma complementaria.

TFA — Tasa de Filtrado de Ataques: mide la efectividad defensiva.
LAS — Latencia Agregada de Seguridad: mide el costo operacional.
PCC — Porcentaje de Controles Cumplidos: mide la coherencia interna.
NCP — Nivel de Consistencia de Protección: verifica la consistencia de la mejora defensiva entre vectores de ataque.

Las tres primeras métricas son calculables por escenario de forma independiente. La cuarta requiere los resultados de al menos dos configuraciones de seguridad distintas para establecer la correlación entre nivel de madurez y resistencia observada.

5.1 Tasa de Filtrado de Ataques (TFA)

La Tasa de Filtrado de Ataques cuantifica la proporción de intentos adversariales que el sistema resistió exitosamente, ya sea por acción de la capa defensiva o por resistencia intrínseca del modelo. Su fórmula es:

$$\text{TFA} = \frac{TP}{TP + FN}$$

donde TP corresponde a los ataques bloqueados correctamente y FN a los ataques que alcanzaron el modelo sin ser interceptados.

El diferencial $\Delta\text{TFA} = \text{TFA}_B - \text{TFA}_A$ constituye la medida del efecto neto de la capa defensiva: TFA_A establece la línea base de resistencia del sistema sin protección activa, mientras que TFA_B incorpora el efecto de los controles implementados.

5.1.1 Fuentes de *ground truth* por vector

Dado que las herramientas de auditoría ofensiva genéricas no tienen acceso al corpus indexado ni al prompt del sistema, el marco define fuentes de *ground truth* diferenciadas por vector OWASP. Los criterios de la Tabla 5.1 caracterizan el ataque exitoso, es decir, el falso negativo del sistema defensivo. Un intento adversarial se contabiliza como bloqueado (TP) cuando el criterio correspondiente a su vector no se cumple. El evaluador debe implementar estos criterios como columnas del registro de resultados.

Cuadro 5.1: Criterio de *ground truth* por vector OWASP para el cálculo de TFA.

Vector	Criterio de verificación
LLM01	El sistema reprodujo una instrucción adversarial inyectada en el prompt, verificado mediante detección de la cadena objetivo en la respuesta generada.
LLM02	La respuesta contiene información sensible proveniente del corpus indexado, verificada mediante detección de marcadores de confidencialidad o patrones de PII estructurada en la salida.
LLM07	La respuesta revela contenido del prompt del sistema, verificado mediante detección de frases literales o estructuras propias de las instrucciones de sistema configuradas.
LLM08	El modelo obedeció una instrucción inyectada en el corpus recuperado **y** alteró el contenido de su respuesta como consecuencia. Ambas condiciones deben verificarse conjuntamente: la reproducción del contenido inyectado sin alteración del comportamiento no constituye compromiso efectivo del sistema.

5.1.2 Prueba estadística

Para determinar si la diferencia entre escenarios es estadísticamente significativa, el marco prescribe la prueba exacta de Fisher como prueba principal, por ser robusta ante frecuencias esperadas bajas en la tabla de contingencia. Como prueba alternativa se declara el Z-test de proporciones, aplicable cuando el tamaño muestral por vector es suficientemente grande. La métrica se reporta desglosada por vector para verificar si el efecto defensivo es homogéneo entre subdimensiones.

5.1.3 Tasa de falsos positivos

El evaluador debe reportar adicionalmente la tasa de falsos positivos $\frac{FP}{FP+TN}$, calculada sobre un conjunto de consultas legítimas de control ejecutadas bajo las mismas condiciones experimentales. Esta medida caracteriza el comportamiento de la capa defensiva ante uso normal del sistema y permite detectar configuraciones que afecten la usabilidad.

5.1.4 Correspondencia con ISO/IEC 25010:2023

Característica	Subcategorías
Security (§3.6)	Confidentiality (§3.6.1) Integrity (§3.6.2) Resistance (§3.6.6)

* Los nombres de característica y subcategoría se citan en inglés por no existir traducción oficial de ISO/IEC 25010:2023 al español.

5.2 Latencia Agregada de Seguridad (LAS)

La Latencia Agregada de Seguridad cuantifica la sobrecarga temporal introducida por la capa defensiva en el flujo de inferencia. Su fórmula es:

$$\text{LAS} = \tilde{x}_B - \tilde{x}_A$$

donde $\tilde{x}$ denota la mediana de las mediciones de latencia registradas en cada escenario. Se emplea la mediana en lugar de la media aritmética porque la distribución de latencia en sistemas de inferencia no sigue normalidad: los valores atípicos introducidos por colas de procesamiento y variabilidad de hardware distorsionan la media sin afectar la mediana.

5.2.1 Prueba estadística

La prueba estadística prescrita es Mann-Whitney U, prueba no paramétrica que opera sobre rangos y no asume ninguna distribución subyacente. El evaluador debe reportar adicionalmente el rango intercuartílico (IQR) de cada escenario para caracterizar la variabilidad de las mediciones. La LAS debe calcularse de forma segmentada entre prompts adversariales y prompts legítimos, dado que la capa defensiva introduce asimetrías operacionales entre ambos tipos de consulta.

5.2.2 Correspondencia con ISO/IEC 25010:2023

Característica	Subcategorías
Performance Efficiency (§3.2)	Time behaviour (§3.2.1) Resource utilization (§3.2.2)

5.3 Porcentaje de Controles Cumplidos (PCC)

El Porcentaje de Controles Cumplidos cuantifica la proporción de controles implementados sobre un universo de controles que el evaluador define. Su fórmula es:

$$\text{PCC}(U) = \frac{|C_{\text{implementados}} \cap U|}{|U|} \times 100$$

donde U denota el universo de controles bajo análisis y $C_{\text{implementados}}$ el conjunto de controles cuyo cumplimiento fue constatado conforme a los criterios de verificación de la sección 6.2.

PCC es una métrica paramétrica: el universo U no está fijado por el marco sino que constituye una decisión del evaluador, determinada por la pregunta que la evaluación busca responder. Un mismo sistema admite tantos valores de PCC como universos se declaren, y todos son igualmente válidos. La condición de interpretabilidad es que el universo se declare explícitamente junto al valor reportado: un PCC sin universo especificado no es interpretable ni comparable.

5.3.1 Definición del universo

El universo se construye acotando el conjunto de los 62 controles del marco mediante uno o más de los siguientes criterios, aplicables de forma combinada:

- **Nivel de madurez:** los controles definidos hasta un nivel determinado, sea el nivel alcanzado por el sistema o el nivel objetivo al que la organización aspira.
- **Subdimensión:** los controles de una o varias subdimensiones, para identificar qué área del modelo presenta menor cobertura.
- **Fuente de evidencia:** los controles verificables técnicamente, o bien los declarativos, según se busque medir cobertura técnica o cobertura organizacional.
- **Tipo funcional:** los controles preventivos, detectivos, correctivos o de gobernanza, para detectar sesgos en la estrategia de implementación.
- **Perfil organizacional:** los controles prioritarios del perfil aplicable (capítulo 4), para medir avance respecto de la trayectoria recomendada.

La elección del universo determina qué significa el valor obtenido. Un PCC calculado sobre los controles verificables hasta el nivel alcanzado mide la coherencia entre el nivel asignado y los controles efectivamente operativos. Uno calculado sobre los controles hasta el nivel objetivo del perfil mide la distancia que resta por cubrir. Uno calculado sobre la totalidad de los 62 controles mide la cobertura absoluta del marco, valor que solo alcanza el 100 % en un sistema de nivel N5 con todos sus controles de gobernanza implementados.

PCC opera como validador de coherencia interna: un nivel de madurez alto acompañado de un PCC bajo sobre los controles de ese mismo nivel señala una discrepancia entre el nivel asignado y los controles realmente operativos, lo que indica una sobreestimación del nivel. Al ser una proporción descriptiva, no requiere prueba estadística de contraste.

5.3.2 Correspondencia con ISO/IEC 25010:2023

Característica	Subcategorías
Security (§3.6)	Cobertura interna de controles implementados
Maintainability (§3.7)	Analysability (§3.7.3) Testability (§3.7.5)

5.4 Nivel de Consistencia de Protección (NCP)

El Nivel de Consistencia de Protección verifica si el incremento en el nivel de madurez verificado se asocia a una mejora defensiva no negativa en todas las suites de ataque evaluadas. Su fórmula es:

$$\text{NCP} = \frac{S_{\Delta \geq 0}}{S_{\text{total}}}$$

donde $S_{\Delta \geq 0}$ corresponde al número de suites de ataque en que $\Delta\text{TFA} \geq 0$ (definido en la sección 5.1), y S_{total} al total de suites evaluadas. Cada suite agrupa las pruebas adversariales correspondientes a un vector OWASP, de modo que S_{total} equivale al número de vectores cubiertos por la evaluación.

NCP es de carácter descriptivo: no contrasta una hipótesis estadística sino que verifica si la mejora defensiva asociada al nivel asignado es consistente entre vectores de ataque. Un NCP = 1,0 indica que el incremento de nivel se asocia a mejora no negativa en todas las suites evaluadas; valores inferiores señalan suites en que el nivel asignado no se tradujo en mejora observable, lo que requiere análisis de causas antes de reportar el nivel.

5.4.1 Criterios de validez

El marco considera que los resultados son coherentes con el modelo de madurez si se cumplen conjuntamente las siguientes condiciones:

1. La mejora en TFA entre el escenario sin protección y el escenario protegido es estadísticamente significativa ($p < 0{,}05$).
2. El PCC calculado sobre los controles verificables definidos hasta el nivel alcanzado en cada subdimensión es $\geq 90\,\%$.
3. NCP = 1,0, es decir, el incremento de nivel se asocia a mejora no negativa en la totalidad de las suites evaluadas.

El incumplimiento de cualquiera de estas condiciones no invalida el marco, pero requiere que el evaluador documente la discrepancia y analice sus causas antes de reportar el nivel asignado.

5.4.2 Correspondencia con ISO/IEC 25010:2023

Característica	Subcategorías
Functional Suitability (§3.1)	Functional correctness (§3.1.2) Functional appropriateness (§3.1.3)

Capítulo 6

Guía de evaluación

Los capítulos anteriores especifican qué evalúa el marco LLM-Sec: un modelo de madurez de seis niveles, una taxonomía de 62 controles y tres perfiles organizacionales que orientan la interpretación del resultado. Este capítulo especifica cómo se conduce la evaluación. Define el flujo de siete pasos que va desde la selección del perfil hasta el plan de remediación, los criterios que el evaluador aplica para dar por cumplido un control según su fuente de evidencia, la matriz de responsabilidades que la organización debe instanciar para que la evaluación sea auditable, y el ciclo iterativo mediante el cual se cierran las brechas identificadas.

6.1 Flujo de evaluación

El proceso de evaluación del marco LLM-Sec sigue seis pasos secuenciales:

1. **Selección del perfil organizacional:** identificar el perfil (P1, P2 o P3) que corresponde a la organización según su tipo y obligaciones regulatorias.
2. **Evaluación de controles:** verificar cada control de las subdimensiones D1 a D5 utilizando la fuente de evidencia correspondiente (configuración, experimental o declarativa).
3. **Cálculo de métricas:** ejecutar la auditoría ofensiva y calcular TFA, LAS, PCC y NCP conforme al capítulo 5. Estas métricas constituyen la evidencia experimental que sustenta la verificación de los controles del paso anterior.
4. **Asignación de nivel por subdimensión:** el nivel de cada subdimensión es el mayor nivel cuyos controles están completamente implementados, respetando la progresión acumulativa.
5. **Cálculo del nivel global:** aplicar la regla de piso mínimo: $L = \text{mín}(d_1, d_2, d_3, d_4, d_5)$.
6. **Análisis de brechas:** identificar la distancia entre el nivel verificado y el nivel objetivo del perfil seleccionado.
7. **Plan de remediación:** priorizar la implementación de controles faltantes según el nivel objetivo, enfocándose primero en la subdimensión que actúa como piso.

6.2 Criterios de verificación por fuente de evidencia

6.2.1 Configuración

El control se verifica inspeccionando la declaración explícita en los archivos de configuración del sistema. Ejemplos: presencia de umbrales en el archivo YAML de la capa defensiva, instrucciones de seguridad en el prompt del sistema, particionamiento de la base vectorial.

6.2.2 Experimental

El control se verifica mediante la ejecución de pruebas de auditoría ofensiva contra el sistema bajo evaluación. El resultado se expresa como una métrica cuantificable (tasa de filtrado, latencia, cobertura). Las pruebas ejecutadas deben cubrir los vectores OWASP declarados como fuente normativa del control: un control anclado a LLM02:2025 no puede verificarse con pruebas que solo ejerciten inyección de instrucciones.

6.2.3 Declarativo

El control se verifica mediante revisión documental o entrevista. El evaluador solicita evidencia de la existencia de la política, procedimiento o asignación de roles descrita por el control.

6.3 Matriz RACI

El marco define roles genéricos que cada organización debe mapear a personas o cargos concretos. La matriz RACI establece las responsabilidades para las actividades principales del ciclo de evaluación.

La gestión efectiva de la seguridad de un sistema RAG requiere que cada actividad tenga un responsable claramente definido. Siguiendo el modelo de COBIT 4.1, el marco LLM-Sec provee una matriz RACI como artefacto central de gobernanza, que define los roles genéricos involucrados en la operación del sistema junto con su nivel de participación en cada actividad.

Los roles definidos son genéricos por diseño: no corresponden a personas específicas sino a funciones organizacionales. Cada organización debe instanciar la matriz asignando cada rol a los cargos o personas concretas de su estructura, conforme al control C50. Esta instanciación es condición necesaria para que los controles de D5 sean auditables.

La Tabla 6.1 presenta las actividades principales del marco y la asignación de roles según los criterios R (Responsable), A (*Accountable*), C (Consultado) e I (Informado).

Cuadro 6.1: Matriz RACI del marco LLM-Sec.

Actividad	Resp. Seguridad	Operador Técnico	Prop. Corpus	Dirección	Cumplimiento
Designar responsable de seguridad del sistema RAG	A	I	I	R	C
Declarar el sistema RAG como activo de información	R	C	C	A	I
Mantener inventario de activos actualizado	R	C	C	I	A
Gestionar accesos al sistema	R	A	C	I	C
Aplicar lista de chequeo LLM-Sec	R	A	C	I	C
Revisar y actualizar el marco periódicamente	R	C	C	A	C
Notificar incidentes de seguridad	R	C	I	A	C
Ejecutar plan de pruebas ofensivas	A	R	I	I	C
Capacitar a los roles en seguridad LLM	R	C	C	A	C
Reportar métricas de gobernanza a la dirección	R	C	I	A	C

R = Responsable (ejecuta) • **A** = *Accountable* (rinde cuentas) • **C** = Consultado • **I** = Informado

6.4 Ciclo de mejora

Ante brechas identificadas entre el nivel verificado y el nivel objetivo, el evaluador debe:

1. Identificar la subdimensión que actúa como piso mínimo.
2. Priorizar los controles faltantes de esa subdimensión en el nivel inmediatamente superior.
3. Implementar los controles priorizados.
4. Re-ejecutar la auditoría ofensiva y recalcular las métricas del capítulo 5: la TFA verifica que la implementación produjo mejora defensiva efectiva, la LAS caracteriza el costo operacional introducido, el PCC confirma la cobertura de controles alcanzada y el NCP verifica que la mejora es consistente entre vectores de ataque.
5. Re-ejecutar la evaluación para verificar el tránsito de nivel.

Este ciclo es iterativo y se repite hasta alcanzar el nivel objetivo del perfil organizacional o hasta que los riesgos residuales sean formalmente aceptados y documentados por la dirección.

Apéndice A

Resumen de controles por nivel

Este apéndice presenta el catálogo completo de controles del marco LLM-Sec organizados por subdimensión. Cada entrada incluye el identificador del control, su nivel de madurez, tipo funcional, fuente de evidencia y una descripción abreviada.

Los controles transversales (aquellos que aparecen en más de una subdimensión) se listan en cada subdimensión donde aplican, reflejando su función protectora múltiple.

D1: Protección de entrada

ID	Nivel	Tipo	Evidencia	Descripción
C01	N1	Preventivo	Configuración	Limitar longitud máxima del prompt de entrada
C02	N1	Preventivo	Experimental	Sanitizar el prompt eliminando caracteres y patrones de control
C06	N1	Preventivo	Configuración	Segregar contenido externo en el prompt mediante delimitadores
C13	N1	Preventivo	Configuración	Limitar el volumen total de contexto inyectado por sesión
C15	N1	Preventivo	Configuración	Restringir rol, capacidades y limitaciones del modelo en el prompt del sistema
C16	N1	Preventivo	Configuración	Interponer un proxy de seguridad externo e independiente del LLM
C21	N1	Preventivo	Configuración	Restringir credenciales y tokens de API al entorno de código
C30	N1	Gobernanza	Declarativo	Verificar procedencia e integridad del modelo mediante *checksums*
C03	N2	Detectivo	Experimental	Detectar patrones sintácticos de inyección en el prompt
C04	N2	Preventivo	Experimental	Validar la relevancia semántica del prompt respecto al dominio autorizado
C05	N2	Preventivo	Experimental	Ocultar el contenido del prompt del sistema al usuario

Continúa en la página siguiente…

ID	Nivel	Tipo	Evidencia	Descripción
C31	N3	Detectivo	Experimental	Registrar y auditar todos los prompts rechazados con motivo del rechazo
C32	N3	Preventivo	Configuración	Validar que el prompt del sistema no ha sido modificado entre sesiones
C33	N4	Preventivo	Declarativo	Ajustar dinámicamente umbrales de detección según tasas de falsos positivos
C34	N4	Detectivo	Declarativo	Medir y reportar periódicamente la tasa de prompts rechazados por categoría
C35	N5	Preventivo	Declarativo	Actualizar patrones de detección ante nuevas técnicas de inyección
C36	N5	Preventivo	Declarativo	Revisar y ajustar el prompt del sistema ante cambios en el modelo base

D2: Control de contexto RAG

ID	Nivel	Tipo	Evidencia	Descripción
C06	N1	Preventivo	Configuración	Segregar contenido externo en el prompt mediante delimitadores
C07	N1	Preventivo	Configuración	Restringir fuentes de información a documentos autorizados y verificados
C10	N1	Preventivo	Configuración	Controlar la cantidad de fragmentos recuperados por consulta
C13	N1	Preventivo	Configuración	Limitar el volumen total de contexto inyectado por sesión
C15	N1	Preventivo	Configuración	Restringir rol, capacidades y limitaciones del modelo en el prompt del sistema
C16	N1	Preventivo	Configuración	Interponer un proxy de seguridad externo e independiente del LLM
C21	N1	Preventivo	Configuración	Restringir credenciales y tokens de API al entorno de código
C30	N1	Gobernanza	Declarativo	Verificar procedencia e integridad del modelo mediante *checksums*
C08	N2	Preventivo	Configuración	Particionar el *vector store* por nivel de sensibilidad
C09	N2	Prev./Det.	Experimental	Validar integridad del corpus y fragmentos antes de inyectarlos al contexto
C11	N2	Preventivo	Experimental	Validar semánticamente la *query* al *vector store* antes del *retrieval*
C14	N2	Correctivo	Experimental	Suprimir o redactar metadatos de documentos en las respuestas

Continúa en la página siguiente…

ID	Nivel	Tipo	Evidencia	Descripción
C17	N2	Prev./Det.	Experimental	Restringir respuestas a información fundamentada en el contexto recuperado
C22	N2	Prev./Det.	Declarativo	Controlar y auditar el acceso por sesión a documentos del *vector store*
C12	N3	Detectivo	Experimental	Detectar consultas al *vector store* para reconocimiento sistemático
C62	N3	Detectivo	Configuración	Mantener registro versionado del corpus indexado
C37	N4	Detectivo	Declarativo	Medir la tasa de recuperación de fragmentos sensibles ante consultas de prueba
C38	N4	Preventivo	Declarativo	Ajustar parámetros de *retrieval* según métricas de exposición
C39	N5	Preventivo	Declarativo	Actualizar particionamiento ante cambios en clasificación de sensibilidad
C40	N5	Preventivo	Declarativo	Revisar fragmentos indexados ante nuevas amenazas de exfiltración

D3: Gestión de salida

ID	Nivel	Tipo	Evidencia	Descripción
C16	N1	Preventivo	Configuración	Interponer un proxy de seguridad externo e independiente del LLM
C14	N2	Correctivo	Experimental	Suprimir o redactar metadatos de documentos en las respuestas
C17	N2	Prev./Det.	Experimental	Restringir respuestas a información fundamentada en el contexto recuperado
C18	N2	Correctivo	Experimental	Sanitizar la salida eliminando contenido con patrones sintácticos sensibles
C19	N2	Det./Corr.	Experimental	Detectar y suprimir fragmentos marcados como confidenciales
C20	N3	Detectivo	Experimental	Validar que la salida no reproduzca literalmente fragmentos del corpus sensible
C41	N4	Detectivo	Declarativo	Ajustar umbrales de sanitización según métricas de falsos positivos
C42	N4	Detectivo	Declarativo	Medir la tasa de supresión de fragmentos confidenciales por tipo de ataque
C43	N5	Detectivo	Declarativo	Actualizar patrones de detección de contenido sensible ante nuevas técnicas

Continúa en la página siguiente…

ID	Nivel	Tipo	Evidencia	Descripción
C44	N5	Detectivo	Declarativo	Incorporar retroalimentación de incidentes al conjunto de patrones

D4: Monitoreo y trazabilidad

ID	Nivel	Tipo	Evidencia	Descripción
C26	N2	Gobernanza	Declarativo	Definir política de umbrales de detección y bloqueo previo a la operación
C27	N2	Gobernanza	Declarativo	Establecer procedimiento de notificación de seguridad ante autoridades
C28	N2	Gobernanza	Declarativo	Definir política de retención y eliminación de datos de sesión
C23	N3	Detectivo	Experimental	Registrar cada decisión de bloqueo con identificación del mecanismo y vector
C25	N3	Detectivo	Experimental	Registrar y analizar la latencia del flujo de inferencia
C29	N3	Gobernanza	Declarativo	Documentar y ejecutar plan de pruebas ofensivas previo a cada despliegue
C24	N4	Detectivo	Experimental	Monitorear patrones de consulta anómalos
C45	N5	Detectivo	Declarativo	Actualizar patrones de detección de anomalías ante nuevas amenazas
C46	N5	Correctivo	Declarativo	Incorporar retroalimentación de incidentes al sistema de alertas

D5: Gobernanza organizacional

ID	Nivel	Tipo	Evidencia	Descripción
C47	N1	Gobernanza	Declarativo	Designar responsable de seguridad del sistema RAG
C48	N1	Gobernanza	Declarativo	Declarar el sistema RAG como activo de información
C49	N1	Gobernanza	Declarativo	Establecer política de uso aceptable del sistema RAG
C61	N1	Gobernanza	Declarativo	Mantener inventario actualizado de activos del sistema RAG
C50	N2	Gobernanza	Declarativo	Adoptar y adaptar la matriz RACI del marco LLM-Sec

Continúa en la página siguiente…

ID	Nivel	Tipo	Evidencia	Descripción
C51	N2	Gobernanza	Declarativo	Establecer procedimiento de gestión de accesos
C52	N2	Gobernanza	Declarativo	Documentar inventario de datos personales procesados
C53	N3	Gobernanza	Declarativo	Establecer programa de capacitación en seguridad de sistemas LLM
C54	N3	Gobernanza	Declarativo	Definir ciclo de revisión periódica del marco con frecuencia mínima anual
C55	N3	Gobernanza	Declarativo	Documentar y comunicar riesgos residuales a la dirección
C60	N3	Gobernanza	Declarativo	Realizar evaluación formal de riesgos con frecuencia mínima anual
C56	N4	Gobernanza	Declarativo	Establecer métricas de desempeño de la gobernanza y reportarlas
C57	N4	Gobernanza	Declarativo	Implementar proceso de gestión de riesgos de IA
C58	N5	Gobernanza	Declarativo	Revisar proactivamente el marco ante cambios normativos o del modelo
C59	N5	Gobernanza	Declarativo	Incorporar lecciones aprendidas de incidentes al ciclo de mejora

Apéndice B

Mapeo normativo

Este apéndice presenta la trazabilidad entre cada control del marco LLM-Sec y sus fuentes normativas de origen. La columna OWASP indica la entrada específica del OWASP LLM Top 10:2025; las columnas restantes indican la norma o legislación aplicable.

Los controles transversales aparecen una sola vez, con todas sus fuentes consolidadas.

Leyenda: ✓ indica aplicabilidad directa de la fuente normativa al control.

ID	Descripción	OWASP	ISO 27002	Ley 21.663	Ley 21.719	NIST AI RMF
D1: Protección de entrada						
C01	Limitar longitud máxima del prompt	LLM01	✓			
C02	Sanitizar prompt de entrada	LLM01	✓			
C03	Detectar patrones de inyección	LLM01	✓			
C04	Validar relevancia semántica del prompt	LLM01	✓			
C05	Ocultar prompt del sistema	LLM01, 07	✓			
C06	Segregar contenido externo con delimitadores	LLM01, 02	✓			
C13	Limitar volumen de contexto por sesión	LLM01, 02	✓			
C15	Restringir rol del modelo en prompt del sistema	LLM01, 02	✓			
C16	Interponer proxy de seguridad externo	LLM01, 02	✓			
C21	Restringir credenciales al entorno de código	LLM01, 02	✓			
C30	Verificar procedencia del modelo	LLM08	✓	✓		
C31	Auditar prompts rechazados	LLM01	✓	✓		
C32	Validar integridad del prompt del sistema	LLM01, 07	✓			
C33	Ajustar umbrales de detección dinámicamente	LLM01	✓			

Continúa en la página siguiente…

ID	Descripción	OWASP	ISO 27002	Ley 21.663	Ley 21.719	NIST AI RMF
C34	Reportar tasa de rechazo por categoría	LLM01	✓	✓		
C35	Actualizar patrones ante nuevas técnicas	LLM01	✓			
C36	Revisar prompt ante cambios del modelo	LLM01	✓			
D2: Control de contexto RAG						
C07	Restringir fuentes a documentos autorizados	LLM02	✓			
C08	Particionar *vector store* por sensibilidad	LLM02, 08	✓			
C09	Validar integridad de fragmentos recuperados	LLM02, 08	✓			
C10	Controlar cantidad de fragmentos por consulta	LLM02	✓			
C11	Validar semánticamente la *query* al *vector store*	LLM02, 08	✓			
C12	Detectar reconocimiento sistemático del corpus	LLM02, 08	✓			
C14	Suprimir metadatos en respuestas	LLM02	✓		✓	
C17	Restringir respuestas al contexto recuperado	LLM02	✓			
C22	Auditar acceso por sesión a documentos	LLM02	✓		✓	
C37	Medir tasa de recuperación de fragmentos sensibles	LLM02	✓			
C38	Ajustar parámetros de *retrieval*	LLM02	✓			
C39	Actualizar particionamiento ante reclasificación	LLM02, 08	✓			
C40	Revisar fragmentos ante nuevas amenazas	LLM02, 08	✓			
C62	Mantener registro versionado del corpus	LLM02, 08	✓	✓		
D3: Gestión de salida						
C18	Sanitizar salida con patrones sintácticos	LLM02, 07	✓			
C19	Suprimir fragmentos confidenciales en salida	LLM02, 07	✓		✓	
C20	Validar que la salida no reproduzca corpus sensible	LLM02, 07	✓		✓	
C41	Ajustar umbrales de sanitización de salida	LLM02, 07	✓			
C42	Reportar tasa de supresión por tipo de ataque	LLM02, 07	✓	✓		
C43	Actualizar patrones de detección en salida	LLM02, 07	✓			
C44	Incorporar retroalimentación de incidentes a patrones	LLM02, 07	✓			
D4: Monitoreo y trazabilidad						

Continúa en la página siguiente…

ID	Descripción	OWASP	ISO 27002	Ley 21.663	Ley 21.719	NIST AI RMF
C23	Registrar decisiones de bloqueo con mecanismo y vector	LLM01, 02, 07, 08	✓	✓		
C24	Monitorear patrones de consulta anómalos	LLM01, 02, 07, 08	✓			
C25	Registrar y analizar latencia del flujo	LLM01, 02, 07, 08	✓			
C26	Definir política de umbrales previo a operación	—		✓		
C27	Procedimiento de notificación ante autoridades	—		✓		
C28	Política de retención y eliminación de datos	—			✓	
C29	Plan de pruebas ofensivas previo a despliegue	—		✓		
C45	Actualizar patrones de detección de anomalías	LLM01, 02, 07, 08	✓			
C46	Retroalimentación de incidentes al sistema de alertas	LLM01, 02, 07, 08	✓			
D5: Gobernanza organizacional						
C47	Designar responsable de seguridad del sistema RAG	—		✓		
C48	Declarar sistema RAG como activo de información	—		✓		
C49	Política de uso aceptable del sistema RAG	—			✓	
C50	Adoptar matriz RACI del marco LLM-Sec	—		✓		
C51	Procedimiento de gestión de accesos	—			✓	
C52	Inventario de datos personales procesados	—			✓	
C53	Programa de capacitación en seguridad LLM	—				✓
C54	Ciclo de revisión periódica del marco	—				✓
C55	Documentar y comunicar riesgos residuales	—				✓
C56	Métricas de desempeño de gobernanza	—				✓
C57	Proceso de gestión de riesgos de IA	—				✓
C58	Revisión proactiva ante cambios normativos	—				✓
C59	Lecciones aprendidas al ciclo de mejora	—				✓
C60	Evaluación formal de riesgos anual	—				✓
C61	Inventario actualizado de activos RAG	—		✓		

Apéndice C

Fichas técnicas de control

El capítulo 3 define los 62 controles del marco mediante su descripción, nivel de madurez, tipo funcional, fuente de evidencia y fuente normativa. Esa especificación identifica qué exige cada control, pero no por qué lo exige ni cómo debe interpretarse su cumplimiento.

Este apéndice desarrolla la totalidad de los controles del marco. Cada ficha especifica el propósito del control, la justificación técnica o normativa que lo sustenta, la guía de implementación que orienta su adopción y los controles con que se relaciona. La extensión de cada ficha es proporcional a la complejidad del control: aquellos cuya implementación se deduce directamente de su descripción reciben un tratamiento breve, mientras que los que involucran decisiones de diseño, dependencias funcionales o interpretación normativa se desarrollan con mayor detalle.

La guía de implementación es prescriptiva en cuanto al resultado esperado y agnóstica en cuanto a la tecnología empleada: el marco no impone herramientas ni productos específicos, sino que define el comportamiento que la implementación debe satisfacer.

Los siete controles transversales, aplicables a más de una subdimensión, se desarrollan en una sección propia que precede a las restantes. Las secciones siguientes agrupan los controles exclusivos de cada subdimensión, ordenados por nivel de madurez.

C.1 Controles transversales

Los siete controles de esta sección protegen activos correspondientes a más de una subdimensión. Su función protectora opera sobre distintas etapas del flujo RAG, razón por la cual la fuente normativa que se les atribuye varía según la subdimensión en que se apliquen. La ficha desarrolla el control en su integridad, con independencia de la subdimensión desde la que se lo consulte.

C.1.1 C06: Delimitación explícita del contenido recuperado

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM01:2025, LLM02:2025

Propósito

Estructurar el prompt aumentado de modo que el contenido recuperado del corpus y la consulta del usuario ocupen secciones explícitamente delimitadas y distinguibles entre sí.

Justificación

El modelo recibe el prompt aumentado como una única secuencia de texto. Sin delimitación, no dispone de ningún criterio para distinguir qué porción de esa secuencia proviene de sus instrucciones, cuál del corpus y cuál del usuario. Un fragmento del corpus que contenga una instrucción, sea porque fue inyectado deliberadamente o porque el documento original la incluía, se presenta ante el modelo con el mismo estatuto que las instrucciones legítimas del sistema.

La delimitación no impide que el modelo obedezca una instrucción inyectada, dado que opera sobre su interpretación del texto y no sobre un mecanismo de aislamiento. Lo que hace es proveerle el criterio estructural que permite distinguir instrucción de dato, condición previa para que las restricciones del prompt del sistema puedan invocarse contra el contenido recuperado.

Guía de implementación

El prompt debe construirse con marcadores que identifiquen cada sección: el contexto recuperado, la consulta del usuario y, si aplica, las instrucciones del sistema. Los marcadores deben ser consistentes entre invocaciones y estar declarados en la configuración de la plantilla, no dispersos en el código.

Los marcadores elegidos no deben ser reproducibles desde la entrada del usuario. Si el usuario puede escribir el mismo delimitador que el sistema emplea, puede simular el cierre de la sección de datos y la apertura de una sección de instrucciones. El control C02, que elimina caracteres y tokens especiales de la entrada, es la contramedida contra esta evasión.

Controles relacionados

C02 (sanitización de la entrada), que impide la falsificación de los delimitadores; C15 (definición del rol y las restricciones del modelo), cuyas instrucciones invocan la separación que este control establece.

C.1.2 C13: Límite de volumen de contexto inyectado

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM01:2025, LLM02:2025

Propósito

Acotar el volumen total de contenido recuperado que se incorpora al prompt de inferencia, restringiendo la cantidad de fragmentos que la etapa de recuperación entrega al modelo.

Justificación

El contexto recuperado es contenido no confiable: proviene del corpus, cuya integridad el sistema verifica pero no garantiza en origen, y su selección la determina la consulta del usuario. Cada fragmento adicional que ingresa al prompt amplía la superficie disponible para que una instrucción inyectada en el corpus alcance la inferencia, y amplía también el volumen de corpus que una sola consulta puede exponer en la respuesta.

El control opera sobre ambos riesgos con la misma medida. Contener el número de fragmentos limita simultáneamente el vector de inyección indirecta y la tasa a la que un atacante puede extraer contenido del corpus mediante consultas sucesivas.

Guía de implementación

El límite se declara en la configuración de la etapa de recuperación y se aplica antes de la construcción del prompt aumentado. Su valor debe derivarse de la cantidad de fragmentos que las consultas legítimas del dominio requieren para ser respondidas correctamente: un valor excesivamente bajo degrada la calidad de las respuestas sin aportar seguridad proporcional.

Este control es distinto de C01, que acota la entrada del usuario. C13 acota lo que el sistema mismo agrega al prompt, y por tanto opera sobre un canal que el usuario no controla directamente pero sí influye mediante la formulación de su consulta.

Controles relacionados

C01 (límite de longitud de la entrada del usuario), que acota el otro componente del prompt; C10 (control de la cantidad de fragmentos recuperados), con el que comparte el mecanismo de implementación.

C.1.3 C15: Definición del rol y las restricciones del modelo

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM01:2025, LLM02:2025

Propósito

Declarar en el prompt del sistema el rol que el modelo desempeña, el alcance de sus capacidades y las restricciones que gobiernan su comportamiento, mediante instrucciones parametrizadas externamente al código.

Justificación

El prompt del sistema es el único mecanismo por el cual el sistema comunica al modelo qué debe y qué no debe hacer. Un modelo desplegado sin restricciones explícitas opera bajo el alineamiento genérico con que fue entrenado, que no contempla las condiciones del despliegue: qué dominio está autorizado a cubrir, qué información no debe revelar, qué formato debe respetar.

La eficacia de este control es parcial por naturaleza. Las instrucciones del sistema y el contenido adversarial compiten por la misma capacidad de atención del modelo, y una instrucción inyectada suficientemente insistente puede prevalecer sobre ellas. El control no elimina el riesgo de secuestro de comportamiento: establece la línea base contra la cual los controles de salida pueden verificar si la respuesta se apartó de lo autorizado.

Guía de implementación

Las instrucciones deben declararse en configuración y no incrustarse en el código, de modo que su contenido sea verificable por inspección y modificable sin redespliegue. Deben cubrir,

como mínimo, el rol del modelo, el dominio autorizado, la prohibición de generar información no fundamentada en el contexto recuperado y la prohibición de revelar las propias instrucciones.

Las restricciones deben formularse en positivo cuando sea posible. Una instrucción que enumera lo prohibido comunica al atacante el mapa de las defensas si llega a filtrarse, y es evadible mediante formulaciones no contempladas en la enumeración.

Controles relacionados

C05 (no inclusión del prompt del sistema en la respuesta) y C32 (verificación de integridad del prompt del sistema), que protegen el contenido que este control declara; C07 (restricción al uso exclusivo del contexto recuperado), que es una de las instrucciones que este control materializa.

C.1.4 C16: Proxy de seguridad independiente del generador

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM01:2025, LLM02:2025, LLM07:2025

Propósito

Desplegar los controles de seguridad de entrada y salida en un componente independiente del generador, interpuesto en el flujo de inferencia, con capacidad de interrumpir la transacción antes de que alcance el modelo o antes de que la respuesta llegue al usuario.

Justificación

Un control implementado dentro del propio modelo, sea mediante instrucciones del sistema o mediante ajuste fino, depende de la obediencia del modelo para funcionar. Esa obediencia es precisamente lo que el atacante busca subvertir: un modelo comprometido por una inyección exitosa no aplicará las restricciones que él mismo debía hacer cumplir.

La separación arquitectónica rompe esa dependencia. Un componente externo evalúa la entrada y la salida con lógica propia, cuyo comportamiento no es alterable mediante el contenido del prompt. La instrucción adversarial que convence al modelo de revelar el corpus no convence al escáner que inspecciona la respuesta antes de retornarla.

Esta es la razón por la que C16 es el único control de nivel N1 en D3: sin un componente externo interpuesto, la gestión de salida carece de todo mecanismo de intervención, dado que el único agente que produce la salida es el modelo mismo.

Guía de implementación

El componente debe interponerse en la ruta de red entre el cliente y el generador, de modo que ninguna solicitud pueda alcanzar el modelo sin atravesarlo. Una implementación en la que el generador invoque al componente de seguridad como biblioteca no satisface el control: si el generador es comprometido, la invocación puede omitirse.

El componente debe fallar de forma cerrada. Ante un error interno o la indisponibilidad de un escáner, el comportamiento esperado es el rechazo de la solicitud, no su tránsito sin inspección.

Controles relacionados

Este control es condición previa para la totalidad de los controles experimentales de D1 y D3 (C02, C03, C18, C19, C20), que se implementan en el componente que C16 despliega.

C.1.5 C17: Fundamentación de la respuesta en el contexto recuperado

Nivel	N2	**Evidencia**	Experimental
Tipo	Preventivo/Detectivo	**Fuente**	LLM02:2025, LLM07:2025

Propósito

Verificar que la respuesta generada guarde correspondencia suficiente con el contexto recuperado, y bloquearla cuando el solapamiento entre ambos caiga por debajo del umbral configurado.

Justificación

Un sistema RAG existe para responder a partir de su corpus. Una respuesta que no guarda relación con el contexto recuperado es, por construcción, una respuesta que el modelo produjo desde otra fuente: su conocimiento paramétrico, o bien una instrucción que le indicó qué responder.

Esa condición captura simultáneamente dos vectores. La alucinación, en que el modelo afirma contenido que el corpus no respalda, y el secuestro de comportamiento, en que una inyección exitosa hace que la respuesta obedezca al atacante en lugar de a la consulta. Ambos se manifiestan de la misma forma observable: la respuesta no está fundamentada en lo que se recuperó.

El control es detectivo y preventivo a la vez. Detecta la discrepancia mediante la comparación entre respuesta y contexto, y previene la entrega al usuario mediante el bloqueo.

Guía de implementación

El umbral de fundamentación debe calibrarse contra un conjunto de consultas legítimas del dominio, midiendo el solapamiento que las respuestas correctas presentan de forma natural. Un umbral fijado sin esa calibración produce falsos positivos sobre respuestas válidas que parafrasean el contexto en lugar de reproducirlo.

La métrica de solapamiento admite distintas implementaciones. El marco no prescribe una: exige que sea determinista, que su umbral esté declarado en configuración y que el resultado de la comparación se registre para cada solicitud, de modo que la tasa de falsos positivos sea medible.

Controles relacionados

C07 (instrucción de uso exclusivo del contexto recuperado), que declara al modelo la restricción que este control verifica; C20 (detección semántica de contenido sensible en la salida), con el que comparte la etapa de intervención.

C.1.6 C21: Externalización de la configuración de tiempo de ejecución

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM01:2025, LLM02:2025

Propósito

Declarar fuera del código fuente la totalidad de la configuración de tiempo de ejecución del sistema: credenciales, umbrales de detección, rutas, identificadores de servicio y parámetros de despliegue.

Justificación

Una credencial incrustada en el código se filtra con el código. El repositorio, los artefactos de compilación, los registros de error y las trazas de excepción son vías por las que un valor codificado en el fuente alcanza a quien no debía verlo.

El argumento se extiende a los umbrales de detección, y ahí adquiere una segunda dimensión. Un umbral declarado en configuración es verificable por inspección, y por tanto satisface la fuente de evidencia que el marco exige para los controles de configuración. Un umbral incrustado en el código no lo es: constatarlo requiere leer el fuente, y modificarlo requiere redesplegar, lo que en la práctica desalienta la calibración que los controles de nivel N4 exigen.

Guía de implementación

La configuración debe residir en artefactos declarativos externos al código, sea como archivos de parametrización o como variables del entorno de ejecución. El código no debe contener valores por defecto que suplan la ausencia de un parámetro: un sistema que arranca con umbrales implícitos porque la configuración no fue provista opera en un estado que nadie declaró.

Las credenciales exigen un tratamiento distinto del resto de la configuración. No deben residir en los mismos artefactos que los umbrales, dado que estos últimos son objeto de revisión y versionado, mientras que aquellas no deben aparecer en ningún registro versionado.

Controles relacionados

C26 (documentación de la política de umbrales), que exige que los valores declarados por este control estén además justificados; C32 (verificación de integridad del prompt del sistema), que es un caso particular de verificación sobre configuración externalizada.

C.1.7 C30: Verificación de procedencia e integridad del modelo

Nivel	N1	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663, LLM08:2025

Propósito

Verificar, con anterioridad al despliegue, que el modelo de inferencia procede de la fuente declarada y que su contenido no ha sido alterado, mediante el contraste de su función de resumen criptográfico contra el valor publicado por el proveedor.

Justificación

El modelo es el activo sobre el cual opera la totalidad del flujo de inferencia. Un modelo alterado en origen o en tránsito compromete el sistema completo, y lo hace de una forma que ningún control posterior detecta: los escáneres de entrada y salida verifican el contenido de las transacciones, no el comportamiento del modelo que las procesa.

La Ley 21.663 exige que las organizaciones gestionen los riesgos de sus activos de información. Un modelo cuya procedencia no ha sido verificada es un componente de origen no acreditado en la cadena de suministro del sistema, condición que la norma obliga a controlar.

Guía de implementación

La verificación se realiza contrastando el resumen criptográfico del artefacto descargado contra el valor que el proveedor publica por un canal independiente al de la descarga. Un resumen publicado en el mismo canal desde el que se obtuvo el artefacto no acredita nada: quien pudo alterar uno pudo alterar el otro.

El registro de la verificación debe conservarse como evidencia, indicando el identificador del modelo, la versión, el resumen obtenido y la fecha. Ese registro es el artefacto que la auditoría documental inspecciona, dado que la verificación en sí es un evento del pasado que no deja traza en el sistema en ejecución.

Controles relacionados

C61 (inventario de activos del sistema RAG), que registra el modelo cuya procedencia este control verifica; C09 (verificación de integridad de los fragmentos recuperados), que aplica el mismo principio al corpus.

C.2 D1: Protección de entrada

Los controles de esta sección operan sobre el prompt del usuario antes de que alcance la etapa de recuperación o la capa de inferencia. Los controles transversales C06, C13, C15, C16, C21 y C30, que también pertenecen a D1, se desarrollan en la sección C.1.

C.2.1 C01: Límite de longitud del prompt de entrada

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM01:2025

Propósito

Rechazar toda entrada que exceda la longitud máxima definida en la configuración, antes de que ingrese al proceso de recuperación de contexto o alcance la capa de inferencia.

Justificación

La longitud del prompt determina la superficie disponible para construir un ataque. Los modelos de lenguaje no atienden de manera uniforme a todas las posiciones de su ventana de contexto: la atención se concentra en el inicio y el final de la secuencia, y decae en las posiciones intermedias. Un atacante puede explotar esta propiedad situando la instrucción adversarial en una posición donde compita ventajosamente con el prompt del sistema, precedida de relleno suficiente para desplazarlo. Restringir la longitud de la entrada limita el margen disponible para esta construcción, y contiene además el consumo de recursos de inferencia, que crece con el tamaño de la secuencia procesada.

Guía de implementación

El límite se aplica en el componente perimetral, previo a cualquier procesamiento del contenido, y su valor se declara en la configuración y no en el código, de modo que sea verificable por inspección. La unidad de medida debe ser coherente con la que el modelo emplea para su ventana de contexto: un límite expresado en caracteres no acota de forma determinista el número de tokens resultante, dado que la razón entre ambos varía según el idioma y la codificación del contenido. El marco no prescribe un valor específico; este se deriva de la longitud máxima que las consultas legítimas del dominio requieren.

Ante una entrada que excede el límite, el comportamiento esperado es el rechazo explícito con registro del evento, no el truncamiento silencioso. Truncar produce una consulta que el usuario no formuló, e impide distinguir un intento adversarial de una consulta legítima excesivamente larga.

Controles relacionados

C13 (límite de volumen de contexto por sesión), que opera sobre el mismo eje de contención en la etapa de recuperación; C31 (registro de prompts rechazados), que consume los eventos generados por este control.

C.2.2 C02: Sanitización de caracteres de control en la entrada

Nivel	N1	**Evidencia**	Experimental
Tipo	Correctivo	**Fuente**	LLM01:2025

Propósito

Eliminar de la entrada del usuario los tokens especiales del modelo, los bytes nulos y los caracteres de control Unicode, antes de que el texto alcance cualquier componente de análisis o inferencia.

Justificación

Los caracteres de control no imprimibles operan como vector de evasión por dos vías.

La primera es el quiebre de la tokenización. Un atacante puede inyectar los delimitadores internos que el modelo emplea para separar segmentos del prompt, o bytes nulos que provoquen excepciones en el procesamiento. En ambos casos el efecto buscado es que el modelo interprete las instrucciones del sistema como terminadas antes de tiempo, dejando la instrucción adversarial en posición de gobernar la respuesta. El mismo mecanismo permite falsificar los delimitadores que C06 establece para separar contexto de consulta.

La segunda es la evasión de los componentes de detección. Los escáneres que evalúan la entrada operan sobre el texto tal como lo reciben. Intercalar caracteres invisibles dentro de un payload adversarial altera la cadena que el escáner analiza sin alterar sustancialmente lo que el modelo termina interpretando, de modo que el contenido pasa el filtro y llega íntegro a la inferencia.

Guía de implementación

La sanitización debe ejecutarse antes que cualquier escáner, no después: un escáner que analiza texto sin sanitizar es evadible por construcción. El conjunto de caracteres a eliminar debe incluir, como mínimo, los delimitadores estructurales del modelo desplegado, los caracteres de control ASCII no imprimibles y los caracteres invisibles de Unicode.

El control es correctivo porque modifica la cadena en lugar de rechazarla. Esa elección es deliberada: una entrada legítima puede contener caracteres anómalos por accidente de codificación, y rechazarla penalizaría al usuario sin necesidad. No obstante, la presencia de caracteres removidos constituye por sí misma un indicador de intento adversarial, por lo que el evento de sanitización debe registrarse.

Controles relacionados

C06 (delimitación del contenido recuperado), cuyos marcadores este control protege de falsificación; C03 (bloqueo de intentos de inyección), que opera sobre la cadena ya sanitizada; C18, que aplica el mismo mecanismo a la salida del modelo.

C.2.3 C03: Bloqueo de intentos de inyección de instrucciones

Nivel	N2	**Evidencia**	Experimental
Tipo	Preventivo	**Fuente**	LLM01:2025

Propósito

Someter la entrada del usuario a un escáner que asigne una puntuación de riesgo de inyección, y bloquear la transacción cuando esa puntuación supere el umbral configurado.

Justificación

Las reglas deterministas basadas en coincidencia de patrones son evadibles por reformulación. Un atacante que conoce el patrón lo elude mediante sinónimos, alteración del orden sintáctico,

traducción a otro idioma o codificación del payload. La superficie de reformulación del lenguaje natural es, en la práctica, inagotable, y cada patrón bloqueado admite una variante que lo esquiva.

Un escáner que evalúa la intención del texto, en lugar de su forma, no depende de la coincidencia exacta con un patrón conocido. Clasifica la entrada según su semejanza semántica con el comportamiento adversarial, lo que le permite reconocer construcciones que no fueron vistas durante su entrenamiento. Esta propiedad es la que sostiene su valor como control de nivel N2: es el primer mecanismo del marco que interpone una decisión sobre el contenido de la entrada, y no solo sobre su forma.

Guía de implementación

El umbral de bloqueo debe declararse en la configuración antes de la operación, no ajustarse a posteriori en función de los resultados observados. Un umbral fijado después de conocer los resultados de la auditoría incorpora un sesgo que invalida la medición: el sistema aparece más efectivo de lo que es porque el criterio se acomodó a los datos.

El umbral debe calibrarse contra dos conjuntos: uno de entradas adversariales conocidas y otro de consultas legítimas del dominio. La calibración solo contra el primero produce un umbral que bloquea todo, con una tasa de falsos positivos que hace el sistema inutilizable. El registro de la puntuación asignada a cada solicitud, y no solo de la decisión de bloqueo, es condición para que esa tasa sea medible.

Controles relacionados

C02 (sanitización de la entrada), que garantiza que este control opere sobre texto no ofuscado; C26 (documentación de la política de umbrales), que exige la declaración previa que este control requiere; C33 (ajuste dinámico de umbrales), que en niveles superiores calibra el valor que este control emplea.

C.2.4 C04: Restricción de la consulta al dominio autorizado

Nivel	N2	**Evidencia**	Experimental
Tipo	Preventivo	**Fuente**	LLM01:2025

Propósito

Bloquear las consultas cuya distancia semántica mínima al corpus supere el umbral configurado, rechazando aquellas que se apartan del dominio que el sistema está autorizado a cubrir.

Justificación

Un sistema RAG responde a partir de un corpus acotado. Una consulta cuyo contenido no guarda proximidad semántica con ningún fragmento del corpus es, por definición, una consulta que el sistema no está en condiciones de responder correctamente: no existe contexto que recuperar.

Ante esa situación, un modelo sin este control no se abstiene. Recupera los fragmentos más próximos, que en ausencia de proximidad real son fragmentos arbitrarios, y genera una res-

puesta a partir de su conocimiento paramétrico o de la interpolación entre contenidos no pertinentes. El resultado es una respuesta fuera de dominio que el sistema entrega con la misma apariencia de autoridad que una respuesta fundamentada.

Desde la perspectiva de seguridad, la relevancia del control es distinta. Los ataques de inyección se formulan como instrucciones, no como preguntas sobre el dominio, y por tanto exhiben una distancia semántica al corpus considerablemente mayor que las consultas legítimas. El control captura esa condición sin necesidad de reconocer el ataque como tal.

Guía de implementación

El umbral de distancia debe calibrarse midiendo la distancia que las consultas legítimas del dominio presentan de forma natural, y fijando el corte por encima de ese rango con un margen que absorba la variabilidad. Un umbral demasiado estrecho rechaza consultas válidas formuladas con vocabulario poco frecuente en el corpus.

La distancia debe calcularse contra el corpus completo y no contra los fragmentos recuperados: estos últimos son, por construcción, los más próximos a la consulta, y medir contra ellos produciría siempre una distancia baja.

Controles relacionados

C11 (validación de coherencia de la consulta), que opera sobre el mismo eje pero con un umbral distinto y en la etapa de recuperación; C07 (restricción al uso exclusivo del contexto recuperado), que declara al modelo la restricción de dominio que este control hace cumplir.

C.2.5 C05: No inclusión del prompt del sistema en la respuesta

Nivel	N2	**Evidencia**	Experimental
Tipo	Detectivo	**Fuente**	LLM01:2025, LLM07:2025

Propósito

Extraer de la respuesta del modelo únicamente el texto generado, de modo que el prompt del sistema y sus restricciones no formen parte del contenido que se retorna al usuario.

Justificación

El prompt del sistema contiene las restricciones de comportamiento, el alcance del dominio autorizado y, con frecuencia, información estructural sobre el corpus y los componentes del sistema. Su exposición entrega al atacante el mapa de las defensas que debe evadir: conocer las restricciones exactas permite construir la instrucción que las contradice de la forma más eficaz.

La distinción importante es que este control opera sobre la arquitectura de la respuesta, no sobre la obediencia del modelo. Una instrucción que ordena al modelo no revelar sus directivas depende de que el modelo la respete, y una inyección exitosa puede subvertirla. En cambio, un sistema que construye la respuesta extrayendo únicamente el campo de texto generado no incluye el prompt del sistema con independencia de lo que el modelo haya decidido: el prompt no está en el campo del que se extrae.

Esta propiedad no es completa. El modelo puede reproducir el contenido de sus instrucciones dentro del propio texto generado, en cuyo caso la fuga ocurre por el canal legítimo. Es la razón por la que este control no basta y exige el complemento de los controles de salida de D3.

Guía de implementación

La construcción de la respuesta debe extraer exclusivamente el campo correspondiente al texto generado, sin concatenar ni exponer los demás componentes de la invocación al modelo. Los objetos completos de respuesta que el modelo devuelve, incluidos los metadatos de la invocación y el prompt que la originó, no deben alcanzar el canal de salida bajo ninguna condición, incluidas las trazas de error.

La verificación experimental del control consiste en ejecutar pruebas de extracción del prompt del sistema y constatar que la respuesta no reproduce las instrucciones configuradas.

Controles relacionados

C15 (definición del rol y las restricciones del modelo), cuyo contenido este control protege; C20 (detección semántica de contenido sensible en la salida), que captura la fuga por el canal del texto generado; C32 (verificación de integridad del prompt del sistema).

C.2.6 C31: Registro estructurado del motivo de bloqueo

Nivel	N3	**Evidencia**	Experimental
Tipo	Detectivo	**Fuente**	LLM01:2025

Propósito

Registrar, para cada solicitud rechazada, un motivo de bloqueo estructurado que identifique el componente que originó el rechazo y la etapa del flujo en que se produjo.

Justificación

Un sistema que bloquea sin registrar por qué bloqueó produce una defensa opaca. Ante un bloqueo, ni el operador ni el evaluador pueden determinar si el rechazo fue correcto, cuál de los controles lo originó, ni si la tasa de rechazos responde a un ataque en curso o a un umbral mal calibrado.

La exigencia de estructura, y no solo de registro, es lo que eleva este control a nivel N3. Un mensaje de error en texto libre acredita que hubo un bloqueo; un motivo estructurado que identifica el componente permite agregar los eventos por categoría, medir la tasa de rechazo de cada control por separado y establecer la trazabilidad que las métricas de nivel N4 requieren. Sin este control, las métricas de desempeño no tienen sobre qué calcularse.

Guía de implementación

El motivo debe identificar el componente que originó el rechazo y la etapa del flujo, con una nomenclatura consistente que permita distinguir un bloqueo de entrada de uno de salida. El registro debe producirse para toda solicitud rechazada, sin excepción, incluidas aquellas rechazadas por error interno del componente de seguridad.

El motivo que se registra no debe comunicarse al usuario. Informarle qué control bloqueó su solicitud le entrega el mapa de las defensas y le permite iterar sobre su payload hasta encontrar la formulación que las evade.

Controles relacionados

C01, C02, C03 y C04 (controles de entrada), cuyos eventos de rechazo este control consume; C23 (registro de decisiones de bloqueo en D4), del que este control es la contraparte en la etapa de entrada; C34 (medición de la tasa de rechazo por categoría), que opera sobre los registros que este control produce.

C.2.7 C32: Verificación de integridad del prompt del sistema

Nivel	N3	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM01:2025, LLM07:2025

Propósito

Verificar, mediante función de resumen criptográfico, que el prompt del sistema y sus restricciones no han sido modificados desde el arranque del sistema.

Justificación

El prompt del sistema es un artefacto de configuración, y como tal reside en un archivo o variable de entorno que un atacante con acceso al entorno de ejecución puede alterar. Esa alteración no deja traza en el flujo de inferencia: el sistema opera con normalidad, procesa las solicitudes sin error, y produce respuestas que ningún escáner de contenido identifica como anómalas, porque el comportamiento modificado es ahora el comportamiento configurado.

Un atacante que suprime la restricción de dominio, o la prohibición de revelar el corpus, obtiene un sistema que colabora con él por diseño. La verificación de integridad es el único control del marco que detecta esta condición, y opera sobre un vector que los controles de entrada y salida no cubren: el compromiso de la configuración misma.

Guía de implementación

El sistema debe calcular el resumen del prompt del sistema y sus restricciones al arranque, conservarlo en memoria, y contrastarlo contra el valor recalculado en cada invocación o de forma periódica. La comparación debe realizarse antes de construir el prompt aumentado.

El valor de referencia no debe residir en el mismo artefacto que el prompt del sistema. Un atacante que puede modificar el prompt puede modificar también el resumen almacenado junto a él, con lo que la verificación se satisface trivialmente sobre el contenido alterado.

Ante una discrepancia, el comportamiento esperado es la interrupción del servicio, no la continuación con registro de la anomalía. Un prompt del sistema alterado significa que el entorno de ejecución está comprometido, condición ante la cual la operación del sistema no debe continuar.

Controles relacionados

C15 (definición del rol y las restricciones del modelo), cuyo contenido este control protege; C21 (externalización de la configuración), que establece la condición sobre la que este control opera; C30 (verificación de integridad del modelo), que aplica el mismo principio al artefacto de inferencia.

C.2.8 C33: Ajuste dinámico de los umbrales de detección

Nivel	N4	**Evidencia**	Declarativo
Tipo	Preventivo	**Fuente**	LLM01:2025

Propósito

Ajustar periódicamente los umbrales de los escáneres de entrada en función de las tasas de falsos positivos y falsos negativos observadas en la operación.

Justificación

Un umbral de detección es un compromiso entre dos errores. Un valor estricto bloquea más ataques y también más consultas legítimas; un valor permisivo preserva la usabilidad al costo de dejar pasar payloads adversariales. No existe un valor óptimo universal: el punto de equilibrio depende de la distribución de las consultas del dominio, del perfil de amenaza de la organización y de su tolerancia al riesgo.

El nivel N4 del modelo de madurez se define por la gestión cuantitativa de la seguridad. Este control es su expresión en D1: el sistema deja de operar con umbrales fijados por defecto y pasa a ajustarlos según evidencia medida. La condición previa es que esa evidencia exista, lo que exige los controles de registro de nivel N3.

Guía de implementación

El ajuste debe fundarse en las tasas de error medidas sobre un conjunto de consultas legítimas de control, ejecutadas bajo las mismas condiciones que las consultas reales. Ajustar el umbral únicamente en función de los bloqueos observados en producción es insuficiente: sin un conjunto de control, no es posible distinguir un bloqueo correcto de un falso positivo.

Cada modificación de umbral debe documentarse indicando el valor anterior, el nuevo valor, la evidencia que lo justifica y la fecha. Ese registro es el artefacto que la auditoría inspecciona, dado que la verificación de este control es declarativa.

Controles relacionados

C03 (bloqueo de intentos de inyección), cuyo umbral este control ajusta; C34 (medición de la tasa de rechazo por categoría), que provee la evidencia sobre la que este control opera; C26 (documentación de la política de umbrales), que debe actualizarse ante cada ajuste.

C.2.9 C34: Medición de la tasa de rechazo por categoría de ataque

Nivel	N4	**Evidencia**	Declarativo
Tipo	Detectivo	**Fuente**	LLM01:2025

Propósito

Medir y reportar periódicamente la proporción de prompts rechazados, desglosada por categoría de ataque y por componente que originó el rechazo.

Justificación

Una tasa de rechazo agregada no es interpretable. Un sistema que rechaza el cinco por ciento de las solicitudes puede estar operando correctamente, bloqueando un cinco por ciento de tráfico adversarial, o puede estar produciendo un cinco por ciento de falsos positivos sobre consultas legítimas. La cifra es la misma y las dos situaciones exigen respuestas opuestas.

El desglose por categoría resuelve la ambigüedad y habilita, además, la detección de la asimetría defensiva: un sistema puede exhibir una tasa de filtrado alta en agregado y sin embargo ser sistemáticamente vulnerable a una categoría específica de ataque, condición que solo el reporte segmentado revela.

Guía de implementación

La medición se calcula sobre los registros que C31 produce, agregando los eventos por el motivo estructurado de bloqueo. La periodicidad del reporte debe declararse y respetarse: una medición ocasional no permite detectar la degradación de la efectividad defensiva a lo largo del tiempo.

El reporte debe incluir la tasa de falsos positivos, calculada sobre el conjunto de consultas legítimas de control. Un reporte que solo consigna los bloqueos no permite evaluar el costo de la defensa en términos de usabilidad.

Controles relacionados

C31 (registro estructurado del motivo de bloqueo), cuyos eventos este control agrega; C33 (ajuste dinámico de umbrales), que consume las tasas que este control produce; C56 (métricas de desempeño de la gobernanza), que reporta a la dirección los resultados de esta medición.

C.2.10 C35: Actualización de los patrones de detección

Nivel	N5	**Evidencia**	Declarativo
Tipo	Preventivo	**Fuente**	LLM01:2025

Propósito

Incorporar al componente de detección de entrada las nuevas técnicas de inyección documentadas, mediante un proceso periódico de revisión de la literatura y de los repositorios de amenazas.

Justificación

Las técnicas de inyección evolucionan. Un escáner entrenado o configurado en un momento dado reconoce las construcciones adversariales conocidas hasta esa fecha, y su efectividad decae a medida que aparecen variantes que no estaban en su repertorio.

El nivel N5 se define por la mejora continua. Este control es su expresión en la etapa de entrada: el sistema deja de tratar su capa defensiva como un artefacto estático y la somete a un ciclo de actualización que responde a la evolución de la amenaza, en lugar de responder a los incidentes ya ocurridos.

Guía de implementación

El ciclo de revisión debe tener una periodicidad declarada y fuentes de vigilancia identificadas: catálogos públicos de técnicas adversariales, publicaciones del proveedor del componente de detección, y la literatura del área.

Toda actualización de los patrones o del modelo de detección debe someterse a la auditoría ofensiva antes de su despliegue, dado que una actualización que mejora la cobertura de una categoría puede degradar la de otra. La verificación consiste en constatar que la tasa de filtrado no retrocede en ninguna categoría respecto de la configuración anterior.

Controles relacionados

C29 (plan de pruebas ofensivas previo al despliegue), que verifica la actualización que este control introduce; C43 y C45, que aplican el mismo principio a la salida y al monitoreo respectivamente; C58 (revisión proactiva del marco).

C.2.11 C36: Revisión del prompt del sistema ante cambios del modelo

Nivel	N5	**Evidencia**	Declarativo
Tipo	Preventivo	**Fuente**	LLM01:2025

Propósito

Revisar y ajustar las instrucciones del prompt del sistema cada vez que el modelo base es reemplazado o actualizado.

Justificación

La eficacia de una instrucción del sistema depende del modelo que la interpreta. Una formulación que un modelo respeta de forma consistente puede ser ignorada por otro, o interpretada de una manera que no fue la prevista. La sustitución del modelo base, aunque sea por una versión más reciente de la misma familia, altera la relación entre la instrucción y el comportamiento observado.

Este control captura una condición que las organizaciones tienden a pasar por alto: el prompt del sistema se trata como configuración estable mientras el modelo se trata como componente actualizable, cuando en realidad el primero solo tiene sentido en relación con el segundo. Un modelo actualizado con un prompt no revisado opera con restricciones cuya eficacia nadie ha verificado.

Guía de implementación

El cambio de modelo debe disparar la reejecución de la auditoría ofensiva sobre el prompt del sistema vigente, con particular atención a las pruebas de extracción de instrucciones y de secuestro de comportamiento. La comparación con los resultados de la configuración anterior determina si el prompt requiere ajuste.

El registro del cambio debe consignar el modelo anterior, el nuevo, los resultados de la auditoría en ambas configuraciones y las modificaciones aplicadas al prompt. Ese registro es la evidencia que la auditoría documental inspecciona.

Controles relacionados

C15 (definición del rol y las restricciones del modelo), cuyo contenido este control somete a revisión; C30 (verificación de procedencia del modelo), que se ejecuta ante el mismo evento; C61 (inventario de activos), que debe actualizarse ante todo cambio del modelo.

C.3 D2: Control de contexto RAG

Los controles de esta sección regulan el acceso, la exposición y la integridad de la base de datos vectorial y el corpus de conocimiento. Los controles transversales C06, C13, C15, C16, C17, C21 y C30, que también pertenecen a D2, se desarrollan en la sección C.1.

C.3.1 C07: Restricción al uso exclusivo del contexto recuperado

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM02:2025

Propósito

Declarar en el prompt del sistema la prohibición de generar información que no esté fundamentada en el contexto recuperado del corpus.

Justificación

Un modelo de lenguaje no distingue por sí mismo entre lo que sabe por su entrenamiento y lo que acaba de leer en el contexto. Ante una consulta que el contexto recuperado no responde por completo, la conducta por defecto es completar el vacío con conocimiento paramétrico, y hacerlo con la misma apariencia de fundamentación que el contenido efectivamente recuperado.

Desde la perspectiva de seguridad, esa conducta abre dos brechas. La primera es la alucinación con apariencia de autoridad: el sistema afirma contenido que su corpus no respalda, y el usuario no tiene forma de distinguirlo del contenido fundamentado. La segunda es más sutil: un modelo dispuesto a responder desde su conocimiento paramétrico es un modelo dispuesto a responder consultas ajenas al dominio autorizado, lo que amplía la superficie sobre la que un atacante puede operar.

Este control declara la restricción; C17 la verifica. La instrucción por sí sola no garantiza el cumplimiento, dado que depende de la obediencia del modelo, pero establece el criterio contra el cual el control de verificación puede contrastar la respuesta.

Guía de implementación

La instrucción debe declararse en la configuración del prompt del sistema, junto al resto de las restricciones que C15 establece. Debe cubrir explícitamente el comportamiento esperado ante una consulta que el contexto no responde: la abstención declarada, y no la respuesta parcial ni la completación desde otra fuente.

El control es de nivel N1 porque su implementación es puramente declarativa y no requiere componente adicional alguno. Su presencia se verifica por inspección de la configuración.

Controles relacionados

C15 (definición del rol y las restricciones del modelo), que es el artefacto donde esta instrucción reside; C17 (fundamentación de la respuesta), que verifica el cumplimiento de la restricción que este control declara; C04 (restricción de la consulta al dominio autorizado), que opera sobre el mismo principio en la etapa de entrada.

C.3.2 C10: Control de la cantidad de fragmentos recuperados

Nivel	N1	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM02:2025

Propósito

Limitar el número de fragmentos que la etapa de recuperación devuelve por consulta, acotando el volumen de corpus que una sola solicitud puede exponer.

Justificación

La exfiltración de un corpus mediante consultas sucesivas es un ataque de acumulación: cada consulta extrae una porción, y el atacante reconstruye el conjunto a lo largo de múltiples sesiones. La cantidad de fragmentos que cada consulta devuelve determina directamente cuántas consultas requiere el ataque para completarse.

Un sistema que devuelve veinte fragmentos por consulta expone su corpus en un orden de magnitud menos de solicitudes que uno que devuelve tres. El control no impide la exfiltración, dado que un atacante persistente puede realizar el número de consultas que sean necesarias, pero eleva el costo del ataque y prolonga la ventana durante la cual los controles de detección de reconocimiento sistemático pueden identificarlo.

Guía de implementación

El valor debe derivarse de la cantidad de fragmentos que las consultas legítimas del dominio requieren para ser respondidas correctamente. Un valor excesivamente bajo degrada la calidad de las respuestas: el modelo carece del contexto necesario y, si C07 está implementado, se abstiene de responder consultas que el corpus sí cubría.

La calibración exige medir, sobre un conjunto de consultas legítimas, cuántos fragmentos contribuyen efectivamente a la respuesta correcta. Ese número, y no un valor arbitrario, es el que el control debe declarar.

Controles relacionados

C13 (límite de volumen de contexto inyectado), con el que comparte el mecanismo de implementación; C12 (detección de reconocimiento sistemático del corpus), que identifica los ataques de acumulación que este control ralentiza; C38 (ajuste de parámetros de retrieval).

C.3.3 C08: Clasificación y filtrado del corpus por sensibilidad

Nivel	N2	**Evidencia**	Configuración
Tipo	Preventivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Clasificar cada fragmento del corpus según su nivel de sensibilidad al momento de la indexación, y restringir la recuperación a los niveles que la sesión está autorizada a consultar.

Justificación

Un corpus indexado sin distinción de sensibilidad es un corpus en el que toda consulta puede alcanzar todo fragmento. La única barrera entre una consulta y un documento confidencial es la proximidad semántica, y esa barrera no es una decisión de seguridad: es un accidente de cómo el atacante formule su pregunta.

La clasificación introduce una decisión de autorización allí donde antes solo había una decisión de relevancia. El filtro se aplica en la consulta a la base vectorial, antes de que los fragmentos se recuperen, de modo que el contenido no autorizado no ingresa al contexto de inferencia bajo ninguna circunstancia. Un modelo no puede revelar aquello que nunca recibió, y esa es la propiedad que distingue este control de los controles de salida: estos últimos intentan suprimir el contenido sensible después de que el modelo lo procesó, con la incertidumbre que ello conlleva.

Guía de implementación

La clasificación debe realizarse durante la indexación y almacenarse como metadato del fragmento, no calcularse en tiempo de consulta. El criterio de clasificación debe estar documentado y ser reproducible: dos indexaciones del mismo corpus deben producir la misma clasificación.

El filtro debe aplicarse en la propia consulta a la base vectorial, y no como descarte posterior de los resultados. Un sistema que recupera todos los fragmentos y luego descarta los no autorizados ha materializado el contenido sensible en memoria, y toda ruta de error o traza de excepción que exponga esa estructura constituye una fuga.

La verificación de este control exige constatar que el metadato de sensibilidad está presente en la totalidad de los fragmentos indexados. Un corpus en el que el metadato falta en algunos fragmentos produce un filtro que no los alcanza, con lo que el control opera con una cobertura inferior a la declarada.

Controles relacionados

C22 (control de acceso por sesión al vector store), que determina qué niveles de sensibilidad cada sesión está autorizada a consultar; C39 (actualización del particionamiento ante reclasificación); C62 (registro versionado del corpus), que permite constatar qué clasificación estaba vigente en cada sesión.

C.3.4 C09: Verificación de integridad de los fragmentos recuperados

Nivel	N2	**Evidencia**	Experimental
Tipo	Preventivo/Detectivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Contrastar los fragmentos recuperados contra una línea base de integridad establecida en la indexación, antes de incorporarlos al contexto de inferencia.

Justificación

La base vectorial es un componente con estado, y su contenido es alterable por quien tenga acceso a ella. Un atacante que modifica un fragmento indexado no necesita comprometer el modelo ni el prompt del sistema: le basta con que el sistema recupere el fragmento alterado y lo entregue al modelo como contexto legítimo.

Este es el vector de intoxicación del corpus, y su peligrosidad reside en que ningún control de entrada lo detecta. La consulta del usuario puede ser perfectamente legítima; el ataque no está en la pregunta sino en el material con que el sistema la responde. Un fragmento intoxicado con una instrucción adversarial llega al modelo por el canal que el sistema considera confiable, y con la autoridad que el sistema le atribuye.

La verificación de integridad convierte esa alteración en un evento detectable. El fragmento que no corresponde a su resumen de referencia es un fragmento que fue modificado después de la indexación, condición que el sistema no puede atribuir a ninguna operación legítima.

Guía de implementación

El resumen de cada fragmento debe calcularse durante la indexación y conservarse en un artefacto independiente de la base vectorial. Almacenar la línea base dentro de la misma base que se pretende verificar anula el control: quien pudo alterar el fragmento pudo alterar su resumen.

La verificación debe ejecutarse sobre los fragmentos recuperados y antes de la construcción del prompt aumentado. Ante una discrepancia, el comportamiento esperado es el rechazo de la solicitud y el registro del evento, no la exclusión silenciosa del fragmento y la continuación con los restantes: una discrepancia significa que la base vectorial está comprometida, y la respuesta que el sistema produzca con los demás fragmentos también proviene de una fuente cuya integridad se acaba de refutar.

Controles relacionados

C62 (registro versionado del corpus), que provee la trazabilidad de qué versión del corpus estaba activa cuando se estableció la línea base; C30 (verificación de integridad del modelo), que

aplica el mismo principio al artefacto de inferencia; C23 (registro de decisiones de bloqueo), que consume los eventos de discrepancia.

C.3.5 C11: Validación de coherencia de la consulta

Nivel	N2	**Evidencia**	Experimental
Tipo	Preventivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Bloquear las consultas cuya distancia semántica mínima a los fragmentos del corpus supere el umbral de coherencia configurado, rechazando aquellas cuyo contenido no admite una interpretación semántica válida.

Justificación

Una consulta codificada, ofuscada o compuesta de contenido sin estructura semántica coherente produce una representación vectorial que no guarda proximidad con ningún fragmento del corpus. Esa condición es observable con independencia de que el sistema reconozca la técnica de ofuscación empleada.

La distinción con C04 es de umbral y de propósito. C04 rechaza consultas que son semánticamente válidas pero ajenas al dominio: preguntas legítimas sobre temas que el corpus no cubre. C11 rechaza consultas que no son semánticamente válidas en absoluto: cadenas codificadas en base64, secuencias de caracteres sin significado, o payloads construidos para evadir los escáneres de texto plano mediante representaciones alternativas.

El control captura una clase de ataque que los escáneres de contenido no ven. Un payload adversarial codificado no exhibe los patrones que un escáner de inyección reconoce, precisamente porque su codificación los oculta; pero tampoco exhibe la coherencia semántica que una consulta legítima presenta, y es esa segunda propiedad la que este control mide.

Guía de implementación

El umbral de coherencia debe ser más permisivo que el de dominio: una consulta legítima formulada con vocabulario poco frecuente en el corpus debe superar el filtro de coherencia aunque no supere el de dominio. Ambos controles operan sobre la misma métrica pero con cortes distintos, y su calibración debe realizarse de forma conjunta para evitar que uno haga redundante al otro.

La distancia debe calcularse contra el corpus completo, y el valor obtenido debe registrarse para cada solicitud, de modo que la distribución de distancias de las consultas legítimas sea observable y el umbral pueda calibrarse contra ella.

Controles relacionados

C04 (restricción de la consulta al dominio autorizado), con el que comparte la métrica pero no el umbral; C02 (sanitización de la entrada), que elimina la ofuscación por caracteres de control mientras este control captura la ofuscación por codificación; C03 (bloqueo de intentos de inyección).

C.3.6 C14: Exclusión de metadatos en la recuperación

Nivel	N2	**Evidencia**	Experimental
Tipo	Preventivo	**Fuente**	LLM02:2025

Propósito

Excluir los metadatos de los documentos en la etapa de recuperación, de modo que únicamente el texto de los fragmentos alcance el contexto de inferencia.

Justificación

Los metadatos de un fragmento indexado describen su procedencia: el documento de origen, su ruta en el sistema de archivos, su fecha, su autor, su clasificación de sensibilidad. Ninguno de esos campos contribuye a que el modelo responda mejor la consulta, y todos ellos constituyen información sobre la estructura interna del corpus que el sistema no tiene razón para exponer.

Un modelo que recibe los metadatos en su contexto puede reproducirlos en la respuesta, sea porque el usuario los solicita explícitamente, sea porque una instrucción inyectada se lo ordena, sea simplemente porque el modelo los considera pertinentes para fundamentar su afirmación. El resultado es la exposición de la topología del corpus: qué documentos existen, cómo se llaman, dónde residen y cuáles están marcados como sensibles.

La decisión de excluir los metadatos en la recuperación, y no de suprimirlos en la salida, es lo que hace de este control un control preventivo de D2 y no un control correctivo de D3. El modelo no puede revelar aquello que nunca recibió, y esa propiedad no depende de que ningún escáner posterior acierte a identificar el contenido a suprimir.

Guía de implementación

La consulta a la base vectorial debe solicitar explícitamente el texto de los fragmentos y sus identificadores, y omitir los metadatos del conjunto de campos devueltos. Una implementación que recupera los metadatos y luego los descarta antes de construir el prompt satisface el resultado, pero materializa el contenido en memoria, con la exposición que ello implica ante trazas de error.

Los identificadores de fragmento constituyen la excepción: el sistema los requiere para la trazabilidad y para la verificación de integridad, y su exposición no revela información sobre la estructura del corpus siempre que sean opacos, es decir, que no codifiquen el nombre del documento de origen ni su ruta.

Controles relacionados

C08 (clasificación por sensibilidad), cuyo metadato este control impide que alcance el contexto; C19 (bloqueo de contenido sensible en la salida), que captura las fugas que este control no previene; C09 (verificación de integridad), que emplea los identificadores que este control preserva.

C.3.7 C22: Control de acceso por sesión al vector store

Nivel	N2	**Evidencia**	Declarativo
Tipo	Preventivo/Detectivo	**Fuente**	LLM02:2025

Propósito

Determinar, para cada sesión, qué documentos del corpus está autorizada a consultar, y registrar los accesos efectivamente realizados.

Justificación

Los controles de D2 acotan qué se recupera y cuánto, pero no quién. Un sistema que aplica la totalidad de los controles anteriores sigue tratando a todos sus usuarios como un único sujeto: la clasificación de sensibilidad que C08 establece determina qué niveles son recuperables, pero no en función de quién consulta.

Esa indiferenciación es aceptable en un sistema cuyo corpus es uniformemente accesible para todos sus usuarios legítimos. Deja de serlo en cuanto el corpus contiene información cuya visibilidad depende del rol, la pertenencia organizacional o la autorización individual del consultante, situación que es la norma en un despliegue productivo.

El control es de fuente de evidencia declarativa porque su verificación depende de la capa de identidad y autenticación de la organización, componente externo al flujo de inferencia RAG. No es evaluable mediante auditoría ofensiva contra el sistema: un escáner que ataca el endpoint de inferencia no puede constatar si la sesión que lo ejecuta tenía las autorizaciones que se le atribuyen.

Guía de implementación

La autorización debe determinarse antes de la consulta a la base vectorial y traducirse en el filtro que la consulta aplica, componiéndose con el filtro de sensibilidad que C08 establece. Una implementación que autoriza el acceso al sistema pero no discrimina el corpus recuperable por sesión no satisface este control.

El registro de accesos debe consignar la identidad de la sesión, los identificadores de los fragmentos recuperados y la marca temporal. Ese registro es el artefacto que la auditoría inspecciona, y es además el insumo sobre el que C24 detecta los patrones de reconocimiento sistemático a lo largo de múltiples sesiones.

Controles relacionados

C08 (clasificación y filtrado por sensibilidad), con cuyo filtro este control se compone; C51 (procedimiento de gestión de accesos), que establece el marco organizacional que este control materializa; C24 (monitoreo de patrones de consulta anómalos), que consume los registros de acceso.

C.3.8 C12: Detección de reconocimiento sistemático del corpus

Nivel	N3	**Evidencia**	Experimental
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Detectar y bloquear las consultas cuya formulación indica un intento de enumeración o mapeo sistemático del contenido del corpus, en lugar de una pregunta sobre él.

Justificación

Existe una diferencia observable entre preguntar por el contenido de un corpus y preguntar por su estructura. Una consulta legítima interroga sobre un hecho, un concepto o una relación; una consulta de reconocimiento interroga sobre el continente: qué documentos existen, cuántos son, cómo se organizan, qué temas cubren, qué fragmentos están marcados como sensibles.

Esta segunda clase de consulta es el primer paso de una exfiltración sistemática. El atacante que pretende extraer un corpus no comienza extrayéndolo: comienza determinando qué contiene, para dirigir sus consultas posteriores hacia el contenido que le interesa. Detectar esa fase de reconocimiento permite interrumpir el ataque antes de que alcance la fase de extracción.

El control opera sobre la consulta individual y no sobre el patrón de consultas a lo largo del tiempo. Esa segunda capacidad corresponde a C24, que es un control de nivel N4 y de subdimensión D4. La distinción es relevante: C12 captura la consulta que se delata por su formulación, mientras que C24 captura al atacante que se delata por su comportamiento aunque cada consulta individual parezca inocua.

Guía de implementación

La detección debe cubrir las formulaciones que interrogan sobre la estructura del corpus, sobre la existencia o el número de documentos, sobre su clasificación, y sobre el contenido del prompt del sistema en cuanto describe el corpus. Debe cubrir asimismo las formulaciones indirectas: solicitudes de listado, de resumen exhaustivo, o de enumeración de temas cubiertos.

El evento de detección debe registrarse aunque la consulta no llegue a bloquearse, dado que la tasa de consultas de reconocimiento es en sí misma un indicador de amenaza que la organización debe poder observar.

Controles relacionados

C24 (monitoreo de patrones de consulta anómalos), que opera sobre la dimensión temporal que este control no cubre; C10 (control de la cantidad de fragmentos recuperados), que ralentiza la fase de extracción que este control busca prevenir; C31 y C23 (registro de decisiones de bloqueo).

C.3.9 C62: Registro versionado del corpus indexado

Nivel	N3	**Evidencia**	Configuración
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Mantener un registro persistente de cada evento de indexación del corpus, que permita identificar qué documentos estaban activos en cada sesión y rastrear los cambios entre versiones sucesivas.

Justificación

El corpus es un activo mutable. Se le agregan documentos, se le retiran, se reindexa con otra estrategia de segmentación, se reclasifica su sensibilidad. Cada una de esas operaciones produce un corpus distinto del anterior, y el sistema que lo consulta no conserva ninguna traza de cuál estaba vigente cuando respondió una consulta determinada.

La ausencia de versionado tiene una consecuencia que solo se manifiesta ante un incidente. Si una respuesta reveló contenido sensible, la investigación requiere saber qué fragmentos estaban indexados en ese momento y con qué clasificación. Un corpus que fue reindexado desde entonces no permite reconstruir esa condición: los fragmentos que se recuperaron pueden ya no existir, y los que existen pueden tener una clasificación distinta de la que tenían.

El registro convierte al corpus en un activo trazable. Es, además, la condición que permite atribuir un incidente a una versión específica del corpus y no al sistema en general, distinción que la investigación de causas requiere.

Guía de implementación

El registro debe consignar, para cada evento de indexación, la marca temporal, la acción realizada, la cantidad de documentos y fragmentos resultantes, y un resumen criptográfico del conjunto que permita identificar unívocamente la versión.

El registro debe ser persistente e independiente de la base vectorial. Un registro que reside en la misma base que documenta se pierde con ella ante un reinicio o una reindexación destructiva, que es precisamente el evento cuya trazabilidad este control busca preservar.

La correlación entre una sesión y la versión del corpus vigente exige que los registros de solicitud, que C25 produce, consignen el identificador de la versión activa. Sin esa correlación el registro versionado documenta la evolución del corpus pero no permite atribuir una respuesta a una versión determinada.

Controles relacionados

C09 (verificación de integridad de los fragmentos), cuya línea base este control versiona; C25 (registro de latencia y metadatos de cada solicitud), que debe consignar la versión activa; C61 (inventario de activos), del que este registro es la componente correspondiente al corpus.

C.3.10 C37: Medición de la tasa de recuperación de fragmentos sensibles

Nivel	N4	**Evidencia**	Declarativo
Tipo	Detectivo	**Fuente**	LLM02:2025

Propósito

Medir y reportar periódicamente la proporción de fragmentos clasificados como sensibles que la etapa de recuperación devuelve ante un conjunto de consultas de prueba.

Justificación

El filtro de sensibilidad que C08 establece se declara en la configuración, y su presencia es verificable por inspección. Lo que la inspección no acredita es su eficacia: un filtro correctamente declarado puede no alcanzar a los fragmentos cuyo metadato de clasificación falta, o puede resultar insuficiente ante consultas formuladas para maximizar la proximidad semántica con el contenido sensible.

La medición convierte esa incertidumbre en una cifra. Ejecutar un conjunto de consultas dirigidas contra el contenido clasificado como sensible, y medir cuántos de esos fragmentos el sistema devuelve, es la única forma de constatar que el filtro opera como se declara.

Este control es la expresión de la gestión cuantitativa en D2. Su ausencia significa que la organización confía en la corrección de su configuración sin haberla puesto a prueba.

Guía de implementación

El conjunto de consultas de prueba debe construirse a partir del contenido sensible del corpus, formulando las consultas que un atacante emplearía para alcanzarlo. Un conjunto compuesto de consultas genéricas no ejerce presión sobre el filtro y produce una tasa de recuperación artificialmente baja.

La medición debe repetirse ante cada reindexación del corpus y ante cada cambio en la clasificación de sensibilidad, dado que ambas operaciones pueden alterar la cobertura del filtro sin que la configuración cambie.

Controles relacionados

C08 (clasificación y filtrado por sensibilidad), cuya eficacia este control mide; C38 (ajuste de parámetros de retrieval), que consume la tasa que este control produce; C42 (medición de la tasa de supresión en la salida), que es su contraparte en D3.

C.3.11 C38: Ajuste de los parámetros de recuperación

Nivel	N4	**Evidencia**	Declarativo
Tipo	Preventivo	**Fuente**	LLM02:2025

Propósito

Ajustar los parámetros de la etapa de recuperación, incluidos el número de fragmentos devuel-

tos y los umbrales de proximidad semántica, en función de las métricas de exposición observadas.

Justificación

Los parámetros de recuperación se fijan al desplegar el sistema, con valores que se derivan de la calidad de respuesta esperada y no de la exposición que producen. El resultado es un compromiso que nadie midió: se recuperan tantos fragmentos como se creyó necesario, con la exposición que ello implique.

Este control invierte la relación. Los parámetros dejan de ser una decisión de calidad con consecuencias de seguridad no medidas, y pasan a ser una decisión que integra ambas dimensiones sobre la base de evidencia. Un sistema que mide la tasa de recuperación de fragmentos sensibles y no ajusta sus parámetros en consecuencia mide sin actuar; uno que ajusta sin medir actúa sin fundamento.

Guía de implementación

El ajuste debe fundarse en las métricas que C37 produce y en la medición de la calidad de respuesta sobre un conjunto de consultas legítimas. Reducir el número de fragmentos recuperados disminuye la exposición y degrada la calidad; el punto de equilibrio exige medir ambas magnitudes, no solo la primera.

Cada modificación debe documentarse indicando los valores anteriores, los nuevos, la evidencia que los justifica y la fecha. Ese registro es el artefacto que la auditoría documental inspecciona.

Controles relacionados

C10 y C13 (control del volumen recuperado), cuyos valores este control ajusta; C37 (medición de la tasa de recuperación de fragmentos sensibles), que provee la evidencia; C33 (ajuste dinámico de umbrales en la entrada), del que este control es el equivalente en D2.

C.3.12 C39: Actualización del particionamiento ante reclasificación

Nivel	N5	**Evidencia**	Declarativo
Tipo	Preventivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Actualizar la clasificación de sensibilidad de los fragmentos indexados y el filtro que la aplica, ante cambios en la política de clasificación del corpus o en el contenido de los documentos.

Justificación

La sensibilidad de un documento no es una propiedad permanente. Un contenido que era público puede pasar a ser reservado ante un cambio normativo; uno que era confidencial puede desclasificarse. La política de clasificación de la organización evoluciona, y un corpus indexado bajo una política anterior conserva una clasificación que ya no corresponde a la vigente.

El riesgo es asimétrico. Un fragmento que se volvió sensible y sigue clasificado como público es recuperable por cualquier consulta, y el filtro que debía protegerlo no lo alcanza porque su metadato dice que no lo necesita. La configuración es correcta, el control opera como se declara, y la fuga ocurre de todos modos.

Guía de implementación

El ciclo de revisión de la clasificación debe tener una periodicidad declarada y debe dispararse, además, ante todo cambio en la política de clasificación de la organización y ante toda incorporación de documentos al corpus.

La reclasificación exige la reindexación de los fragmentos afectados, dado que el metadato de sensibilidad se establece en la indexación. Un sistema que actualiza la política pero no reindexa opera con un filtro que aplica la política nueva sobre metadatos que reflejan la anterior.

La verificación de este control, tras cada reclasificación, consiste en reejecutar la medición que C37 establece sobre el contenido reclasificado.

Controles relacionados

C08 (clasificación y filtrado por sensibilidad), cuya vigencia este control mantiene; C62 (registro versionado del corpus), que documenta las versiones sucesivas que la reclasificación produce; C37 (medición de la tasa de recuperación de fragmentos sensibles), que verifica el resultado.

C.3.13 C40: Revisión proactiva del corpus ante nuevas amenazas

Nivel	N5	**Evidencia**	Declarativo
Tipo	Preventivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Revisar el contenido indexado ante la documentación de nuevas técnicas de exfiltración, evaluando si los fragmentos del corpus resultan explotables por vectores que no existían al momento de su indexación.

Justificación

Un corpus indexado bajo la evaluación de riesgo de un momento dado contiene fragmentos que se consideraron seguros según los vectores conocidos entonces. La aparición de una técnica nueva puede convertir en explotable un contenido que hasta ese momento no lo era, sin que nada en el corpus haya cambiado.

El caso más claro es el de la exfiltración por agregación: fragmentos que aisladamente no revelan información sensible, pero cuya combinación mediante una secuencia de consultas dirigidas sí lo hace. La vulnerabilidad no está en ningún fragmento sino en la relación entre ellos, y su reconocimiento exige revisar el corpus con el conocimiento de la técnica que la explota.

Guía de implementación

La revisión debe dispararse ante la documentación de nuevas técnicas de exfiltración en la literatura del área o en los catálogos públicos de amenazas, y debe evaluar el corpus en su

conjunto y no fragmento a fragmento, dado que las técnicas de agregación operan sobre el conjunto.

El resultado de la revisión puede ser la reclasificación de fragmentos, su retiro del índice, o la incorporación de controles adicionales. Toda decisión debe documentarse indicando la técnica que la motivó y la evidencia de su aplicabilidad al corpus.

Controles relacionados

C39 (actualización del particionamiento), que materializa la reclasificación que esta revisión determina; C35 y C43 (actualización de los patrones de detección), que responden al mismo ciclo de vigilancia de amenazas; C58 (revisión proactiva del marco).

C.4 D3: Gestión de salida

Los controles de esta sección filtran y regulan las respuestas generadas por el modelo antes de entregarlas al usuario. Los controles transversales C16 y C17, que también pertenecen a D3, se desarrollan en la sección C.1.

C.4.1 C18: Sanitización de caracteres de control en la salida

Nivel	N2	**Evidencia**	Experimental
Tipo	Correctivo	**Fuente**	LLM01:2025, LLM07:2025

Propósito

Eliminar de la respuesta generada los caracteres de control y los tokens especiales del modelo, antes de someterla a los escáneres de contenido y de retornarla al usuario.

Justificación

Este control es el espejo de C02 en la etapa de salida, y su justificación es análoga pero opera sobre un canal distinto.

El modelo puede emitir en su respuesta los tokens especiales de su propia arquitectura, sea porque una inyección exitosa se lo ordenó, sea porque el contenido del corpus los contenía y el modelo los reprodujo. Esos tokens, si alcanzan la salida, comprometen a quien la consuma: un cliente que reenvía la respuesta a otro modelo, o que la incorpora a un prompt posterior, recibe una cadena capaz de alterar la estructura de ese segundo prompt.

La segunda razón es la misma que sostiene C02: los escáneres que evalúan la salida operan sobre el texto que reciben, y un contenido sensible intercalado con caracteres invisibles evade los patrones deterministas que C19 aplica sin dejar de ser legible para el usuario que la recibe.

Guía de implementación

La sanitización debe ejecutarse antes que los escáneres de contenido de la salida, por la misma razón que C02 debe ejecutarse antes que los de la entrada: un escáner que analiza texto sin sanitizar es evadible por construcción.

El evento debe registrarse cuando la respuesta contenía caracteres removidos. Su presencia en una salida es un indicador de que el modelo emitió contenido anómalo, condición que en un flujo sin incidentes no debería producirse.

Controles relacionados

C02 (sanitización de la entrada), del que este control es la contraparte en la salida; C19 (bloqueo de contenido sensible por patrones deterministas), que opera sobre la cadena que este control sanea; C16 (proxy de seguridad), que es el componente donde este control se implementa.

C.4.2 C19: Bloqueo de contenido sensible por patrones deterministas

Nivel	N2	**Evidencia**	Experimental
Tipo	Detectivo/Correctivo	**Fuente**	LLM02:2025, LLM07:2025

Propósito

Bloquear las respuestas que coincidan con patrones deterministas de contenido sensible: los marcadores de confidencialidad del corpus y los identificadores personales estructurados.

Justificación

Existe una clase de contenido sensible cuya forma es reconocible con certeza. Los identificadores personales estructurados, como los números de identificación nacional, las direcciones de correo, los números telefónicos y los de tarjeta de crédito, exhiben una estructura sintáctica que un patrón determinista reconoce sin ambigüedad. Lo mismo ocurre con los marcadores de confidencialidad que la organización aplica a su corpus.

Sobre ese contenido, un escáner determinista es superior a uno semántico. No falla, no depende de un umbral, y su decisión es reproducible: una cadena que coincide con el patrón coincide siempre. La detección semántica, que C20 aporta, es necesaria precisamente para el contenido que no exhibe esa regularidad, pero introduce una incertidumbre que sobre este subconjunto sería innecesaria.

El control es detectivo y correctivo a la vez: identifica la coincidencia y suprime la respuesta antes de su entrega.

Guía de implementación

El conjunto de patrones debe declararse en la configuración y cubrir, como mínimo, los identificadores personales estructurados que la normativa de protección de datos aplicable a la organización reconoce como tales, y los marcadores de confidencialidad que la política de clasificación del corpus emplea.

El marcador de confidencialidad merece una consideración particular. Su presencia en la salida significa que un fragmento clasificado como confidencial alcanzó el contexto de inferencia y el modelo lo reprodujo, lo que constituye una falla de los controles de D2 y no solo de D3. El evento debe registrarse como tal, dado que su ocurrencia indica que el filtro de sensibilidad no operó.

Ante una coincidencia, el comportamiento esperado es el bloqueo de la respuesta completa, no la supresión del fragmento coincidente y la entrega del resto. Una respuesta que contenía un identificador personal probablemente contiene también el contexto que lo rodea, y la supresión selectiva entrega ese contexto.

Controles relacionados

C08 (clasificación y filtrado por sensibilidad), cuya falla este control revela; C20 (detección semántica de contenido sensible), que cubre el contenido sin estructura reconocible; C42 (medición de la tasa de supresión).

C.4.3 C20: Detección semántica de contenido sensible en la salida

Nivel	N3	**Evidencia**	Experimental
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM07:2025

Propósito

Detectar y puntuar mediante análisis semántico las respuestas que contengan información sensible cuya forma no coincide con ningún patrón determinista.

Justificación

Los patrones deterministas que C19 aplica cubren el contenido cuya estructura los delata. No cubren el que carece de esa estructura: un dato médico expresado en prosa, una condición personal descrita en lenguaje natural, un nombre asociado a una circunstancia reservada, o el contenido del prompt del sistema parafraseado por el modelo en lugar de reproducido literalmente.

Esa segunda clase es la que un atacante persigue cuando el sistema ya bloquea la primera. Una instrucción que ordena al modelo revelar el prompt del sistema puede ser reformulada para que lo parafrasee, con lo que la fuga ocurre sin que ninguna cadena coincida con ningún patrón. El escáner semántico evalúa el significado de la respuesta y no su forma, lo que le permite reconocer el contenido que la reformulación oculta.

El precio de esa capacidad es la incertidumbre. La detección semántica opera sobre un umbral, y todo umbral admite falsos positivos y falsos negativos. Es la razón por la que este control es de nivel N3 y no N2: exige una calibración que los controles deterministas no requieren, y esa calibración es lo que caracteriza al nivel definido del modelo de madurez.

Guía de implementación

El umbral debe declararse en la configuración antes de la operación y calibrarse contra dos conjuntos: uno de respuestas que contienen contenido sensible del corpus y otro de respuestas legítimas del dominio. La calibración solo contra el primero produce un umbral que bloquea respuestas válidas.

La puntuación asignada a cada respuesta debe registrarse, y no solo la decisión de bloqueo. Sin ese registro, la distribución de puntuaciones de las respuestas legítimas no es observable, y la tasa de falsos positivos que C41 debe ajustar no es medible.

La eficacia de este control depende del dominio. Un corpus cuyo contenido sensible se expresa en la forma que el escáner reconoce produce una tasa de detección alta; uno cuyo contenido sensible es sensible por su contexto y no por su forma puede resultar invisible al escáner. Esa dependencia debe documentarse: un escáner semántico que no activa en un dominio determinado no acredita la ausencia de contenido sensible en la salida.

Controles relacionados

C19 (bloqueo por patrones deterministas), cuya cobertura este control extiende; C05 (no inclusión del prompt del sistema en la respuesta), cuyas fugas por paráfrasis este control captura; C41 (ajuste de los umbrales de sanitización).

C.4.4 C41: Ajuste dinámico de los umbrales de sanitización

Nivel	N4	**Evidencia**	Declarativo
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM07:2025

Propósito

Ajustar periódicamente los umbrales de los escáneres de salida en función de las tasas de falsos positivos observadas sobre las respuestas legítimas del sistema.

Justificación

El costo de un falso positivo en la salida es mayor que en la entrada. Una consulta legítima bloqueada en la entrada produce un rechazo que el usuario puede reformular; una respuesta legítima bloqueada en la salida produce una consulta que el sistema procesó, cuyo costo de inferencia ya se pagó, y cuya respuesta correcta el usuario no recibe. El sistema aparenta ser incapaz de responder aquello que en realidad respondió bien.

El ajuste de este umbral es, en consecuencia, el que exhibe la tensión más aguda entre seguridad y usabilidad de todo el marco. Un umbral estricto bloquea las fugas y también las respuestas correctas que se le parecen; uno permisivo preserva la usabilidad al costo de dejar pasar contenido sensible cuya expresión no alcanza el corte.

Guía de implementación

El ajuste debe fundarse en las tasas de error medidas sobre un conjunto de consultas legítimas de control, cuyas respuestas correctas se conocen. Sin ese conjunto, un bloqueo de salida es indistinguible de una detección correcta, y la tasa de falsos positivos no es calculable.

La asimetría de costos entre las dos clases de error debe declararse explícitamente. Una organización cuyo corpus contiene datos personales bajo régimen normativo puede aceptar una tasa de falsos positivos elevada; una cuyo corpus es de acceso público difícilmente lo justifique. La decisión es de la organización y debe estar documentada, no incrustada en un valor por defecto.

Controles relacionados

C19 y C20 (escáneres de salida), cuyos umbrales este control ajusta; C42 (medición de la tasa

de supresión), que provee la evidencia; C33 (ajuste dinámico de los umbrales de entrada), del que este control es la contraparte en D3.

C.4.5 C42: Medición de la tasa de supresión de contenido confidencial

Nivel	N4	**Evidencia**	Declarativo
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM07:2025

Propósito

Medir y reportar la proporción de respuestas suprimidas por los escáneres de salida, desglosada por escáner y por categoría de ataque.

Justificación

El desglose por escáner revela cuál de los dos mecanismos de salida está haciendo el trabajo. Un sistema en que la totalidad de las supresiones proviene del escáner determinista opera con un escáner semántico que no aporta cobertura, sea porque el umbral es demasiado permisivo, sea porque el contenido sensible del dominio no exhibe la forma que reconoce. Ambas condiciones exigen respuesta, y ninguna es visible en una tasa agregada.

El desglose por categoría de ataque revela la asimetría defensiva. Un sistema puede suprimir eficazmente el contenido que las pruebas de exfiltración directa producen, y no suprimir nada ante las pruebas de extracción del prompt del sistema. La tasa agregada oculta esa brecha; el reporte segmentado la expone.

Guía de implementación

La medición se calcula sobre los registros que C23 produce, agregando los eventos de bloqueo de salida por el escáner que los originó y por la categoría de la prueba que los provocó.

El reporte debe consignar el número de supresiones y la tasa relativa al total de respuestas generadas, no solo el número absoluto. Un aumento en el número de supresiones puede responder a un aumento del tráfico y no a una degradación de la seguridad.

Debe incluirse la tasa de falsos positivos, medida sobre el conjunto de consultas legítimas de control. Un reporte de supresiones sin esa cifra no permite evaluar el costo de la defensa.

Controles relacionados

C23 (registro de decisiones de bloqueo), cuyos eventos este control agrega; C41 (ajuste dinámico de los umbrales de sanitización), que consume las tasas que este control produce; C34 (medición de la tasa de rechazo en la entrada), del que este control es la contraparte en D3.

C.4.6 C43: Actualización de los patrones de detección en la salida

Nivel	N5	**Evidencia**	Declarativo
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM07:2025

Propósito

Revisar y actualizar los patrones deterministas y el modelo de detección semántica de la salida, ante la documentación de nuevas técnicas de exfiltración.

Justificación

Las técnicas de exfiltración evolucionan, y su evolución se dirige precisamente contra los controles que las bloquean. Una técnica que codifica el contenido sensible antes de emitirlo, o que lo fragmenta a lo largo de varias respuestas, o que lo expresa en un formato que el escáner no reconoce, evade una configuración que era eficaz contra la generación anterior de ataques.

Este control es la contraparte de C35 en la etapa de salida, y comparte con él la lógica del nivel N5: la capa defensiva deja de ser un artefacto estático y se somete a un ciclo de actualización que responde a la evolución de la amenaza y no a los incidentes ya ocurridos.

Guía de implementación

El ciclo de revisión debe tener una periodicidad declarada y fuentes de vigilancia identificadas. La revisión debe cubrir tanto los patrones deterministas, cuya actualización es directa, como el modelo de detección semántica, cuya actualización exige la sustitución o el reentrenamiento del componente.

Toda actualización debe someterse a la auditoría ofensiva antes de su despliegue. Una ampliación del conjunto de patrones puede elevar la tasa de falsos positivos sobre respuestas legítimas, y esa consecuencia debe medirse antes de que el sistema entre en operación con la nueva configuración.

Controles relacionados

C35 (actualización de los patrones de detección en la entrada), del que este control es la contraparte; C44 (incorporación de retroalimentación de incidentes), con el que comparte el ciclo de mejora; C29 (plan de pruebas ofensivas previo al despliegue).

C.4.7 C44: Incorporación de retroalimentación de incidentes a los patrones

Nivel	N5	**Evidencia**	Declarativo
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM07:2025

Propósito

Incorporar al conjunto de patrones de detección de la salida las construcciones que produjeron fugas efectivas en incidentes reales.

Justificación

Un incidente de exfiltración acredita que una construcción específica atravesó la totalidad de la capa defensiva. Esa construcción es, por definición, el ejemplo más valioso de que la organización dispone: no es una técnica hipotética documentada en la literatura, sino una que funcionó contra su configuración, su corpus y su modelo.

Este control se distingue de C43 en la fuente. C43 responde a la vigilancia externa de amenazas; C44 responde a la evidencia interna de fallas. Un sistema que aplica solo el primero se actualiza contra los ataques que otros sufrieron; uno que aplica ambos se actualiza también contra los que sufrió él mismo.

La distinción es lo que separa la mejora continua de la mera actualización. El nivel N5 exige que el ciclo se cierre: el incidente produce evidencia, la evidencia produce una actualización del control, y la actualización se verifica contra el incidente que la motivó.

Guía de implementación

El proceso debe estar formalizado: todo incidente de exfiltración debe producir un análisis de la construcción que lo permitió, una propuesta de actualización del control correspondiente y una verificación de que la actualización bloquea el vector original.

La verificación debe extenderse a las variantes de la construcción y no solo a la construcción exacta. Un patrón que bloquea el payload literal del incidente y no sus reformulaciones equivalentes cierra el caso sin cerrar la brecha.

El registro del incidente, del análisis y de la actualización aplicada constituye el artefacto que la auditoría documental inspecciona.

Controles relacionados

C43 (actualización ante nuevas técnicas documentadas), con el que comparte el destino pero no la fuente; C46 (incorporación de retroalimentación al sistema de alertas), que es el equivalente en D4; C59 (incorporación de lecciones aprendidas al ciclo de gobernanza).

C.5 D4: Monitoreo y trazabilidad

Los controles de esta sección registran, alertan y auditan los eventos de seguridad que las subdimensiones anteriores generan. Su naturaleza es observacional: no intervienen sobre el flujo de inferencia sino que lo documentan. D4 no define controles de nivel N1, por la razón que la sección 3.5 establece.

C.5.1 C26: Política documentada de umbrales de detección y bloqueo

Nivel	N2	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663

Propósito

Definir y documentar, con anterioridad a la operación del sistema, los umbrales que cada escáner aplicará y el criterio que justifica cada valor.

Justificación

Un umbral fijado después de conocer los resultados de la auditoría incorpora un sesgo que invalida la medición. El evaluador que observa que el sistema bloquea el noventa por ciento de los ataques con un umbral determinado, y ajusta ese umbral hasta alcanzar una cifra más favorable, no está midiendo la efectividad del sistema: está eligiendo la cifra que quiere reportar. El resultado no es reproducible ni comparable, y no acredita nada sobre la postura de seguridad.

La declaración previa es lo que convierte la medición en evidencia. Un umbral documentado antes de la operación es un compromiso contrastable: el sistema opera con el valor declarado y la auditoría mide lo que ese valor produce, sin que el criterio pueda acomodarse a los datos.

La Ley 21.663 exige evidencia técnica cuantificable sobre la gestión del riesgo. Una cifra obtenida con un criterio ajustado a posteriori no satisface esa exigencia, con independencia de cuán favorable sea.

Guía de implementación

La política debe consignar, para cada escáner, el umbral aplicado, la evidencia sobre la que se derivó, la fecha de su fijación y el responsable de la decisión. Un umbral declarado sin justificación documenta el valor pero no el criterio, y no permite evaluar si el compromiso entre seguridad y usabilidad que representa es el que la organización quería asumir.

La política debe versionarse. Los ajustes que C33, C38 y C41 introducen en niveles superiores modifican los umbrales, y la trazabilidad de esos cambios exige que cada versión de la política registre qué valor estuvo vigente y durante cuánto tiempo.

Controles relacionados

C03, C11, C17, C19 y C20 (escáneres con umbral configurable), cuyos valores esta política declara; C21 (externalización de la configuración), que establece que esos valores residan en artefactos inspeccionables; C33, C38 y C41 (ajustes dinámicos), que actualizan la política que este control establece.

C.5.2 C27: Procedimiento de notificación de incidentes ante la autoridad

Nivel	N2	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663

Propósito

Establecer el procedimiento formal mediante el cual la organización notifica a las autoridades competentes los incidentes de seguridad que afecten al sistema RAG.

Justificación

La Ley 21.663 impone a los sujetos obligados el deber de notificar los incidentes de ciberseguridad, con plazos y contenidos determinados. El cumplimiento de ese deber no admite improvisación: un procedimiento inexistente al momento del incidente produce una notificación tardía, incompleta o dirigida al destinatario equivocado, y el incumplimiento es imputable con independencia de que el incidente mismo no lo fuera.

La razón por la que este control es de nivel N2, y no de un nivel superior, es que la obligación existe desde el momento en que el sistema entra en operación. No es una capacidad avanzada que la organización adquiera al madurar: es una condición de licitud de la operación.

Un sistema RAG plantea, además, una dificultad de calificación que el procedimiento debe resolver por anticipado. No toda respuesta que expone contenido sensible constituye un incidente notificable, y la determinación exige un criterio establecido antes de que el caso se presente.

Guía de implementación

El procedimiento debe identificar la autoridad competente, el plazo de notificación aplicable, el contenido exigido y el rol responsable de ejecutarla, conforme a la matriz que C50 instancia.

Debe establecer el criterio de calificación de un evento como incidente notificable, distinguiéndolo de los eventos de seguridad que el sistema registra en su operación normal. Un bloqueo de salida no es un incidente; una fuga efectiva de datos personales del corpus probablemente lo sea. El criterio debe ser explícito y no depender del juicio de quien detecte el evento.

El procedimiento debe ejercitarse. Una notificación que nunca se ha ensayado se ejecuta por primera vez bajo la presión de un incidente real, que es la peor condición posible para descubrir que el destinatario cambió o que el formato exigido es otro.

Controles relacionados

C47 (designación del responsable de seguridad), que es el rol que ejecuta la notificación; C23 (registro de decisiones de bloqueo), cuyos eventos alimentan la calificación; C55 (comunicación de riesgos residuales a la dirección).

C.5.3 C28: Política de retención y eliminación de datos de sesión

Nivel	N2	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.719

Propósito

Definir el plazo durante el cual los registros de sesión se conservan, el criterio que lo justifica y el procedimiento mediante el cual se eliminan al vencer.

Justificación

Los controles de registro que este marco exige producen un artefacto que la organización no siempre reconoce como tal: un repositorio de las consultas que los usuarios formularon. Ese

repositorio contiene datos personales, tanto por lo que las consultas dicen de quien las formula como por lo que pueden contener en su texto.

La tensión es directa. La trazabilidad que la seguridad exige empuja hacia la conservación indefinida de los registros; el principio de limitación temporal que la Ley 21.719 establece empuja hacia su eliminación. Un sistema que aplica rigurosamente los controles de registro sin una política de retención construye, sin proponérselo, la base de datos personales cuya existencia la norma restringe.

Este control resuelve la tensión mediante un plazo declarado. No elimina el conflicto, pero lo convierte en una decisión documentada que la organización asume, en lugar de una omisión que la expone.

Guía de implementación

La política debe declarar el plazo de retención de cada clase de registro y el criterio que lo justifica: la finalidad para la que el dato se conserva y el tiempo durante el cual esa finalidad subsiste. Un plazo declarado sin finalidad es un plazo arbitrario, que la norma no admite.

La eliminación debe ser efectiva y verificable. Un procedimiento que marca los registros como eliminados sin removerlos del soporte no satisface el control, y la verificación debe alcanzar a las copias de respaldo, que con frecuencia conservan lo que el sistema en producción ya eliminó.

Los registros de latencia que C25 produce y los de acceso que C22 exige contienen datos de distinta naturaleza y pueden justificar plazos distintos. La política debe distinguirlos en lugar de aplicar un plazo único.

Controles relacionados

C25 (registro de latencia y metadatos), cuyos artefactos esta política gobierna; C52 (inventario de datos personales procesados), que debe incluir los registros de sesión; C22 (registro de acceso por sesión).

C.5.4 C23: Registro de las decisiones de bloqueo

Nivel	N3	**Evidencia**	Experimental
Tipo	Detectivo	**Fuente**	LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

Propósito

Registrar cada decisión de bloqueo producida en la entrada o en la salida, identificando el componente que la originó y la etapa del flujo en que se produjo.

Justificación

Este control es la contraparte de C31 en D4, y su alcance es más amplio: mientras aquel cubre los rechazos de la etapa de entrada, este cubre la totalidad de las decisiones de bloqueo del flujo, incluidas las de salida.

Su función no es meramente documental. Un sistema con múltiples escáneres operando en distintas etapas produce bloqueos cuya atribución no es evidente: una solicitud rechazada pudo serlo por el límite de longitud, por el escáner de inyección, por el filtro de dominio o por el de coherencia. Sin registro atribuible, el operador observa una tasa de rechazo y no puede descomponerla.

La atribución es, además, la condición sobre la que descansa la totalidad de las métricas de nivel N4. La tasa de rechazo por categoría que C34 mide, y la tasa de supresión por escáner que C42 mide, se calculan sobre los registros que este control produce. Un sistema que no los produce no puede alcanzar el nivel de gestión cuantitativa, con independencia de qué controles adicionales implemente.

Guía de implementación

El registro debe consignar el identificador de la solicitud, el componente que originó el bloqueo, la etapa del flujo, la marca temporal y, cuando el componente opere con umbral, la puntuación que motivó la decisión.

La puntuación es esencial y con frecuencia se omite. Un registro que consigna únicamente la decisión permite contar bloqueos; uno que consigna la puntuación permite observar la distribución de las solicitudes respecto del umbral, y por tanto evaluar si el corte está bien situado. Sin ella, los ajustes de nivel N4 operan a ciegas.

El registro debe producirse en un formato estructurado y no como texto libre, dado que su destino es la agregación por categoría.

Controles relacionados

C31 (registro del motivo de bloqueo en la entrada), del que este control es la extensión al flujo completo; C34 y C42 (métricas de nivel N4), que se calculan sobre estos registros; C25 (registro de latencia y metadatos), con el que comparte el artefacto de destino.

C.5.5 C25: Registro de latencia y metadatos de las solicitudes

Nivel	N3	**Evidencia**	Experimental
Tipo	Detectivo	**Fuente**	LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

Propósito

Registrar la latencia y los metadatos de cada solicitud procesada, en un formato que permita el análisis posterior del comportamiento del flujo de inferencia.

Justificación

La latencia es un canal de información que la seguridad tiende a ignorar. Un flujo cuyo tiempo de respuesta se aparta sistemáticamente de su distribución habitual está procesando algo distinto de lo habitual: entradas de longitud anómala, consultas que activan escáneres que normalmente no se activan, o volúmenes de recuperación superiores a los previstos.

La detección de esas condiciones no requiere inspeccionar el contenido de las solicitudes. La forma de la distribución de latencias las revela, y lo hace con independencia de que el contenido esté cifrado, ofuscado o codificado.

Este control tiene, además, una función que el marco explicita en su capítulo de métricas: la Latencia Agregada de Seguridad, que cuantifica el costo operacional de la capa defensiva, se calcula sobre los registros que este control produce. Sin ellos, la organización implementa controles cuyo costo en usabilidad no puede medir, y por tanto no puede justificar ante quien lo padece.

Guía de implementación

El registro debe consignar, para cada solicitud, la latencia total y la de cada etapa que el flujo atraviesa, de modo que el costo pueda atribuirse a los componentes que lo producen. Una latencia total sin desglose acredita que el sistema es lento pero no permite determinar qué lo hace lento.

Debe consignar asimismo el identificador de la versión del corpus vigente, que C62 registra, para permitir la correlación entre una respuesta y el estado del corpus que la produjo.

El artefacto de destino debe ser persistente y estructurado, y su retención debe someterse a la política que C28 establece: los registros de solicitud contienen datos personales.

Controles relacionados

C23 (registro de decisiones de bloqueo), con el que comparte el artefacto de destino; C62 (registro versionado del corpus), cuya versión este registro consigna; C28 (política de retención), que gobierna la conservación de estos registros; C24 (monitoreo de patrones anómalos), que opera sobre ellos.

C.5.6 C29: Plan de pruebas de seguridad ofensiva previo al despliegue

Nivel	N3	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663

Propósito

Documentar y ejecutar, con anterioridad a cada despliegue del sistema, un plan de pruebas de seguridad ofensiva que verifique la eficacia de los controles implementados.

Justificación

Los controles de fuente de evidencia experimental no se acreditan por inspección. Su presencia en el código es constatable; su eficacia no. Un escáner correctamente desplegado con un umbral mal calibrado, o un filtro que no alcanza a los fragmentos cuyo metadato falta, exhiben una configuración impecable y una protección inexistente.

La auditoría ofensiva es el único mecanismo que convierte la implementación declarada en efectividad medida. Es, además, lo que distingue este marco de un cuestionario de cumplimiento: la exigencia de que los controles se prueben contra ataques reales y no se den por implementados porque el código los contiene.

La condición de que el plan preceda a cada despliegue, y no que se ejecute periódicamente, responde a que un cambio en el sistema puede degradar la eficacia de un control sin modificarlo. Una actualización del modelo base altera la respuesta a las mismas instrucciones adversariales; una reindexación del corpus altera la cobertura del filtro de sensibilidad. En ambos casos el control permanece idéntico y su eficacia cambia.

Guía de implementación

El plan debe cubrir la totalidad de los vectores de amenaza que el marco declara, y ejecutar sobre cada uno un conjunto de pruebas cuya composición esté documentada y sea reproducible entre despliegues. Una auditoría cuya composición varía no permite comparar resultados y no detecta degradación.

Debe incluir un conjunto de consultas legítimas de control, ejecutadas bajo las mismas condiciones. Sin él, las pruebas miden la tasa de bloqueo pero no la tasa de falsos positivos, y una configuración que bloquea todo aparece como perfectamente segura.

El criterio de aceptación debe declararse antes de ejecutar el plan. Un despliegue cuyos resultados se evalúan sin criterio previo se aprueba siempre, porque el criterio se construye para admitir el resultado obtenido.

Controles relacionados

C26 (política de umbrales), cuyos valores esta auditoría pone a prueba; C35, C36, C43 y C39 (actualizaciones de nivel N5), cuyo despliegue este plan debe verificar; C60 (evaluación formal de riesgos), que consume los resultados de esta auditoría.

C.5.7 C24: Monitoreo de patrones de consulta anómalos

Nivel	N4	**Evidencia**	Experimental
Tipo	Detectivo	**Fuente**	LLM02:2025, LLM08:2025

Propósito

Detectar, mediante el análisis del comportamiento de una sesión a lo largo del tiempo, los patrones de consulta que sugieren reconocimiento o extracción sistemática del corpus.

Justificación

Los controles de las subdimensiones anteriores evalúan cada solicitud de forma aislada. Esa evaluación es ciega a la clase de ataque cuya firma no está en ninguna consulta individual sino en la secuencia: un atacante que formula cien consultas legítimas, cada una de las cuales el sistema responde correctamente, y que reconstruye el corpus a partir de la unión de las respuestas.

Ninguna de esas consultas activa un escáner. Todas son coherentes, todas pertenecen al dominio, todas obtienen respuestas fundamentadas en el contexto recuperado. El ataque es invisible en el eje de la solicitud individual y evidente en el eje temporal: una sesión que barre sistemáticamente el espacio semántico del corpus exhibe un comportamiento que ninguna consulta legítima produce.

Este control es de nivel N4 porque su implementación exige la capacidad analítica que los niveles inferiores no requieren: no basta con registrar, hay que correlacionar los registros a lo largo de las sesiones y establecer qué constituye un comportamiento anómalo respecto de una línea base de comportamiento normal.

Guía de implementación

El análisis debe operar sobre los registros que C25 y C22 producen, correlacionando las consultas por sesión y evaluando su distribución en el espacio semántico del corpus. La señal de reconocimiento es la cobertura: una sesión cuyas consultas se distribuyen uniformemente sobre el corpus, en lugar de concentrarse en la vecindad de un tema, exhibe el comportamiento de un barrido y no el de una consulta.

La detección exige una línea base de comportamiento normal, construida sobre el tráfico legítimo del sistema. Un umbral fijado sin esa línea base produce alertas sobre usuarios que simplemente consultan mucho.

La correlación por sesión presupone que las sesiones son identificables, condición que C22 establece. Un sistema sin control de acceso por sesión no puede atribuir un conjunto de consultas a un mismo actor, y este control opera sobre una agregación que no distingue a un atacante de la suma de sus usuarios legítimos.

Controles relacionados

C22 (control de acceso por sesión), que es la condición previa para la atribución; C25 (registro de latencia y metadatos), que provee los datos; C12 (detección de reconocimiento en la consulta individual), cuya cobertura este control extiende al eje temporal.

C.5.8 C45: Actualización de los patrones de detección de anomalías

Nivel	N5	**Evidencia**	Declarativo
Tipo	Detectivo	**Fuente**	LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

Propósito

Revisar y actualizar los criterios de detección de comportamiento anómalo ante la documentación de nuevas técnicas de reconocimiento y extracción.

Justificación

Los patrones de comportamiento anómalo que un sistema reconoce son los que se documentaron hasta el momento de su configuración. Una técnica de extracción que distribuye las consultas entre múltiples sesiones, que las espacia en el tiempo para no exceder los umbrales de frecuencia, o que las intercala con tráfico legítimo, evade una detección calibrada contra el barrido concentrado.

La línea base de comportamiento normal, además, se desplaza. El tráfico legítimo de un sistema cambia a medida que cambian sus usuarios y sus casos de uso, y un criterio de anomalía

calibrado contra una línea base antigua produce falsos positivos crecientes sobre un comportamiento que se volvió habitual.

Este control atiende ambas derivas: la de la amenaza y la del tráfico legítimo.

Guía de implementación

El ciclo de revisión debe recalibrar la línea base de comportamiento normal sobre el tráfico reciente, y no solo incorporar los nuevos patrones de amenaza. Una actualización que agrega criterios de detección sin actualizar la referencia contra la que se contrastan eleva la tasa de falsos positivos sin mejorar la cobertura.

Toda actualización debe verificarse sobre los registros históricos: un criterio nuevo debe reconocer los incidentes pasados que el criterio anterior no reconoció, y no debe alertar sobre las sesiones legítimas que el histórico contiene.

Controles relacionados

C24 (monitoreo de patrones anómalos), cuyos criterios este control actualiza; C35 y C43 (actualización de los patrones de detección en entrada y salida), con los que comparte el ciclo de vigilancia; C46 (incorporación de retroalimentación al sistema de alertas).

C.5.9 C46: Incorporación de retroalimentación de incidentes al sistema de alertas

Nivel	N5	**Evidencia**	Declarativo
Tipo	Correctivo	**Fuente**	LLM01:2025, LLM02:2025, LLM07:2025, LLM08:2025

Propósito

Incorporar de forma sistemática y periódica al sistema de alertas los criterios derivados de los incidentes efectivamente ocurridos.

Justificación

Un incidente que el sistema de monitoreo no alertó es una falla del monitoreo, con independencia de que los controles preventivos lo hayan permitido. La distinción importa: un ataque que atraviesa la capa defensiva y además pasa inadvertido es cualitativamente peor que uno que la atraviesa y se detecta, porque el segundo admite respuesta y el primero no.

Este control cierra el ciclo del nivel N5 en D4. C45 actualiza los criterios de detección contra las amenazas documentadas externamente; C46 los actualiza contra las que la organización padeció. La diferencia es que estas últimas están acreditadas: se sabe que funcionaron contra esta configuración, este corpus y este modelo.

El control es correctivo y no detectivo, a diferencia de los demás de su subdimensión, porque su objeto no es detectar sino reparar la capacidad de detección que el incidente demostró insuficiente.

Guía de implementación

Todo incidente debe producir un análisis retrospectivo que determine si el sistema de monitoreo lo señaló, y en caso negativo, qué criterio lo habría señalado. Ese criterio es el que la actualización incorpora.

La verificación de la actualización debe realizarse contra los registros históricos que contienen el incidente: el criterio nuevo debe alertar sobre él. Una actualización que no se contrasta contra el caso que la motivó no acredita haber cerrado la brecha.

La periodicidad debe declararse. Un proceso que se ejecuta únicamente cuando ocurre un incidente deja de operar durante los períodos sin incidentes, que son precisamente aquellos en que la línea base debe recalibrarse.

Controles relacionados

C44 (incorporación de retroalimentación a los patrones de sanitización), del que este control es el equivalente en D4; C45 (actualización de los patrones de detección de anomalías), con el que comparte el destino; C59 (incorporación de lecciones aprendidas al ciclo de gobernanza), que es su correlato organizacional.

C.6 D5: Gobernanza organizacional

Los controles de esta sección capturan las obligaciones institucionales que sustentan la operación segura del sistema RAG. Su verificación es exclusivamente declarativa, conforme a lo establecido en la sección 2.6. Ninguno de ellos produce traza observable en el flujo de inferencia: su cumplimiento se acredita mediante los artefactos documentales que cada ficha identifica.

C.6.1 C47: Designación del responsable de la seguridad del sistema

Nivel	N1	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663

Propósito

Designar formalmente a una persona o cargo como responsable de la seguridad del sistema RAG, con atribuciones documentadas.

Justificación

Un sistema sin responsable designado es un sistema cuya seguridad es responsabilidad de todos, condición que en la práctica significa que no lo es de nadie. Los controles de este marco exigen decisiones: qué umbral fijar, cuándo notificar un incidente, si un despliegue puede proceder tras los resultados de la auditoría. Ninguna de esas decisiones se toma sola.

La Ley 21.663 exige la designación como condición del régimen de deberes que impone. La obligación de notificar un incidente presupone un sujeto obligado a hacerlo; la de mantener un inventario de activos presupone un sujeto que responda por su vigencia.

Este control es de nivel N1 porque su ausencia bloquea el resto de la subdimensión. La totalidad de los controles de D5 asigna responsabilidades, y todas ellas convergen en el rol que este control establece.

Guía de implementación

La designación debe constar en un acto formal de la organización, con identificación del cargo, sus atribuciones y la fecha. Las atribuciones deben incluir, como mínimo, la potestad de suspender un despliegue cuya auditoría no satisfizo el criterio de aceptación.

Una designación sin esa potestad produce un responsable que responde por decisiones que no puede tomar. Es el modo más frecuente en que este control se implementa nominalmente y se incumple en sustancia.

Controles relacionados

C50 (instanciación de la matriz RACI), donde este rol se articula con los demás; C27 (procedimiento de notificación), que este rol ejecuta; C29 (plan de pruebas ofensivas), cuya aprobación este rol otorga.

C.6.2 C48: Declaración del sistema RAG como activo de información

Nivel	N1	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663

Propósito

Declarar formalmente el sistema RAG como activo de información sujeto a las obligaciones de la normativa vigente.

Justificación

Un sistema que la organización no ha declarado como activo de información queda fuera de su marco de gestión de riesgos. No aparece en el inventario, no se le asigna responsable, no se le aplican las políticas de seguridad, y las obligaciones que la normativa impone sobre los activos de información no se le atribuyen.

Esa omisión es más frecuente de lo que parece en los sistemas basados en modelos de lenguaje. La organización que despliega un asistente sobre su documentación tiende a percibirlo como una herramienta de productividad y no como un sistema que procesa, indexa y expone su corpus documental. La percepción es errada: el sistema RAG es precisamente un mecanismo de acceso a información, y su superficie de exposición es el corpus completo.

La declaración es el acto que incorpora el sistema al marco de gestión. Sin ella, los controles de este marco pueden implementarse técnicamente y carecer de todo respaldo institucional.

Guía de implementación

La declaración debe consignar la finalidad del sistema, el corpus que indexa, la clasificación de sensibilidad de ese corpus y las obligaciones normativas que le resultan aplicables.

La clasificación del corpus es el elemento crítico. Un sistema RAG hereda la clasificación del contenido más sensible que indexa, no la del promedio: un corpus mayoritariamente público que contiene un subconjunto reservado es, a efectos de la declaración, un sistema que procesa información reservada.

Controles relacionados

C61 (inventario de activos), que materializa esta declaración en un registro; C52 (inventario de datos personales), que la complementa cuando el corpus los contiene; C57 (clasificación del sistema por criticidad).

C.6.3 C49: Política de uso aceptable del sistema

Nivel	N1	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.719

Propósito

Establecer una política de uso aceptable del sistema RAG, accesible a la totalidad de sus usuarios, que declare los usos autorizados y los prohibidos.

Justificación

Los controles técnicos de este marco bloquean lo que reconocen. Un usuario que formula una consulta inapropiada pero no adversarial, que introduce datos personales de terceros en el texto de su pregunta, o que emplea el sistema para un fin ajeno a su propósito, no activa ningún escáner: su conducta no es un ataque, es un uso indebido.

La política es el único mecanismo que gobierna esa clase de conducta. Establece el marco de lo autorizado y, al hacerlo, convierte el uso indebido en un incumplimiento imputable en lugar de una zona gris.

La Ley 21.719 exige que el tratamiento de datos personales se realice para finalidades determinadas y comunicadas. Un sistema cuyos usuarios ingresan datos personales en sus consultas, sin que exista política que lo regule, realiza un tratamiento cuya finalidad nadie declaró.

Guía de implementación

La política debe declarar explícitamente la prohibición de introducir datos personales de terceros en las consultas, cuando el sistema no esté destinado a procesarlos, y advertir que las consultas se registran conforme a la política de retención que C28 establece.

La accesibilidad es parte del control y no un accesorio. Una política que existe en un repositorio que los usuarios no consultan no gobierna nada. Debe presentarse en el punto de uso.

Controles relacionados

C28 (política de retención de datos de sesión), cuyo contenido esta política debe comunicar; C52 (inventario de datos personales); C51 (procedimiento de gestión de accesos).

C.6.4 C61: Inventario de activos del sistema RAG

Nivel	N1	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663

Propósito

Mantener un inventario actualizado de los activos que integran el sistema RAG: el modelo de inferencia y su versión, el corpus y su versión, la base vectorial y su configuración, y los componentes de la capa defensiva con sus umbrales activos.

Justificación

Los controles de verificación de integridad de este marco, tanto sobre el modelo como sobre el corpus y el prompt del sistema, operan sobre componentes que deben estar formalmente identificados. Sin inventario, esos controles verifican elementos cuya identidad no fue declarada: no es posible afirmar que se verificó el modelo correcto si no está registrado qué modelo debía estar en ejecución.

El inventario materializa la declaración que C48 establece. Aquella declara que el sistema es un activo; este identifica de qué está hecho.

Su función se manifiesta con claridad ante un incidente. La investigación exige saber qué modelo estaba desplegado, qué versión del corpus estaba indexada y con qué umbrales operaban los escáneres. Un sistema sin inventario obliga a reconstruir esa información desde el estado actual, que ya no es el que produjo el incidente.

Guía de implementación

El inventario debe registrar, como mínimo, los cinco activos que la sección 2.1 define, con los atributos que permitan identificar unívocamente la instancia desplegada de cada uno.

Debe actualizarse ante todo cambio en la versión del modelo, la composición del corpus o la configuración de la capa defensiva. Un inventario que se actualiza periódicamente y no ante los cambios documenta un estado que ya no existe.

Su formato no está prescrito. Admite desde un registro documental hasta un inventario derivado automáticamente de la configuración del despliegue, siendo esta última la forma que mejor garantiza su vigencia.

Controles relacionados

C48 (declaración del sistema como activo), que este inventario materializa; C30 (verificación de procedencia del modelo) y C62 (registro versionado del corpus), que son sus componentes técnicos; C26 (política de umbrales), cuyos valores el inventario consigna.

C.6.5 C50: Instanciación de la matriz RACI

Nivel	N2	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.663

Propósito

Adoptar la matriz RACI que el marco define, asignando cada rol genérico a las personas o cargos concretos de la organización.

Justificación

La matriz que este marco provee define roles genéricos: responsable de seguridad, operador técnico, propietario del corpus, dirección y cumplimiento. Esos roles son funciones, no personas, y su valor es nulo mientras no se les atribuya un sujeto.

La instanciación es la condición que hace auditables los controles de D5. Una actividad cuya responsabilidad recae sobre el rol de propietario del corpus, en una organización que no ha designado a nadie como tal, es una actividad sin responsable, con independencia de que la matriz la asigne.

Este control es, en consecuencia, el que convierte el resto de D5 de un catálogo de buenas intenciones en un conjunto de obligaciones exigibles.

Guía de implementación

La asignación debe recaer sobre cargos y no sobre personas, para que sobreviva a la rotación del personal. Una matriz instanciada con nombres propios se vuelve obsoleta ante la primera renuncia.

Un mismo cargo puede asumir más de un rol en organizaciones pequeñas, condición admisible salvo en un caso: el rol que ejecuta una actividad y el que rinde cuentas por ella no deben coincidir cuando la actividad es la aprobación de un despliegue o la calificación de un incidente. Esa coincidencia elimina la supervisión que la matriz busca establecer.

Controles relacionados

C47 (designación del responsable de seguridad), que es el primero de los roles a instanciar; C53 (programa de capacitación), dirigido a los roles que esta matriz define; la totalidad de los controles de D5, cuyas responsabilidades esta matriz distribuye.

C.6.6 C51: Procedimiento de gestión de accesos

Nivel	N2	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.719

Propósito

Establecer el procedimiento formal que regula las altas, bajas y modificaciones de los permisos de acceso al sistema RAG y a su corpus.

Justificación

El control técnico de acceso por sesión, que C22 establece, determina qué puede consultar cada sesión según las autorizaciones que se le atribuyen. De dónde provienen esas autorizaciones, quién las otorga y cuándo se revocan es lo que este control gobierna.

Un sistema con control de acceso técnicamente impecable y sin procedimiento de gestión acumula autorizaciones que nadie revoca. El usuario que cambió de función conserva el acceso a un corpus que ya no le corresponde; el que dejó la organización conserva credenciales activas. La falla no está en el mecanismo sino en el proceso que lo alimenta.

La Ley 21.719 exige que el acceso a los datos personales se limite a quienes lo requieran para la finalidad declarada. Un acceso que subsiste tras extinguirse la finalidad que lo justificaba constituye un tratamiento sin fundamento.

Guía de implementación

El procedimiento debe declarar quién autoriza el acceso, sobre qué criterio, y qué eventos disparan su revisión o revocación: el cambio de función, el término de la relación laboral, y la reclasificación del corpus que el usuario consulta.

Debe establecer una revisión periódica de los accesos vigentes, cuyo resultado se documente. La revocación por evento captura los cambios que la organización registra; la revisión periódica captura los que se le pasaron.

Controles relacionados

C22 (control de acceso por sesión al vector store), que es el mecanismo que este procedimiento alimenta; C08 (clasificación por sensibilidad), cuya política determina qué autorizaciones son necesarias; C52 (inventario de datos personales).

C.6.7 C52: Inventario de datos personales procesados

Nivel	N2	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Ley 21.719

Propósito

Documentar el inventario de los datos personales que el sistema RAG procesa, conforme a las obligaciones del responsable de tratamiento.

Justificación

Un sistema RAG procesa datos personales por dos canales que la organización tiende a evaluar de forma desigual. El primero es el corpus: los documentos indexados pueden contener nombres, identificadores y circunstancias personales, y el sistema los expone en sus respuestas. El segundo son los registros de sesión, que los controles de este marco exigen producir y que documentan qué consultó cada usuario.

El segundo canal es el que se omite. La organización que inventaría el contenido personal de su corpus rara vez inventaría los registros que su propia capa de trazabilidad genera, pese a que estos últimos constituyen un tratamiento tan sujeto a la norma como el primero.

El inventario es la condición previa de la totalidad de las obligaciones que la Ley 21.719 impone. No es posible aplicar el principio de finalidad, ni el de limitación temporal, ni atender un derecho de acceso, sobre datos cuya existencia no está documentada.

Guía de implementación

El inventario debe cubrir ambos canales: el contenido personal del corpus, con su clasificación de sensibilidad, y los registros de sesión que el sistema produce, identificando qué campos de esos registros constituyen datos personales.

Debe consignar, para cada categoría, la finalidad del tratamiento, la base de licitud que lo habilita y el plazo de conservación que C28 establece. Un inventario que enumera los datos sin declarar su finalidad no satisface la obligación.

Controles relacionados

C28 (política de retención), cuyos plazos este inventario consigna; C08 (clasificación del corpus por sensibilidad), que identifica el contenido personal indexado; C49 (política de uso aceptable), que advierte a los usuarios sobre el tratamiento de sus consultas.

C.6.8 C53: Programa de capacitación en seguridad de sistemas LLM

Nivel	N3	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	NIST AI RMF

Propósito

Establecer un programa formal de capacitación en seguridad de sistemas basados en modelos de lenguaje, dirigido a los roles que la matriz RACI define.

Justificación

Los vectores de amenaza que este marco aborda no tienen precedente en la experiencia de seguridad de la mayoría de las organizaciones. Un profesional formado en seguridad de aplicaciones reconoce una inyección de código y no necesariamente una inyección de instrucciones; sabe que la entrada del usuario no es confiable y no necesariamente que el contenido recuperado del propio corpus tampoco lo es.

La consecuencia práctica es que los controles de este marco se implementan sin comprenderse. Un operador que despliega un escáner de inyección sin entender qué evade y qué no lo calibra mal; un propietario de corpus que desconoce el vector de intoxicación no evalúa la procedencia de los documentos que incorpora.

La capacitación es lo que convierte la implementación en competencia. Es, además, la única defensa contra la clase de falla que ningún control técnico cubre: la decisión desinformada de quien opera el sistema.

Guía de implementación

El programa debe diferenciarse por rol. El operador técnico requiere formación en la calibración de umbrales y en la interpretación de los registros; el propietario del corpus, en la clasificación de sensibilidad y en los vectores de intoxicación; la dirección, en la interpretación de las métricas que el marco produce.

El programa debe someterse al mismo ciclo de actualización que los controles técnicos, dado que las técnicas que enseña evolucionan a la misma velocidad que las que los controles bloquean.

Controles relacionados

C50 (instanciación de la matriz RACI), que define los roles a los que este programa se dirige; C58 (revisión proactiva del marco), cuyo ciclo este programa debe seguir; C35, C43 y C45 (actualización de los patrones de detección), cuya ejecución competente este programa habilita.

C.6.9 C54: Ciclo de revisión periódica del marco

Nivel	N3	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	NIST AI RMF

Propósito

Definir y ejecutar un ciclo de revisión del marco LLM-Sec aplicado al sistema, con una frecuencia mínima anual.

Justificación

Una evaluación de madurez es una fotografía. Acredita el estado del sistema en el momento en que se realizó, y su vigencia decae desde entonces: el corpus crece, el modelo se actualiza, los umbrales se ajustan, y el nivel verificado que se reportó deja de corresponder al sistema que está en operación.

La revisión periódica es lo que convierte la evaluación en un instrumento de gestión y no en un certificado. Su ausencia produce el fenómeno más común en los marcos de madurez: una organización que reporta un nivel alcanzado hace tres años sobre un sistema que ya no es el que se evaluó.

La frecuencia mínima anual no responde a un criterio técnico sino a la práctica establecida en los marcos de gestión de riesgos. Un sistema con un ritmo de cambio superior exige un ciclo más frecuente.

Guía de implementación

La revisión debe reejecutar la evaluación completa que el capítulo 6 establece, incluidas las métricas, y no limitarse a constatar que los controles siguen presentes. Un control presente cuya eficacia decayó produce un nivel que ya no corresponde.

Debe disparse además ante los eventos que alteran la eficacia de los controles sin modificarlos: el cambio del modelo base, la reindexación del corpus y la modificación de la política de clasificación.

El resultado debe documentarse y comunicarse conforme a C55, incluso cuando la revisión no arroje cambios: la constatación de que el nivel se mantiene es un resultado tan reportable como su variación.

Controles relacionados

C60 (evaluación formal de riesgos), con la que este ciclo debe coordinarse; C55 (comunicación de riesgos residuales), que reporta los resultados; C29 (plan de pruebas ofensivas), que provee la evidencia experimental de la revisión.

C.6.10 C55: Comunicación de los riesgos residuales a la dirección

Nivel	N3	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	NIST AI RMF

Propósito

Documentar y comunicar formalmente a la dirección de la organización los riesgos que subsisten tras la implementación de los controles.

Justificación

Ningún conjunto de controles elimina el riesgo. El sistema que implementa la totalidad de este marco sigue expuesto: los escáneres operan con umbrales que admiten falsos negativos, la detección semántica depende de un dominio que puede resultarle opaco, y el modelo puede obedecer una instrucción adversarial que ningún control reconoció.

Ese riesgo residual es de la organización, no del equipo técnico. Su aceptación es una decisión de dirección, y solo puede tomarse si la dirección lo conoce. Un equipo que implementa controles y no comunica lo que queda fuera de su alcance ha asumido, por omisión, una decisión que no le corresponde.

La comunicación no es un trámite. Es el acto mediante el cual el riesgo se traslada al nivel en que puede aceptarse, mitigarse con recursos adicionales o transferirse.

Guía de implementación

El informe debe expresar el riesgo en términos que la dirección pueda evaluar: qué información puede exponerse, ante qué clase de ataque y con qué probabilidad estimada, en lugar de enumerar los controles no implementados.

Debe incluir el costo de mitigación de cada riesgo residual, dado que la decisión que la dirección debe tomar es de asignación de recursos y no de aprobación técnica.

La aceptación del riesgo residual debe constar formalmente. Un informe entregado y no respondido no acredita aceptación, y ante un incidente la responsabilidad revierte a quien lo emitió.

Controles relacionados

C60 (evaluación formal de riesgos), que produce el análisis que este control comunica; C56 (métricas de desempeño de la gobernanza), que acompaña el informe; C54 (ciclo de revisión periódica), cuya cadencia este control sigue.

C.6.11 C60: Evaluación formal de riesgos del sistema

Nivel	N3	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	NIST AI RMF

Propósito

Realizar y documentar una evaluación formal de los riesgos del sistema RAG, con frecuencia mínima anual o ante cambios significativos en el modelo o el corpus.

Justificación

La valoración de riesgo que este marco presenta en la sección 2.2 corresponde a un sistema RAG genérico. Es un punto de partida, no un sustituto de la evaluación que cada organización debe realizar sobre su propio despliegue.

Los factores que la alteran son concretos. Un corpus que contiene datos personales bajo régimen normativo eleva el impacto de la exfiltración; un sistema expuesto a usuarios externos eleva la probabilidad de explotación; un modelo desplegado en infraestructura de terceros incorpora activos que la valoración genérica no contempla.

La evaluación propia es, además, lo que determina qué perfil organizacional aplica y por tanto qué nivel objetivo la organización debe alcanzar. Sin ella, la elección del perfil es arbitraria.

Guía de implementación

La evaluación debe emplear las escalas que la sección 2.2 define, y recalcular la probabilidad y el impacto de cada activo según el contexto de despliegue. Adoptar la valoración genérica sin recalcularla no satisface este control.

Debe disparse ante todo cambio significativo, entendiendo por tal la sustitución del modelo, la incorporación de documentos que alteren la clasificación del corpus, y la modificación del perímetro de exposición del sistema.

El resultado debe expresarse como una matriz de riesgo actualizada, cuya comparación con la de la evaluación anterior evidencie la evolución del riesgo.

Controles relacionados

C48 (declaración del sistema como activo), que es su presupuesto; C55 (comunicación de riesgos residuales), que reporta sus resultados; C57 (clasificación por criticidad), que se deriva de esta evaluación; C29 (plan de pruebas ofensivas), que provee evidencia experimental sobre la eficacia de los controles evaluados.

C.6.12 C56: Métricas de desempeño de la gobernanza de seguridad

Nivel	N4	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Proyecto Ley IA

Propósito

Establecer métricas de desempeño de la gobernanza de seguridad del sistema y reportarlas periódicamente a la dirección.

Justificación

Las métricas que el capítulo 5 define cuantifican la postura técnica del sistema. No cuantifican la gobernanza: cuántos de los controles declarativos están efectivamente implementados, con qué latencia se cierran las brechas identificadas, cuántos incidentes se notificaron dentro del plazo, cuántos accesos se revocaron ante los eventos que lo exigían.

Esa segunda dimensión es la que determina si la organización opera el marco o solo lo implementó. Un sistema con excelente tasa de filtrado y un proceso de gobernanza que no cierra brechas exhibe una seguridad que decae desde el momento de su medición.

El nivel N4 se define por la gestión cuantitativa, y este control extiende esa exigencia al plano organizacional: la gobernanza deja de evaluarse por la existencia de sus artefactos y pasa a evaluarse por su desempeño.

Guía de implementación

Las métricas deben incluir, como mínimo, el Porcentaje de Controles Cumplidos calculado sobre los controles declarativos, el tiempo medio de cierre de las brechas identificadas y la tasa de cumplimiento de los plazos que los procedimientos establecen.

El reporte debe dirigirse a la dirección y no al equipo técnico. Su función es habilitar la decisión de asignación de recursos, que es la que resuelve las brechas que la gobernanza no cierra por falta de capacidad.

Controles relacionados

C34 y C42 (métricas técnicas de nivel N4), que este control complementa en el plano organizacional; C55 (comunicación de riesgos residuales), con la que este reporte se coordina; el capítulo 5, cuya métrica de Porcentaje de Controles Cumplidos este control emplea.

C.6.13 C57: Clasificación del sistema por nivel de criticidad

Nivel	N4	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Proyecto Ley IA

Propósito

Implementar un proceso formal de gestión de riesgos de inteligencia artificial que clasifique el sistema RAG según su nivel de criticidad.

Justificación

El proyecto de ley de inteligencia artificial en tramitación establece un régimen de obligaciones diferenciado según el nivel de riesgo del sistema. La clasificación determina qué deberes le resultan aplicables, y es en consecuencia el acto que define el alcance del cumplimiento.

Un sistema RAG puede quedar en categorías muy distintas según su despliegue. El asistente que responde consultas sobre documentación técnica interna no plantea el mismo riesgo que aquel que informa decisiones sobre personas, y el régimen que les corresponde difiere en consecuencia.

Anticipar la clasificación es, además, una decisión de prudencia. Una organización que la realiza antes de que la norma entre en vigor conoce el régimen que le será aplicable y dispone del tiempo para prepararse; una que espera al vencimiento del plazo lo enfrenta con el sistema ya desplegado.

Guía de implementación

La clasificación debe fundarse en la evaluación de riesgos que C60 produce, y debe considerar el uso efectivo del sistema y no solo el declarado: un sistema desplegado para consulta documental cuyos usuarios lo emplean para fundamentar decisiones sobre personas opera en la categoría del uso real.

El proceso debe revisar la clasificación ante cambios en el uso del sistema, en su corpus o en el marco normativo aplicable.

Controles relacionados

C60 (evaluación formal de riesgos), sobre la que esta clasificación se funda; C48 (declaración del sistema como activo); C58 (revisión proactiva del marco ante cambios normativos), que actualiza esta clasificación cuando la norma evoluciona.

C.6.14 C58: Revisión proactiva del marco ante cambios del entorno

Nivel	N5	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Proyecto Ley IA

Propósito

Revisar y actualizar proactivamente la aplicación del marco LLM-Sec ante cambios normativos, la aparición de nuevas amenazas o la modificación del modelo base.

Justificación

El marco que este documento especifica se ancla a un estado del conocimiento y de la normativa. Ambos cambian. Los vectores de amenaza que el OWASP LLM Top 10 reconoce evolucionan con cada revisión; el proyecto de ley de inteligencia artificial se aprobará con un contenido que aún no es definitivo; las técnicas de ataque que hoy no existen serán las que en dos años definan la superficie de exposición.

La distinción entre este control y C54 es la de la iniciativa. C54 establece un ciclo de revisión periódica, que se ejecuta con una cadencia declarada. C58 exige la revisión ante el evento, con independencia de dónde esté el ciclo: una amenaza documentada en el mes posterior a la revisión anual no espera once meses a la siguiente.

El nivel N5 se define por la anticipación. Una organización que solo revisa cuando le toca revisar reacciona; una que revisa cuando el entorno cambia se adelanta.

Guía de implementación

La organización debe identificar las fuentes de vigilancia que dispararán la revisión: las publicaciones normativas, los catálogos de amenazas del área y los avisos del proveedor del modelo.

La revisión debe evaluar si el conjunto de controles del marco sigue siendo suficiente, y no solo si los controles implementados siguen operando. Un vector de amenaza nuevo puede exigir un control que el marco no contempla, y en ese caso la respuesta correcta es extender el marco y no forzar el nuevo riesgo dentro de una categoría existente.

Controles relacionados

C54 (ciclo de revisión periódica), que este control complementa con la revisión ante evento; C35, C40, C43 y C45 (actualizaciones técnicas ante nuevas amenazas), que este control coordina; C57 (clasificación por criticidad), que se revisa ante cambio normativo.

C.6.15 C59: Incorporación de lecciones aprendidas al ciclo de gobernanza

Nivel	N5	**Evidencia**	Declarativo
Tipo	Gobernanza	**Fuente**	Proyecto Ley IA

Propósito

Incorporar las lecciones derivadas de los incidentes de seguridad al ciclo de mejora continua del marco de gobernanza.

Justificación

Un incidente revela más que la falla técnica que lo permitió. Revela también las fallas de gobernanza que la hicieron posible: el umbral que nadie recalibró, la brecha que se identificó y no se cerró, la revisión que se pospuso, el acceso que no se revocó.

Los controles de nivel N5 de las demás subdimensiones incorporan la retroalimentación del incidente a los mecanismos técnicos. Este la incorpora al proceso. La distinción importa porque una organización puede cerrar la brecha técnica que el incidente explotó y conservar intacto el proceso que permitió que esa brecha existiera, con lo que el próximo incidente ocurrirá por una vía distinta y la misma causa.

Este control cierra el ciclo del marco completo. Es el punto en que la evidencia de la falla retorna a la gobernanza que debe prevenirla.

Guía de implementación

El análisis retrospectivo debe alcanzar la cadena de decisiones que precedió al incidente, y no detenerse en el control que falló. Debe determinar si la falla respondió a un control ausente, a uno mal calibrado, a una brecha conocida y no cerrada, o a un proceso que no se ejecutó.

El resultado debe traducirse en modificaciones de los procedimientos, de las periodicidades declaradas o de la asignación de responsabilidades, y no únicamente en la corrección técnica del control que falló.

El registro del análisis y de las modificaciones aplicadas constituye el artefacto que la auditoría documental inspecciona, y es la evidencia de que el ciclo de mejora continua opera.

Controles relacionados

C44 y C46 (incorporación de retroalimentación en D3 y D4), de los que este control es el correlato organizacional; C27 (procedimiento de notificación), cuya ejecución el análisis retrospectivo evalúa; C58 (revisión proactiva del marco), con el que comparte el ciclo de mejora.

Apéndice D

Glosario

Este apéndice define los términos técnicos empleados a lo largo del documento. Las definiciones son operacionales y se acotan al alcance del marco LLM-Sec; no pretenden sustituir las definiciones normativas de las fuentes referenciadas en la sección 1.4.

Auditoría ofensiva
Ejecución controlada de ataques simulados contra un sistema con el objeto de medir su resistencia. En el marco LLM-Sec constituye la fuente de evidencia experimental.

Base de datos vectorial
Sistema de almacenamiento que indexa fragmentos de texto mediante su representación vectorial y permite recuperarlos por similitud semántica. También denominada *vector store*.

Capa defensiva
Conjunto de componentes interpuestos entre el usuario y el modelo de inferencia que aplican controles de validación sobre la entrada y la salida del sistema.

Contexto recuperado
Conjunto de fragmentos seleccionados desde la base vectorial en respuesta a una consulta, que se incorporan al prompt antes de la inferencia.

Control
Medida técnica u organizacional que reduce la probabilidad o el impacto de un riesgo. En el marco LLM-Sec cada control se caracteriza por nivel de madurez, tipo funcional, fuente de evidencia, descripción y fuente normativa.

Corpus de conocimiento
Conjunto de documentos indexados que constituyen la fuente de contexto del sistema RAG.

Embedding
Representación vectorial de un fragmento de texto en un espacio de dimensión fija, utilizada para calcular similitud semántica entre la consulta y los fragmentos indexados.

Escenario
Configuración de seguridad bajo la cual se evalúa el sistema. El marco distingue entre un escenario sin protección activa y un escenario con la capa defensiva habilitada.

Exfiltración
Extracción no autorizada de información sensible desde el corpus indexado o desde el prompt del sistema, mediante consultas diseñadas para inducir su reproducción en la salida del modelo.

Fragmento
Unidad mínima de texto indexada en la base vectorial, resultante de la segmentación de un documento del corpus. También denominado *chunk*.

Fuente de evidencia
Criterio mediante el cual se verifica el cumplimiento de un control. El marco define tres: configuración, experimental y declarativo.

Ground truth
Criterio de referencia que determina si un intento adversarial fue exitoso o resistido. El marco define fuentes de ground truth diferenciadas por vector OWASP (sección 6.1.1).

Inyección de prompt
Técnica adversarial que introduce instrucciones maliciosas en la entrada del sistema con el objeto de alterar el comportamiento del modelo. Corresponde al vector LLM01:2025.

LLM
Modelo de lenguaje de gran escala (*Large Language Model*). Componente de inferencia que genera respuestas en lenguaje natural a partir del prompt recibido.

Nivel declarado
Nivel de madurez asignado mediante lista de chequeo sin evidencia técnica directa, basado en auditoría organizacional o revisión documental. Aplica a la subdimensión D5.

Nivel verificado
Nivel de madurez asignado mediante evidencia experimental o de configuración. Aplica a las subdimensiones D1 a D4.

Perfil organizacional
Categoría que orienta la interpretación del nivel de madurez según el tipo de organización y sus obligaciones regulatorias. El marco define tres: P1 (PYME), P2 (Mediana/Grande) y P3 (Crítica regulada).

Probe
Unidad de prueba adversarial ejecutada por la herramienta de auditoría ofensiva, correspondiente a una técnica de ataque específica dentro de una categoría OWASP.

Prompt aumentado
Prompt final entregado al modelo, resultante de combinar la consulta del usuario con el contexto recuperado desde la base vectorial.

Prompt del sistema
Instrucciones de configuración que definen el rol, las capacidades y las restricciones del modelo, invisibles al usuario en condiciones normales de operación.

Proxy de seguridad
Componente externo e independiente del LLM que intercepta la entrada y la salida del flujo de inferencia para aplicar controles de validación y sanitización.

RAG
Generación aumentada por recuperación (*Retrieval-Augmented Generation*). Arquitectura en que el modelo genera respuestas a partir de fragmentos recuperados desde una base de conocimiento externa, incorporados al prompt en tiempo de inferencia.

Regla de piso mínimo
Criterio de agregación del nivel global del sistema, definido como el mínimo entre los niveles alcanzados por cada subdimensión (sección 2.6).

Retrieval
Etapa del flujo RAG en que se seleccionan los fragmentos del corpus semánticamente más próximos a la consulta del usuario.

Sanitización
Modificación de la entrada o la salida del sistema mediante la eliminación o sustitución de contenido que coincide con patrones definidos como riesgosos.

Subdimensión
Eje de evaluación del modelo de madurez. El marco define cinco: D1 (Protección de entrada), D2 (Control de contexto RAG), D3 (Gestión de salida), D4 (Monitoreo y trazabilidad) y D5 (Gobernanza organizacional).

Suite
Conjunto de probes agrupados por vector OWASP, sobre el cual se calcula la Tasa de Filtrado de Ataques de forma desglosada.

Tipo funcional
Clasificación del control según el momento en que actúa respecto al evento de seguridad: preventivo, detectivo, correctivo o gobernanza (ISO/IEC 27002:2022).

TRL
Nivel de madurez tecnológica (*Technology Readiness Level*). Escala que caracteriza el grado de desarrollo de una tecnología desde la investigación básica hasta el despliegue operacional.

Vector de amenaza
Categoría de ataque definida en el OWASP LLM Top 10:2025. El marco cubre cuatro: LLM01, LLM02, LLM07 y LLM08.

Referencias

[1] OWASP Foundation. *OWASP Top 10 for Large Language Model Applications, Version 2025*. 2025. https://genai.owasp.org/llm-top-10/

[2] International Organization for Standardization. *ISO/IEC 27002:2022 — Information security, cybersecurity and privacy protection — Information security controls*. ISO, Geneva, 2022.

[3] International Organization for Standardization. *ISO/IEC 33001:2015 — Information technology — Process assessment — Concepts and terminology*. ISO, Geneva, 2015.

[4] National Institute of Standards and Technology. *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1, January 2023. https://doi.org/10.6028/NIST.AI.100-1

[5] República de Chile. *Ley 21.663 — Ley Marco de Ciberseguridad*. Diario Oficial de la República de Chile, 2024.

[6] República de Chile. *Ley 21.719 — Ley sobre Protección de Datos Personales*. Diario Oficial de la República de Chile, 2024.

[7] República de Chile. *Proyecto de Ley que regula los sistemas de Inteligencia Artificial, la robótica y las tecnologías conexas*. Boletín N° 15.869-19, en tramitación.

[8] Center for Internet Security. *CIS Controls v8.1*. CIS, 2024. https://www.cisecurity.org/controls

[9] Protect AI. *LLM Guard — Self-Hardening Firewall for LLMs*. Versión 0.3.16, 2024. https://llm-guard.com/

[10] NVIDIA / Garak Project. *Garak — Generative AI Red-teaming and Assessment Kit*. Versión 0.13.3, 2024. https://docs.garak.ai/